사회통계

확률의 기초

김현우, PhD[1]

[1] 충북대학교 사회학과 부교수

진행 순서

1. 확률 개념의 이해
2. 확률법칙
3. 결합확률, 한계확률과 조건부확률
4. 베이즈 정리

확률 개념의 이해

확률 개념의 이해

확률이론의 역사는 도박과 밀접한 연관을 갖고 있었다.

- 17세기 프랑스 도박사였던 Antoine Gombaud는 도박과 판돈의 분배 문제에 관해 고민하다가 결국 해법을 찾는데 실패하고, 당대의 천재 수학자였던 Blaise Pascal과 Pierre de Fermat에게 이에 관해 물어보았다.
- 이에 Pascal과 Fermat는 서신을 교환하면서 **확률이론(probability theory)**의 토대를 쌓기 시작했다.
- 감사하라. 이들 덕택에 여러분이 이 고생을 하는 거다.

Gombaud

Pascal

Fermat

확률 개념의 이해

왜 사회학에서 확률이론을 필요로 할까?

- 우리는 **모집단(population)**에서 **표본(sample)**을 골라낼 것이다.
- 그 뒤, (모집단을 전수조사하지 않고) 표본만을 관찰하여 어떤 성질을 찾을 것이다.
- 우리는 그 **표본의 성질**로부터 **모집단의 성질**을 **유추한다(make inference)**.
- 표본으로부터 유추된 성질이 (모집단과는 상관없이) 그저 표본만에서 우연히 나타났을 **확률**을 알고 싶기 때문에 확률이론을 필요로 한다.

확률 개념의 이해

예제 1. 동전을 한 번 던져서 앞면이 나올 가능성은 1/2이다. 그렇다면 동전을 두 번 던져서 두 번 모두 앞면이 나올 가능성은 얼마인가?

확률 개념의 이해

- 일단 동전을 (한 번) 던졌을 때, **있을 수 있는 모든 결과(all possible outcomes)**는 암만 생각해도 두 가지 뿐이다: 앞면(head)과 뒷면(tail).
- 앞면(H)이 나올 확률은 $1/2$, 뒷면(T)이 나올 확률도 $1/2$.
- 이제 두 번 던졌을 때, 있을 수 있는 모든 **결과(outcomes)**의 **집합(set)**은 다음과 같다

$$S = \{HH, HT, TH, HH\}.$$

- "답은 $1/4$이구나."
- 이 아이디어를 (동전 던지기 뿐만 아니라) 모든 현상에도 일반화할 수 있다.

확률 개념의 이해

이 예제로부터 몇 가지 유용한 개념을 배울 수 있다.

- **확률(probability)**이란 "어떤 **사건(event)**이 발생할 가능성을 나타난 값"이다.
- **사건**이란 "**표본공간(sample space)**의 특정한 부분집합"을 의미한다.
- 앞의 예제에서 사건은 "두 번 모두 앞면(HH)"으로 문제에서 주어졌다.
- **표본공간(sample space)** S란 "어떤 **시행(trial)** 또는 **실험(experiment)**에서 가능한 모든 **결과**(all possible **outcomes**)의 집합"을 의미한다.
- 앞의 예제에서 표본공간은 $S = \{HH, HT, TH, TT\}$이다.

확률 개념의 이해

- **결과(outcome)**는 시행 또는 실험에서 수집된 관측치를 뜻한다.
- 앞의 예제에서 "동전을 두 번 던진" 결과들은 HH, HT, TH, TT로 모두 4개가 있다.
- 결과와는 달리 사건은 연구자의 관심에 따라 달라질 수 있다!
- 앞에서는 "두 번 모두 앞면"이라는 사건에 관심을 두었는데, 만일 "적어도 한 번은 앞면"이라는 사건으로 관심을 바꿀 수도 있다. 이 경우 사건은 HH, HT, TH이다.

확률 개념의 이해

확률을 몇 가지 방식으로 정의할 수 있다.

- **고전적 확률(classical probability)**은 "논리적으로 생각하여" 알 수 있는 가능성을 확률로 정의하는 입장이다.
- 경험적 관찰에 근거하지 않고 논리적 판단에 의해 정의된다. 이 때문에 **분석적 확률**이라고도 불리운다.
- 표본공간 $S = \{s_1, s_2, ..., s_N\}$에서 각각의 결과(outcome)가 일어날 가능성이 동등하다면, m개의 결과(outcomes)를 포함하는 사건(event)의 확률은 다음과 같다.

$$P(E) = \frac{m}{N}$$

확률 개념의 이해

- **경험적 확률(empirical probability)**은 "장기간에 걸쳐 사건의 발생을 관찰하여(in a long run of observations) 얻은 상대적인 빈도"로 확률을 정의하는 관점이다.
- 주사위를 단 몇 차례만 던졌다면, 6이 나올 확률은 1/6이 아닐 수도 있다.
- 그러나 주사위를 제법 여러 차례 던졌다면, 6이 나올 확률은 1/6에 제법 근접할 것이다.
- 주사위를 무한히 많이 던진다면, 6이 나올 확률은 1/6에 무한히 근접할 것이다.
- 고전적 접근은 확률을 분석적으로 **연역**하고 있지만, 경험적 접근은 확률을 자료로부터 **귀납**한다.

확률 개념의 이해

확률은 사건에 대응하여 정의된다.

- "오늘 비가 내릴" 가능성이나 "동전을 열 번 던져 모두 뒷면이 나올" 가능성과 같이 관심있는 사건(event)이 먼저 정의되어 있어야 한다.
- 그 뒤 개별적인 사건에 대응하여 각각의 발생 확률을 제시할 수 있어야 한다.

사건	확률
H	$1/2$
T	$1/2$

확률 개념의 이해

이때 사건과 확률은 반드시 다음의 두 가지 법칙을 따라야 한다.

- **포괄적**이고 **상호배타적** 사건들의 확률의 합은 1이다.
- 첫째, (구분한 후에 얻어진) 자항의 총합이 모항과 같아야 한다(exhaustive). 예컨대 "10대", "20대', "30대 이상"은 자항의 총합이 모항과 같지 않은 구분이다.
- 둘째, (구분한 후에 얻어진) 자항들은 서로 배제해야 한다(mutually exclusive). 예컨대 "군필", "미필", "장교 전역"은 서로 배제하지 못하는 구분이다.
- 이에 따라 표본공간 S에 대하여 $P(S) = 1$이다.

확률법칙

확률법칙

둘 이상의 사건들 사이 관계를 그림으로 표현할 수 있다.

- 흔히 **벤 다이어그램(Venn Diagram)**으로 두 사건의 확률이 어떤 관련을 갖고 있는가를 나타낸다.
- A와 B의 **합사건(union)**은 $A \cup B$ 로 표현한다
- A와 B의 **교사건(intersection)**은 $A \cap B$ 로 표현한다.
- A의 **여사건(complement)**은 A^C 로 표현한다

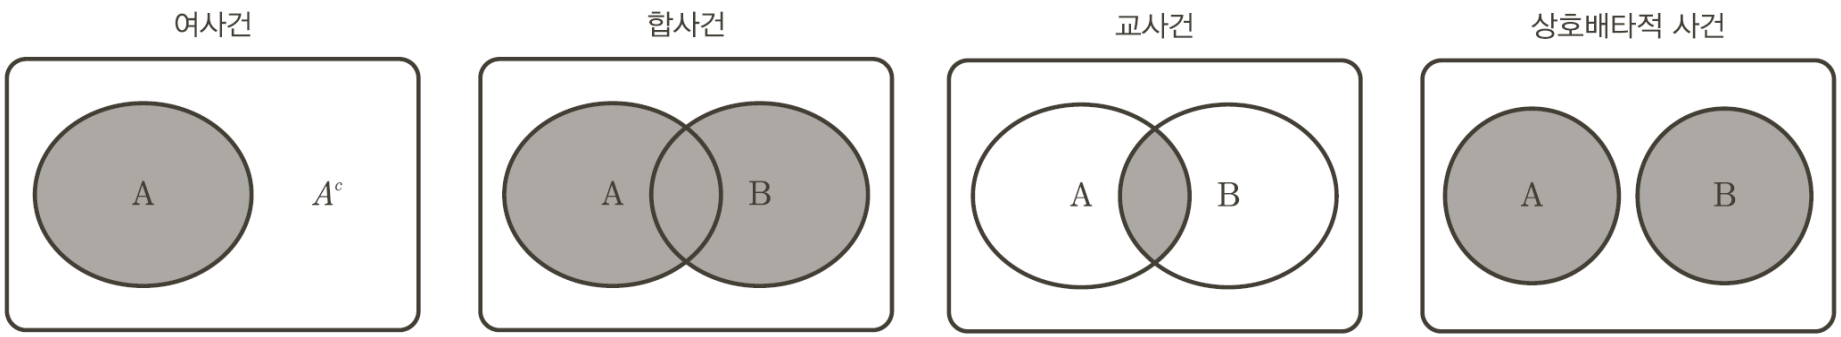

확률법칙

둘 이상의 사건들 사이 관계에 관하여 두 가지 기본 법칙이 성립한다.

- 첫째, 두 사건 A와 B 중 "최소한 한 사건이 발생"할 확률에 관해 다음의 **덧셈 법칙 (addition rule)**이 성립한다.

$$P(A \cup B) = P(A) + P(B) - P(A \cap B)$$

- 여기서 $P(A \cap B)$는 (곧 설명할) **결합확률(joint probability)**이다.
- 만일 사건 A와 B가 상호배타적(=배반사건)이라면 다음과 같이 단순화된다.

$$P(A \cup B) = P(A) + P(B)$$

확률법칙

- 둘째, 두 사건 A와 B가 "둘 다 발생할 확률"에 관해 다음의 **곱셈 법칙 (multiplication rule)**이 성립한다.

$$P(A \cap B) = P(A|B) \cdot P(B) = P(B|A) \cdot P(A)$$

- 여기서 $P(A|B)$ 또는 $P(B|A)$ 는 (곧 설명할) **조건부확률(conditional probability)**이다.

확률법칙

두 사건의 관계를 독립사건 혹은 종속사건으로 이해할 수 있다.

- 두 사건 A와 B가 있을 때, $P(A|B) = P(A)$ 이거나 $P(B|A) = P(B)$ 이거나 $P(A \cap B) = P(A)P(B)$ 이면 두 사건은 **독립(independent)** 사건이다(Why?).
- (두 사건은 독립 아니면 종속이므로) 위 식이 성립하지 않으면 두 사건은 **종속(dependent)** 사건이다.
- A와 B가 독립적인 사건들이라면 덧셈 법칙은 좀 더 단순해진다(Why?).

$$P(A \cup B) = P(A) + P(B) - P(A)P(B)$$
$$P(A \cap B) = P(A) \cdot P(B)$$

확률법칙

- 세 독립사건인 경우에는 다음이 성립한다(Why?).

$$P(E_1 \cup E_2 \cup E_3) = P(E_1) + P(E_2) + P(E_3) \\ - P(E_1E_2) - P(E_1E_3) - P(E_2E_3) + P(E_1E_2E_3)$$

- 이와 마찬가지로 세 독립사건인 경우에 다음이 성립한다(Why?).

$$P(E_1 \cap E_2 \cap E_3) = P(E_1) \cdot P(E_2) \cdot P(E_3)$$

- A와 B가 상호배타적(=배반사건)이라면, A와 B는 함께 일어날 수 없으므로 독립사건이 될 수조차 없다(Why?).

결합확률, 한계확률과 조건부확률

결합확률, 한계확률과 조건부확률

지금까지 배운 것을 토대로 자료 설명에 유용한 확률 개념을 도출한다.

- 어떤 자료가 주어졌을 때, "두 사건이 동시에 일어날 확률"을 **결합확률(joint probability)**이라고 부른다.

$$\begin{aligned} P(A \cap B) &= P(A|B) \cdot P(B) \\ &= P(B|A) \cdot P(A) \end{aligned}$$

- 결합확률은 곱셈법칙을 그대로 이용한다.
- 위 수식의 의미를 천천히 음미해보아야 한다.

결합확률, 한계확률과 조건부확률

- **조건부확률(conditional probability)**이란 "다른 사건(B)이 이미 있어났다는 전제 아래, 한 사건(A)이 일어날 확률"을 의미한다.

$$P(A|B) = \frac{P(A \cap B)}{P(B)}$$

- 조건부확률 또한 곱셈법칙을 그대로 이용한다(Why?).
- 결합확률과는 달리 조건부확률에서는 **교환법칙(commutative property)**이 성립하지 않는다.

$$P(A \cap B) = P(B \cap A)$$
$$P(A|B) \neq P(B|A)$$

결합확률, 한계확률과 조건부확률

- **한계확률(marginal probability)**은 "연관된 결합확률의 합"이다.

$$P(A) = P(A \cap B) + P(A \cap B^C) \tag{1a}$$

$$= P(A|B) \cdot P(B) + P(A|B^C) \cdot P(B^C) \tag{1b}$$

- (1b)는 조건부확률 $P(A|B)$의 정의를 이용하여 (1a)에서 도출된 것이다.

결합확률, 한계확률과 조건부확률

우리는 사실 이 개념들을 이미 배웠고 심지어 엑셀에서 활용까지 했다.

- 자료부터 교차표를 만든 뒤, 행 합계(row total)로 표준화한다.
- 아래 교차표를 들여다보면 $P(\text{종교인}|\text{여자}) = 0.44$, $P(\text{비종교인}|\text{여자}) = 0.56$, $P(\text{종교인}|\text{남자}) = 0.23$, $P(\text{비종교인}|\text{남자}) = 0.77$ 임을 알 수 있다.
- 이것이 바로 **조건부확률(conditional probability)**이다.

	종교인	비종교인	행 합계
여자	97	124	221
남자	68	232	300
열 합계	165	356	521

	종교인	비종교인	행 합계
여자	0.44	0.56	1
남자	0.23	0.77	1
열 합계	0.32	0.68	1

결합확률, 한계확률과 조건부확률

- 만약 열 합계(column total)로 표준화한 경우 다른 해석을 해야 한다(Why?)
- 아래 교차표를 들여다보면 P(여자|종교인), P(남자|종교인), P(여자|비종교인), P(남자|비종교인)을 구할 수 있다.
- 이것들도 물론 **조건부확률(conditional probability)**이다.

	종교인	비종교인	행 합계
여자	97	124	221
남자	68	232	300
열 합계	165	356	521

	종교인	비종교인	행 합계
여자	0.59	0.35	0.42
남자	0.41	0.65	0.58
열 합계	1	1	1

결합확률, 한계확률과 조건부확률

- 마지막으로 총 합계(grand total)로 표준화한 경우 다른 해석을 해야 한다.
- 아래 교차표를 들여다보면 $P(\text{종교인} \cap \text{여자}) = 0.19$, $P(\text{비종교인} \cap \text{여자}) = 0.24$, $P(\text{종교인} \cap \text{남자}) = 0.13$, $P(\text{비종교인} \cap \text{남자}) = 0.45$ 임을 알 수 있다.
- 이것이 바로 **결합확률(joint probability)**이다.

	종교인	비종교인	행 합계
여자	97	124	221
남자	68	232	300
열 합계	165	356	521

	종교인	비종교인	행 합계
여자	0.19	0.24	0.42
남자	0.13	0.45	0.58
열 합계	0.32	0.68	1

결합확률, 한계확률과 조건부확률

- **한계확률(marginal probability)** 역시 교차표에서 계산할 수 있다.

$$\begin{aligned} P(\text{종교인}) &= P(\text{종교인} \cap \text{여자}) + P(\text{종교인} \cap \text{남자}) \\ &= P(\text{종교인}|\text{여자}) \cdot P(\text{여자}) + P(\text{종교인}|\text{남자}) \cdot P(\text{남자}) \end{aligned}$$

$$\begin{aligned} P(\text{비종교인}) &= P(\text{비종교인} \cap \text{여자}) + P(\text{비종교인} \cap \text{남자}) \\ &= P(\text{비종교인}|\text{여자}) \cdot P(\text{여자}) + P(\text{비종교인}|\text{남자}) \cdot P(\text{남자}) \end{aligned}$$

- $P(\text{여자})$와 $P(\text{남자})$도 연습삼아 계산해보자.

결합확률, 한계확률과 조건부확률

- 교차표가 2×2 가 아니라 3×3 라도 조금 더 길어지지만 본질은 똑같다.

	보수적 성역할 태도	중립적 성역할 태도	진보적 성역할 태도	합계
소득: 상	486	761	279	1526
소득: 중	1024	1080	967	3071
소득: 하	662	822	434	1918
합계	2172	2663	1680	6515

- 여기서도 표준화 방식에 따라 상이하게 조건부확률과 결합확률을 구할 수 있다.
- 한계확률도 마찬가지다. 다만 2×2 방식이 아니므로,

$$P(A) = P(A \cap B) + P(A \cap B^C)$$

대신 다음과 같이 표현한다.

$$P(A) = P(A \cap B_1) + P(A \cap B_2) + P(A \cap B_3)$$

베이즈 정리

베이즈 정리

이제 인공지능 분야에서 새롭게 피어난 확률이론의 꽃을 살펴보자.

- 지금까지 배운 개념들을 토대로 **베이즈 정리(Bayes' Theorem)**를 살펴보자

$$
\begin{aligned}
P(A|B) &= \frac{P(A \cap B)}{P(B)} \qquad\qquad (\text{if } P(B) \neq 0) \\
&= \frac{P(B|A) \cdot P(A)}{P(B)} \\
&= \frac{P(B|A) \cdot P(A)}{P(B|A) \cdot P(A) + P(B|A^C) \cdot P(A^C)}
\end{aligned}
$$

- **사전확률(prior probability)**인 $P(A)$와 $P(A^C)$ 그리고 **우도(likelihood)**인 $P(B|A)$를 알면 **사후확률(posterior probability)** $P(A|B)$를 알 수 있다.
- 좌변의 $P(A|B)$가 우변에서는 모두 $P(B|A)$와 같이 바뀌었음에 주목하자!

베이즈 정리

예제 2. 사지선다 문제를 맞추었을 때 알고 풀었을 확률을 구하시오(단, 답을 아는 사전확률과 모르는 사전확률은 같다고 전제한다).

베이즈 정리

- "답을 알(K)" 사전확률과 "답을 모르는(DK)" 사전확률이 같다면 이는 상호배타적 사건임을 의미한다.

$$P(A_K) = P(A_{DK}) = \frac{1}{2}$$

- (다른 문제도 그렇지만 특히) 베이즈 확률을 계산할 때는 문제가 묻는 것이 정확히 무엇인지 먼저 식별해야 한다.
- 여기서는 "답을 맞추었다(C)"는 조건 아래 답을 알(A_K) 확률, 즉 $P(A_K|C)$를 묻고 있다.

$$P(A_K|C) = \frac{P(C|A_K) \cdot P(A_K)}{P(C|A_K) \cdot P(A_K) + P(C|A_{DK}) \cdot P(A_{DK})}$$

베이즈 정리

- 곰곰히 생각하면 우도(likelihood)가 무엇인지 알 수 있다(Why?).

$$P(C|A_K) = 1$$
$$P(C|A_{DK}) = \frac{1}{4}$$

- 그러므로 문제가 찾는 답은 다음과 같다.

$$P(A_K|C) = \frac{1}{1+\frac{1}{4}} = \frac{4}{5}$$

- 문제를 맞췄다고 하여 반드시 답을 알고 있었던 것은 아니다. 베이즈 정리는 그 확률마저 예측한다!

베이즈 정리

베이즈 정리에는 독특한 역사가 있다.

- 장로교 목사이자 아마추어 수학자였던 Thomas Bayes (1701?–1761)는 David Hume의 회의주의적 경험론에 반발하여 (아마도) 신의 존재를 수학으로 증명하는데 관심이 있었다.
- 그의 논문은 한때 완전히 잊혀졌다가 Pierre-Simon Laplace (1749–1827)에 의해 재발견되었다.
- 그러나 20세기 들어 통계학이 급성장하면서 Karl Pearson, Ronald Fisher, Jerzy Neyman 등이 베이즈의 관점과 상이한 통계추론의 논리를 제시하면서 다시 한 번 잊혀졌다.

Bayes

Laplace

Pearson

Fisher

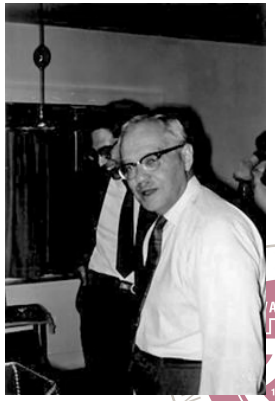
Neyman

베이즈 정리

- 21세기 들어 **인공지능(AI)**과 **기계학습(machine learning)**의 시대가 도래하면서 다시 한 번 **베이즈 통계학(Bayesian statistics)**이 부상하게 되었다.
- 20세기 통계학의 관점을 **빈도주의 통계학(frequentist statistics)**이라고도 부른다.
- 우리 수업은 (아쉽게도 베이즈 통계학이 아니라) 빈도주의 통계학의 기초를 배우는 과정이다.
- 뇌의 작동 방식이 베이즈 정리에 의해 잘 설명된다는 주장이 있지만, 아쉽게도 베이즈 통계학은 **계산집약적(computationally intensive)**인 점이 흠이다.

베이즈 정리

- 확률의 기초는 **베이즈 정리**를 알기 전과 이것을 안 뒤로 나뉜다.
- 몇 가지 흥미로운 논리적 문제를 풀 수 있다: **몬티 홀 문제**(the Monty Hall Problem), 다운증후군 임신 테스트 신뢰성 문제 등등...
- 그 밖에도 몇 가지 실생활에서 할 수 있는게 있다: 사람의 말과 글을 알아듣는 기계나 자율주행하는 자동차를 만든다던가 등등...
- (R이나 Python 등을 통해) 20–30줄 정도의 코드로도 꽤 쓸모있는 인공지능을 구현할 수 있다.
- 3학년이나 4학년 때 소셜데이터사이언스 수업에서 살짝 다룬다.