사회통계

통계학과 자료의 이해

김현우, PhD[1]

[1] 충북대학교 사회학과 조교수

March 4, 2022

진행 순서

1. 경험과학으로의 초대
2. 통계학의 기초 어휘
3. 자료유형
4. 리커트 척도
5. 자료유형별 분석기법

경험과학으로의 초대

경험과학으로의 초대

오늘날 통계적 리터러시가 갖는 중요성은 대단히 높다.

- 제4차 산업혁명의 기반기술(빅데이터, 인공지능, IoT 등) 전문가 수요
- 급속히 증가하는 데이터의 양: 오늘날 전 세계 데이터의 90%가 최근 2년 동안 생성
- 통계학은 인공지능, 빅데이터 분석, 기계학습(machine learning) 등의 기초가 된다.
- 다른 한편으로 통계학은 경험과학(empirical science)의 방법론적 도구이다.

경험과학으로의 초대

경험과학이란 무엇인가?

- 경험과학으로서 사회학이란 "사회 현상을 체계적으로 관찰하여 얻어낸 자료(data)를 토대로 분석하여 법칙이나 원리 따위를 개발하는 학문"이다.
- 넓게 보면 이렇게 "증거를 수집하고 정리하는 체계적인 절차"를 개발하는 것도 경험과학의 일부로 볼 수 있다.
- 이렇게 "증거를 수집 정리하는 체계적인 절차"를 흔히 방법(method)이라고 하며, 방법론(methodology)이란 방법(method)에 대한 과학이다.
- 여러분은 사회조사방법론을 3학년에 배운다. 하지만 사회조사방법론 이외에도 경험과학적 접근은 사회학 전체에 걸쳐 이루어진다.

경험과학으로의 초대

(너무나도 당연한 말이지만) 경험과학은 측정도구를 필요로 한다!

- 측정(measurement)이란 "어떤 현상을 관찰한 후 일정한 규칙에 따라 수치를 부여하는 것"이다.
- 이런 행위에는 현상을 계량할 수 있다(quantifiable)는 인식론을 내포하고 있다. 어떤 사람은 이런 관념을 배격한다.
- 경험과학의 개념화는 사실 매우 복잡한 역사를 가지고 있다. 논쟁 끝에 우리가 지금 아는 경험과학이 정립되었다. 몇몇 과학철학자들은 여전히 이러한 개념화를 선호하지 않는다.

경험과학으로의 초대

교과서대로라면 경험과학적 연구는 아래 순서대로 진행된다.

1. 문제인식: 엄격한 정의, 왜 연구가 필요한가, 기존 연구 속에 위치
2. 가설설정: 잠정적 진술의 꼴
3. 연구설계: 누구/무엇을, 언제, 어떻게 연구?
4. 자료수집: 설문조사? 실험?
5. 자료분석: 이른바 통계적 분석(statistical analysis)
6. 가설검정 및 일반화: 가설의 입증 또는 기각
7. 결과발표: 논문 또는 포스터

경험과학으로의 초대

경험과학은 자료를 토대로 한다.

- 주장(argument)에는 증거(evidence)가 필요하고, 증거는 자료(data)를 토대로 얻는다.

자료에 대해 여러분이 알아야 할 모든 상식!

- 발음은 데이타(o), 다타(x), 뎃타(x)
- 어원은 라틴어 dare -> 주다(to give).
- Data는 복수. datum은 단수. 하지만 일상 생활에서 datum이란 단어를 누가 들어본 적이나 있을까? "Your data are trash." 같이 말해야하지만 who cares?
- 딱 하나의 관측치가 주어졌다면 이것은 데이터라고 하지 않는다(정의상 이것은 datum이다). 다시 말해, 일단 자료(data)가 주어졌다면 이것은 필연적으로 많은 관측치(many observations)가 있음을 의미한다.

경험과학으로의 초대

많은 관측치를 담고 있다보니 아무래도 자료를 요약해야 할 필요가 있다.

- 많은 관측치들의 성격을 요약하여 나타낸 숫자들을 일컫어 기술통계(descriptive statistics)라고 한다.
- 이때 기술(記述)이란 기록하고 서술한다는 것이지, 테크닉같은 기술을 말하는 것이 아니다.
- 다음 주에는 본격적으로 어떻게 기술통계을 계산하는지에 관해 공부한다.

경험과학으로의 초대

통계학은 "자료를 수집 · 요약 · 분석하는 이론과 방법" 으로 정의된다.

- "A body of techniques and procedures dealing with the collection, organization, analysis, interpretation, and presentation of information that can be stated numerically."

Kuzma, J. W. 1984. Basic Statistics for the Health Sciences. Palo Alto, CA: Mayfield.

경험과학으로의 초대

사회통계에서는 자료가 일단 주어졌다고 전제하고 시작한다.

- 데이터 수집의 설계, 수행, 관리, 보관 등의 이슈는 다른 수업에서 다루어야 한다.
- 우리 과에서는 사회조사방법론이 개설되지만 본격적인 서베이 방법론(Survey Methodology), 데이터베이스(SQL 등), 클라우드 컴퓨팅(Cloud Computing) 등은 (적어도 현 시점) 개설되지 않으므로 (원한다면) 다른 과에서 들어야 한다.

통계학의 기초 어휘

통계학의 기초 어휘

통계학과 통계는 statistics로 동일하게 표현되지만 의미가 서로 다르다.

- 통계학(statistics): 필요한 자료를 최적의 방법으로 수집하고, 수집한 자료를 과학적이고 논리적으로 요약, 표현 및 분석하는 학문을 의미한다.
- 통계(statistics): 양적 자료(quantitative data)의 모음(collection)을 뜻한다.

통계학의 기초 어휘

통계학은 기술통계학과 추론통계학의 두 유형으로 구분된다.

- 기술통계학(descriptive statistics): 수집된 자료의 특성을 정리 및 요약하여 기술하는(describe) 통계학
- 추론통계학(inferential statistics): 표본의 통계량을 기초로 모집단 전체의 특성을 추론하고(infer) 일반화하는(generalize) 통계학

통계학의 기초 어휘

추론통계학은 표본의 특성(=통계량)을 통해 모집단의 특성(=모수)을 유추한다.

- 모집단(population): 연구자의 관심 대상이 되는 전체 집단
- 표본(sample): 모집단을 대표하도록 선택된 모집단에 속한 일부 부분집합
- 모수(parameter): 연구 중인 모집단의 특성을 표현한 참값
- 통계량(statistic): 표본의 특성을 요약한 값

통계학의 기초 어휘

자료의 단위(unit)는 관찰과 분석 단계에서 서로 다를 수 있다.

- 자료(data): 분석 대상의 속성(attributes)을 기록한 수열(series). "자료의 관찰"은 사람을 단위로 이루어졌으나, 나중에 "자료의 분석"은 각 사람이 속한 지역 또는 국가 단위로 이루어질 수도 있다.
- 관찰단위(unit of observations): 자료의 관찰과 수집이 이루어지는 단위
- 분석단위(unit of analysis): 분석이 수행되고 발견이 일반화(generalization)될 수 있는 단위

통계학의 기초 어휘

예제 1. 다음 자료의 관찰단위는 무엇인가?

ID	female	socialclass	IQ	income
1	1	3	135	250
2	0	2	110	310
3	1	1	128	1500
4	0	2	98	122
5	1	2	106	450
6	0	3	102	190

통계학의 기초 어휘

데이터는 사각형이다.

- 앞서 데이터는 수열이라고 말했지만, 사실 여러 변수(variables)를 갖기 때문에 각각의 변수가 하나씩 수열을 이루어서 결국 행렬(matrix)이 된다.
- 행렬은 행과 열의 조합이다. 행은 가로고, 열은 세로다.
- 행은 rows (=극장 따위의 좌석 줄)라고 쓰고, 열은 columns (=기둥)이라고 쓴다.

ID	female	socialclass	IQ	income
1	1	3	135	250
2	0	2	110	310
3	1	1	128	1500
4	0	2	98	122
5	1	2	106	450
6	0	3	102	190

통계학의 기초 어휘

열(columns)은 변수(variables)가 되고, 행(rows)은 관측치(observations)가 된다.

- 변수(variables)는 변(vary)할 수 있는(able) 숫자를 말한다.
- 위 예제에서 변수는 모두 4개, 관측치는 모두 6개다(Why?).
- 그러므로 데이터를 남에게 설명할 때 "변수는 몇 개, 관측치는 몇 개"와 같은 식으로 표현할 수 있다.

ID	female	socialclass	IQ	income
1	1	3	135	250
2	0	2	110	310
3	1	1	128	1500
4	0	2	98	122
5	1	2	106	450
6	0	3	102	190

통계학의 기초 어휘

여러 변수들이 모여 자료를 구성할 수 있다.

- 변수(variable): 여러가지 값 중 하나를 취할 수 있도록 변동하는 수량. 반면, 상수(constant)는 변동하지 않는 수량
- 독립변수(independent variable): 다른 변수에 의해 영향받지 않고 다른 변수의 원인(cause)으로 파악될 수 있는 변수. 따라서 설명변수(explanatory variable)라고도 함
- 종속변수(dependent variable): 독립변수에 의해 영향을 받으므로 결과(effect)로 파악될 수 있는 변수. 따라서 반응변수(response variable)라고도 함

ID	female	socialclass	IQ	income
1	1	3	135	250
2	0	2	110	310
3	1	1	128	1500
4	0	2	98	122
5	1	2	106	450
6	0	3	102	190

자료유형

자료유형

각각의 변수마다 자료유형(data type)이 다를 수 있다.

- 자료유형이 다르다는 것은 보다 구체적으로 측정의 척도(scales of measurement)가 다르다는 것을 뜻한다.
- 측정의 척도란 변수가 정의(define)되고 유형화(categorize) 되는 방식을 뜻한다.
- 보통 네 종류의 척도를 거론할 수 있다: 명목(nominal), 서열(ordinal), 등간(interval), 비율(ratio).

자료유형

네 종류의 척도에는 위계적인 관계가 있다.

- 명목척도(nominal scale): 범주(category)가 존재할 뿐, 그들 사이에 우열이나 대소가 없음
- 서열척도(ordinal scale): 범주들 사이에 서열 혹은 순서(order)가 있음
- 등간척도(interval scale): 범주들 사이에 우열이나 대소가 있고, 그 간격은 동등함 (등간; equal interval)
- 비율척도(ratio scale): 범주들 사이에 우열이나 대소가 있고, 그 간격도 동일하며, 절대영(absolute zero) 또한 의미를 가짐

ID	female	socialclass	IQ	income
1	1	3	135	250
2	0	2	110	310
3	1	1	128	1500
4	0	2	98	122
5	1	2	106	450
6	0	3	102	190

자료유형

네 종류의 척도는 각각이 가진 정보량에 차이가 있다.

- 정보량의 크기는 다음과 같다: 비율 > 등간 > 서열 > 명목 (Why?)

척도	Category	Order	Equal interval	Absolute zero
명목(nominal)	O	X	X	X
서열(ordinal)	O	O	X	X
등간(interval)	O	O	O	X
비율(ratio)	O	O	O	O

Stevens, S. S. 1946. "On the theory of scales of measurement." Science 103: 677–680.

자료유형

- 명목척도에는 우열이 없다. 예를 들어 {남자=1, 여자=0} 이라고 입력하더라도 남자를 지시하는 숫자가 크다고 딱히 우월한 게 아니다.
- 서열척도로는 산술연산을 아예 할 수 없다(Why?). 예컨대 1+2=3이 성립하려면 2가 1보다 정확히 두 배 커야 하기 때문이다.
- 등간척도로는 덧셈과 뺄셈은 할 수 있지만 곱셈과 나눗셈은 할 수 없다(Why?). 대수적으로 절대영(absolute zero)이 정의되지 않기 때문이다.
- 비율척도로는 모든 사칙연산을 할 수 있다!

자료유형

척도 간에는 변환(recoding)이 가능하지만 오로지 일방향으로만 가능하다!

- 왜 정보가 많은 쪽에서 정보가 적은 쪽으로만 변환 가능할까?
- 정보량에 차이가 있기 때문에 변환하는 순간 "사라진 정보"는 복원 불가능하게 된다.
- 예를 들면 비율척도로 측정된 월평균 소득은 다음과 같이 서열척도로 변환할 수 있다. {100만원 미만=1; 100만원 이상~300만원 미만=2; 300만원 이상~500만원 미만 =3; 500만원 이상=4}

자료유형

근데 현실에서는 양적변수와 질적변수로 대충 나누는 경우가 많다.

- 양적변수(quantitative variable): 수치로 나타내는 변수로, 상대적으로 풍부한 정보를 내포함. 정수로만 셀 수 있는 이산변수(discrete variable)와 소숫점을 허용하는 연속변수(continuous variable)로 구분됨
- 질적변수(qualitative variable): 범주로서의 성격만 가지는 변수. 상대적으로 정보의 양은 적지만 양적변수로 표현하기 곤란하기 어려운 뉘앙스(nuance)를 나타낼 수 있음
- 비율척도와 등간척도는 양적변수인 반면, 서열척도와 명목척도는 질적변수가 됨

자료유형

예제 2. 모 대학의 학칙에 따르면 {학점 90점 이상=A; 80–89점=B; 70–79점=C; 60–69점=D; 60점 미만=F}으로 letter grade가 부여된다. 이때 letter grade의 척도는 무엇인가? 만약 letter grade가 주어졌을 때 이를 원점수로 변환할 수 있는가?

- A에서 F까지에는 순서가 명백히 있다. 하지만 A에서 B까지의 간격이 B에서 C까지의 간격과 동등한 것은 아니다. 그러므로 서열척도이다. 물론 서열척도는 범주형 변수로 분류된다.
- 원점수에는 순서가 명백히 있을 뿐 아니라 간격도 동등하다. 게다가 절대영도 성립한다. 그러므로 비율척도이다. 비율척도의 정보량은 서열척도의 정보량보다 많으므로 letter grade에서 원점수로는 변환할 수 없다. 반대로 원점수에서 letter grade로는 변환할 수 있다.

리커트 척도

리커트 척도

많은 사회통계학의 자료가 설문조사(questionnaire survey)로 수집된다.

※ 다음으로, 일과 직장문화에 대한 견해를 여쭈어 보겠습니다.

143. 귀하의 직장에서 매우 성공적인 직원으로 인정받는 사람의 이미지를 생각해보십시오. 아래 특성이 그 사람들의 특성에 해당된다고 생각하십니까? (현재 취업하지 않은 경우라면 예전 직장이나 본인이 취업할 만한 미래의 직장을 생각하며 답해주십시오)

		매우 그렇다	다소 그렇다	보통	별로 그렇지 않다	전혀 그렇지 않다	모르겠다
SUCCEMP1	1) 장시간 근무한다	①	②	③	④	⑤	(8)
SUCCEMP2	2) 기꺼이 야근을 한다	①	②	③	④	⑤	(8)
SUCCEMP3	3) 근무시간 후에도 즉각적인 카톡/문자 메시지를 통해 연락이 된다	①	②	③	④	⑤	(8)
SUCCEMP4	4) 가족을 위해 필요한 경우 휴가를 쓴다	①	②	③	④	⑤	(8)
SUCCEMP5	5) 사내 행사나 부서 회식에 적극적으로 참여 한다	①	②	③	④	⑤	(8)

SUCCEMPM

144. 이어지는 질문입니다. 귀하께서는 귀하가 답하신 성공적인 사람들의 이미지에 얼마나 가까운 편입니까? (현재 취업하지 않은 경우라면 예전 직장이나 본인이 취업할 만한 미래의 직장을 생각하며 답해주십시오)

____ ① 매우 가깝다 ____ ③ 보통 ____ ⑤ 전혀 가깝지 않다

____ ② 다소 가깝다 ____ ④ 별로 가깝지 않다 ____ (8) 모르겠다

한국종합사회조사(KGSS) 설문지 예제

리커트 척도

- 위 설문의 중요한 특징은 바로 (주어진 문항에 대하여) "동의하는 정도를 미리 설정한 카테고리 중에 고르도록 유도했다"는 것이다.
- 5단계 척도를 많이 사용하지만, 연구자에 따라서는 7/9단계, 또는 중립적인 응답을 제외시킨 4/6/8단계를 사용하기도 한다(Why?).
- 이런 식으로 특정하게 서열화된 응답을 유도하는 척도를 특별히 리커트 척도(Likert scale)라고 부른다.
- Rensis Likert는 미시건대 사회학 학부를 나오고 컬럼비아대에서 바로 이 척도에 대한 심리학 박사논문을 썼다.

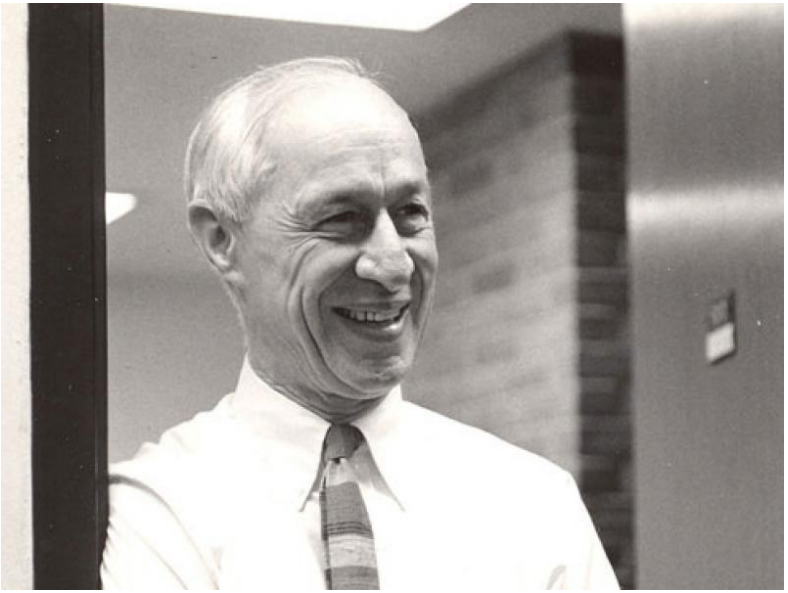

Rensis Likert (1903-1981)

리커트 척도

엄밀히 말해 리커트 척도는 서열척도이다. 하지만...

- (앞서 설명하였듯) 원칙적으로 서열척도로는 산술연산이 불가능하다.
- 그러나 현실적으로 많은 연구에서 리커트 척도를 마치 등간척도처럼 사용한다.
- 어떤 경우에 이와 같은 관행이 정당화될 수 있을까?

  (1) 범주의 숫자가 많은 경우
  (2) 여러 개의 리커트 척도를 함께 사용하는 경우

리커트 척도

- 첫째로, 리커트 척도는 서열척도지만 범주의 숫자가 아주 많아지면 등간척도에 점차 근접하게 되므로(Why?), 범주의 숫자가 많다는 조건 아래 등간척도처럼 취급할 수도 있다.
- 연속변수인 시험 점수를 질적변수로 변환하는 여러 방식을 생각해보자. 범주가 많아질수록 본래의 연속변수에 점차 근접한다(approximately interval).

  (1) {40점 미만=1; 40점-60점=2; 60점-80점=3; 80점 이상=4}
  (2) {10점 미만=1; 10점-20점=2; $\cdots$ 80점-90점=9; 90점-100점=10}
  (3) {0점=0; 1점=1; 2점=2; $\cdots$; 98점=98; 99점=99; 100점=100}

리커트 척도

- 둘째로, 여러 리커트 척도를 함께 사용하여 비슷한 대상을 여러모로 측정하면 그것의 합 또는 평균은 매우 등간척도와 유사하다고도 볼 수 있다.
- (리커트 척도의 숫자가 클수록 문항에 동의하는 정도가 높다고 가정하면) 아래 문항 중 네 문항은 큰 값을 가질수록(나머지 하나는 작은 값을 가질수록) 일에 몰두하는 사람임을 보여준다.

설문문항	리커트 척도
1) 장시간 근무한다	① ② ③ ④ ⑤
2) 기꺼이 야근을 한다	① ② ③ ④ ⑤
3) 근무시간 후에도 즉각적인 카톡/문자 메시지를 통해 연락이 된다	① ② ③ ④ ⑤
4) 가족을 위해 필요한 경우 휴가를 쓴다	① ② ③ ④ ⑤
5) 사내 행사나 부서 회식에 적극적으로 참여 한다	① ② ③ ④ ⑤

- 모든 리커트 척도 문항의 합은 최소 5에서 최대 25사이에 분포한다(Why?). 이렇게 "20점 척도일 경우의 1점과 2점의 차이"는 "5점 척도일 경우의 1점과 2점의 차이"보다 점진적으로 더 등간에 가깝다(approximately interval).
- 더 세련된 사용방식은 다음 학기 사회통계연습에서 배우기로 한다.

자료유형별 분석기법

자료유형별 분석기법

왜 구태여 자료유형을 촘촘히 나누고 그 차이를 공부해야 하나?

- 자료유형에 따라 할 수 있는 분석기법이 다르기 때문이다.
- 우리에게 데이터가 이미 주어져 있다면, 어떤 분석기법을 쓸 것인가를 결정하기에 앞서 먼저 자료유형을 판정해야 한다. 자료유형에 대응하지 않는 분석기법을 사용하면 잘못된 결과를 이끌어낸다.
- 우리가 새로운 데이터를 수집한다면, 앞으로 어떤 분석기법을 사용할 것인가를 예상하고 자료유형을 결정해야 한다. 분석기법을 염두에 두지 않고 데이터를 무턱대고 수집하면 나중에 후회한다.
- 클라이언트 등이 "이 자료로 이런 분석을 하고 싶습니다" 라고 하더라도, 만일 자료유형과 분석기법이 대응하지 않는다면 왜 불가능한지 설명할 수 있어야 한다.

자료유형별 분석기법

- 예를 들면 이런식으로 쓸 수 있는 기술통계량이 다르다(구체적인 내용은 아직 몰라도 된다).

유형	척도	추가되는 연산	기술통계량
질적변수	명목척도	셈	빈도(frequency)와 구성비(percentage) 최빈값(mode)
	서열척도	순위 측정	중앙값(median) 범위(range)
양적변수	등간척도	덧셈/뺄셈	산술평균(arithmetic mean) 분산(variance)과 표준편차(standard deviation)
	비율척도	곱셈/나눗셈	기하평균(geometric mean) 조화평균(harmonic mean)

자료유형별 분석기법

- 만약 두 변수 이상의 관계를 분석한다면 (말할 필요도 없이) 모든 변수들의 자료유형을 정확히 식별하고 그에 걸맞는 분석기법을 선택해야 한다.
- 시각화(visualization) 기법이나 고급통계분석에 이르기까지 자료유형을 한눈에 보고 식별하는 것은 가장 기초적인 소양이다.
- 수많은 척도에 대응하는 자료유형을 암기해야 할까 하고 막막하게 느껴질 수 있지만 사실은 전혀 그렇지 않다. 자꾸 하다보면 힐끗 봐도 자료유형이 무엇인지 식별할 수 있고, 게다가 실무상으로는 양적인가 질적인가만 나누는 경우가 상당히 많기 때문이다.

끝!

와~ 숙제다~