사회통계
중심경향 측도

김현우, PhD[1]

[1] 충북대학교 사회학과 조교수

March 11, 2022

진행 순서

1. 지난 주 리뷰
2. 요약통계량
3. 데이터의 요약(I): 중심경향

지난 주 리뷰

지난 주 리뷰

퀴즈 1번 문제

- 수영 100m 소요시간: 비율
- 흡연여부(Yes/No): 명목
- 월소득액: 비율
- 당신의 거주지 우편번호: 명목
- 당신의 학번: 명목
- 당신이 1학년일 때 평균평점: 비율
- 마라톤 순위: 서열
- 어제 운동시간(분): 비율
- 당신의 학년(1/2/3/4): 서열
- 선호하는 색깔(빨/파/노): 명목
- A병원 방문고객수: 비율
- 2021년 1월 평균기온: 등간
- -주민등록번호: 명목
- 연령(만나이): 비율
- 사회통계 학점(A/B/C/D): 서열
- 전국 교통사고 건수: 비율
- 넓이뛰기 기록: 비율
- 브랜드 선호순위(1/2/3): 서열
- 체중: 비율
- 성별(남/여): 명목
- 스포츠 선수의 등 번호: 명목
- 당기생산 불량품수: 비율
- 기업 주가지수: 등간
- 신입/경력직 여부: 명목
- 직업군(사무직/생산직/전문직): 명목

지난 주 리뷰

- 학번은 ID와 마찬가지로 서열척도가 아니라 명목척도.
- 온도(e.g., 체온)은 등간척도. 섭씨에서는 증류수의 얼음이 언다는 것을 기준으로 삼았으나 측정하는 본질, 즉 "따뜻함"의 0에 대응하지 않는다.
- 체중, 연령(만나이)이나 소요시간 따위는 비율척도. 체중, 나이, 소요시간이 0은 일상적으로는 의미가 와닿지 않지만 수학적으로는 문제가 없다. "당신은 나보다 나이가 두 배 많다"도 make sense. 그런데 의외로 연령은 서열척도라는 대답이 많다. 유교문화?

지난 주 리뷰

- 당신의 학년(1/2/3/4)은 서열척도. 명목이라는 응답이 좀 많다. 서열(ordinal)은 우열 뿐 아니라 순서(order)라는 의미도 있다. 1학년 다음에야 2학년이 될 수 있다.
- 신입/경력직 여부는 명목척도. 근데 서열이라고 한 학생들도 좀 있었다. 왜죠?
- 선호하는 색깔(빨/파/노)는 명목척도. 서열이라고 말한 학생이 제법 많았다. 왜죠?
- 기업 주가지수는 등간척도. 지수(index)는 개념상 단지 다른 여러 숫자들을 조합해서 만든 또다른 숫자이므로 절대영은 의미가 없다.

지난 주 리뷰

총평

- 한두 문제 맞고 틀리는 것에 집착하지 말 것. 데드라인을 포함하여 숙제 미제출을 두려워할 것.
- 파일 이름에 자신의 이름을 쓰지 말 것. 파일 이름에는 몇 주차인지와 학번만 쓸 것 (e.g., 1주차_202203091.docx) 답안지 맨 끝에만 이름과 학번을 쓸 것.
- 교과서는 여기서 구입할 수 있다: http://www.enamuh.com/shop/item.php?it_id=9791156646006

요약통계량

요약통계량

요약통계량이란 데이터를 요약하는 수치를 뜻한다.

- 실제 자료를 통해 맥락을 살펴보자. eCampus에서 airpollution.zip을 다운받아 압축을 풀자.
- 이 자료는 에어코리아(https://www.airkorea.or.kr)에서 다운받은 2021년 7월까지 우리나라 전역의 대기오염 상태에 관한 데이터이다.
- 가장 기본적으로 데이터를 요약할때는 파일의 크기를 이야기할 수 있다.
- 2021년 2월.xlsx은 얼마나 큰가? 2021년 4월.xlsx은 얼마나 큰가? 2021년 6월.xlsx은 얼마나 큰가? 대체로 이 파일의 크기는 일정하다고 말할 수 있나?
- 2021년 전체에 걸쳐 파일들은 도합 얼마 정도인가?

요약통계량

- 오늘날 본격적인 빅데이터 분석에 쓰이는 데이터의 파일 사이즈는 최소한 수 기가바이트(giga byte)에서 수 페타바이트(peta byte)에까지 달한다.
- 이 자료는 귀엽게도 150 MB보다 작다. 개별 파일은 20 MB 정도다.
- 이런 장난감 데이터(toy data) 말고, 가령 미국인구 전체를 포괄하는 마케팅 데이터인 Infutor같은 경우에는 매달 수백 기가짜리 파일이 몇 개씩 생산된다.
- 매우 큰 파일은 그에 적합한 보관, 처리 및 분석 기법을 요구하므로 엑셀로는 불가능!
- 그러나 앞으로 우리 수업은 더이상 이런 주제를 다루지 않고 엑셀로 다룰 수 있는 작은 파일들로 예제를 한정한다.

요약통계량

- 데이터 사이즈는 기하급수적으로 팽창하고 있다!
- 하지만 옛날에는 메가 단위를 엄청 큰 것으로 생각했지만, 지금은 내 손바닥만한 휴대폰도 260 GB를 저장할 수 있다.
- 시대는 급속도로 변하고 있다. 앞으로 더 빨리 변할 것이다.

5MB IBM Hard Drive circa mid-1950s

요약통계량

실제 자료를 가지고 자신의 자료를 남에게 설명해보자.

- 2021년 3월.xlsx를 엑셀에 불러오자.
- 전주에 학습하였듯 자료는 사각형 꼴이다. 좀 더 수학적으로 표현하자면 행렬이다.
- 행은 rows (=극장 따위의 좌석 줄)라고 쓰고 열은 columns (=기둥)이라고 쓴다.
- 변수(variables)는 모두 몇 개인가? 관측치(observations)는 모두 몇 개인가?
- 데이터를 남에게 설명할 때 "변수가 몇 개, 관측치가 몇 개" 이런 식으로 표현할 수 있다!

요약통계량

철수: “영희야, 너희 부서에서 다루는 데이터는 어떻니?”
영희: “2021년 3월에 약 26메가 짜리 데이터를 생성하고 보관하고 있어.”
철수: “작구나.”
영희: “변수는 12개지만 관측치는 440,000개가 넘지.”
철수: “어, 다시 들으니 무지 크네.”

- 기술적으로는 대단히 crude (=거칠고 조잡하다)한 표현이지만 현실에서는 종종 이렇게 말한다.
- 하지만 이런 식으로 데이터의 크기를 두고 (본격적인) 요약통계량(summary statistics)이라고는 하지 않는다.

데이터의 요약(I): 중심경향

데이터의 요약(I): 중심경향

요약통계량는 데이터의 중심이 어디에 있는가를 설명하는 것에서 출발한다.

- 데이터를 대표하는(representative) 값은 데이터의 가운데 어딘가에 위치해 있다라는 아이디어.
- 뭔가 그럴 듯 하지 않나? "데이터의 가운데 있는게 대표적이다" 라는 발상!
- 주로 세 가지 통계량이 중심경향(central tendency)을 파악하기 위해 사용된다.

  (1) 평균(average; mean)
  (2) 중앙값(median)
  (3) 최빈값(mode)

데이터의 요약(I): 중심경향

평균이란 모든 관측치을 모두 더한 뒤, 이를 관측치의 갯수로 나누어준 값이다.

- 이 정의는 사실 좀 더 일반화될 수 있는 여지를 남기고 있다.
- 통계학이 가진 중요한 특징은 모집단(population)을 곧장 분석하는게 아니라 표본(sample)을 분석한다는 점이다.
- 모집단의 평균, 즉 모평균(population mean)은 표본집단의 평균, 즉 표본평균(sample mean)과 미묘하게 사용되는 기호가 다르다.

$$\mu = \frac{1}{N}\sum_{i=1}^{N} x_i = \frac{1}{N}\left(x_1 + x_2 + \cdots + x_N\right)$$

$$\bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i = \frac{1}{n}\left(x_1 + x_2 + \cdots + x_n\right)$$

데이터의 요약(I): 중심경향

- 앞서 계산한 방식을 산술평균(arithmetic mean)이라고 부르며 가장 폭넓게 쓰인다.
- 하지만 가중평균(weighted mean), 기하평균(geometric mean), 조화평균(harmonic mean)과 같은 색다른 평균 개념들도 있다.
- 가중평균에서 w_i는 i번째 관측치에 대한 가중치(weight)이다.

$$\bar{x} = w_1 x_1 + w_2 x_2 + \cdots + w_N x_N$$

- 산술평균은 다음의 조건이 성립하는 가중평균의 특수 사례에 불과하다.

$$w_1 = w_2 = \cdots = w_N = \frac{1}{N}$$

- 다른 평균 개념은 교과서를 통해 공부하자.

데이터의 요약(I): 중심경향

중앙값은 자료를 크기 순서로 정렬할 때 중앙에 위치한 수치를 의미한다.

- 일단 자료를 먼저 크기 순서대로 정렬(sort)해야한다.
- 관측치의 수에 따라 중앙의 위치가 달라지므로, 계산 방식은 관측치의 수가 홀수인 경우와 짝수인 경우가 다르다.

$$M_e = \frac{n+1}{2} \text{ 번째 위치한 값} \qquad \text{(홀수인 경우)}$$

$$M_e = \frac{(n/2) \text{ 번째 위치한 값} + [(n/2)+1] \text{ 번째 위치한 값}}{2} \qquad \text{(짝수인 경우)}$$

데이터의 요약(I): 중심경향

최빈값은 데이터에서 최고로 빈도가 높은 값이다.

- 최빈값(mode)은 자료에서 최고의 빈도수를 가진 관측치를 알려주기 때문에 아무래도 질적 변수를 요약할 때 특히 유용하다.
- 규모가 큰 양적 자료의 경우 최빈값보다는 구간으로 범주화된 최빈 계급구간(modal class interval)이 더 유용할 수도 있다.

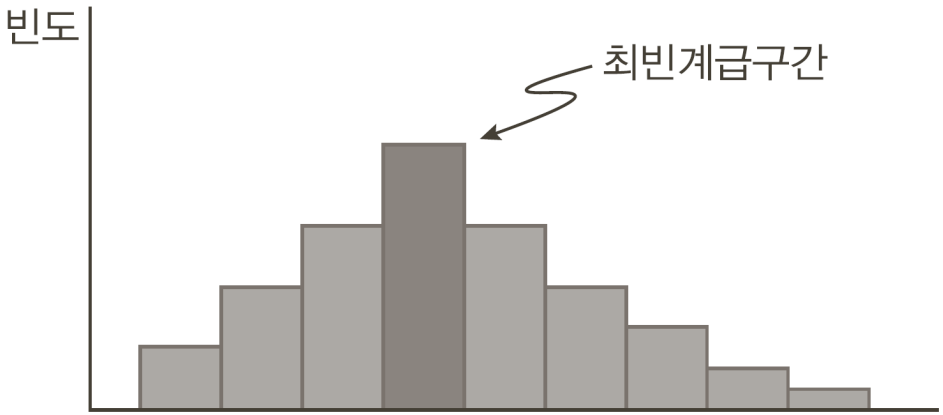

데이터의 요약(I): 중심경향

예제 1. 다음과 같은 자료가 주어졌을 때 평균, 중앙값, 최빈값을 각각 구하시오.

ID	AGE
1	31
2	12
3	25
4	25
5	20

데이터의 요약(I): 중심경향

- 엑셀에서 함수나 계산은 언제나 =로 시작한다. 함수를 입력할 때는 괄호를 잊지 말 것.
- 평균은 엑셀에서 다음과 같이 입력하여 계산할 수 있다:
  $= (31 + 12 + 25 + 25 + 20)/5$.
- 엑셀 함수로 AVERAGE$(\cdot)$ 를 사용할 수 있다.
- 중앙값을 구하기 위해 자료를 정렬하면 12, 20, 25, 25, 31이다. 여기서 딱 한 가운데 값은 25이고 이것이 중위값이다.
- 엑셀 함수로 MEDIAN$(\cdot)$ 을 사용할 수 있다.
- 12가 한 번, 20이 한 번, 25가 두 번, 31이 한 번 나왔다. 그러므로 최빈값은 25이다.
- 엑셀 함수로 MODE$(\cdot)$ 를 사용할 수 있다.

데이터의 요약(I): 중심경향

예제 2. airpollution.zip 일부인 2021년 3월.xlsx를 다시 여시오. 2021년 3월 11일 14시 충북 청주시의 도시대기를 기준으로 다음의 값들을 모두 구하시오.

(1) 일산화탄소(CO)의 평균
(2) 미세먼지(PM10)의 최빈값(mode)
(3) 이산화질소(NO2)의 중앙값(median)

데이터의 요약(I): 중심경향

평균, 중앙값, 최빈값 가운데 어느 것이 옳은가?

- 세 값들이 모두 같거나 비슷하면 뭘 써도 상관없다.
- 일단 평균의 장단점은 비교적 잘 알려져 있다.
- 장점은 평균이 수학적으로 우아하다(elegant)는 사실이다. 다른 요약통계량과는 달리 평균은 간단한 공식을 통해 의미있는 값을 도출해 보인다.
- 단점은 극단값(outliers; extremes)에 쉽게 왜곡(bias)된다는 사실이다.
- 예컨대 자료가 {1, 1, 2, 2, 3, 3, 4, 4, 9999} 와 같이 주어졌다면 평균은 얼마인가? 만일 극단치를 제거하면 평균은 얼마인가? 그 전후 차이는 얼마인가?

데이터의 요약(I): 중심경향

평균이 극단값에 의해 쉽게 왜곡된다는 사실은 반드시 기억해야 한다!

- 1985년 UNC-Chapel Hill에서 지리학 학부 전공 초봉 평균은 무려 약 $100,000 였다.
- Michael Jordan이 그 학교 졸업생이였다. 나머지는 걍 지리학과 나와서 흙파먹고 살았다.

통계를 왜곡하는 중인 Michael Jordan

데이터의 요약(I): 중심경향

- 2015년 3월에는 우리나라 국회의원이 평균재산이 28억 5천만 원으로 나타나 2012년에 비해 일인당 평균 약 67억원이 줄어들었던 것으로 보도되었다. 갑자기 국회의원들이 청빈을 실천하게 된 것일까?
- 재산이 2조 200억원을 상회하는 정몽준 의원이 2014년 국회의원직을 사임했다.

2조 200억을 흐뭇하게 바라보는 정몽준

데이터의 요약(I): 중심경향

중앙값과 최빈값도 완전한 것은 아니다.

- 무엇보다 중앙값과 최빈값은 수학적으로 우아하지 않다.
- 중앙값은 자료의 크기가 조금만 커져도 수계산이 사실상 불가능할 정도로 어렵다.
- 최빈값은 아예 값이 없거나 두 개 이상의 값이 나올 수 있다(Why?). 히스토그램을 그린 뒤, 가장 오똑하게 솟아오른 구간이 바로 최빈값인데 그 봉우리가 1개이면 단봉형(unimodal), 봉우리가 2개이면 쌍봉형(bimodal)이라고 부른다.

데이터의 요약(I): 중심경향

예제 3. coke.csv를 엑셀에 불러오시오. 이 데이터는 10명을 조사하여 이번 한 달동안 얼마나 많은 콜라를 섭취했는가를 파악한 것이다. 평균, 중앙값, 최빈값을 각각 구하시오. 만일 여러분의 보스가 두 개 이상의 숫자는 싫어한다면, 이 많은 요약통계량 중 어떤 숫자를 택할 것인지 그리고 그 이유를 설명하시오.

데이터의 요약(I): 중심경향

평균은 대중적인만큼 조심히 사용해야 하고 비판적으로 접근해야 한다.

- 만약 우리나라 대졸 초봉이 3,391만원이라고 요약한다면 이 통계량은 왜 문제가 되는가?

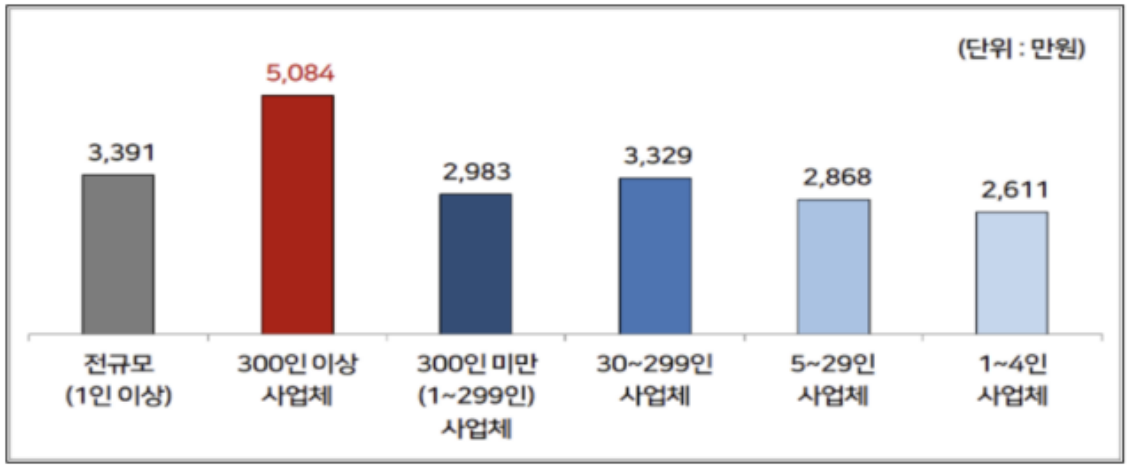

사업체 규모별 정규직 대졸초임(초과급여 포함 임금총액) 평균(2020) ⓒ고용노동부, 경총

- 왜 이 표에서는 기업규모 별로 나누어 보고하고 있을까?

데이터의 요약(I): 중심경향

- 우리는 일상에서 너무나 쉽게 "평균소득"이라는 표현을 사용하지만, 평균소득이라는 개념은 현실을 잘 전달하지 못한다. 평균소득이 make sense 하려면 (1) 중위소득 (median income)과 비교하는 맥락에서 쓰이거나, (2) 조직/직무 따위가 동질적이라는 맥락이 먼저 보장되어야 한다.
- 그렇기 때문에 제대로 된 통계는 중위소득을 보고하기 마련이다(나중에 "중위소득"을 검색해 보자).
- 늘 요약통계량을 "종합적으로" 살펴야 하고, 평균값이 중위값이나 최빈치로부터 크게 이탈해 있다면 즉각 통계적 왜곡을 경계해야 한다.

데이터의 요약(I): 중심경향

오직 제한된 조건 아래에서만 세 요약통계량이 같다.
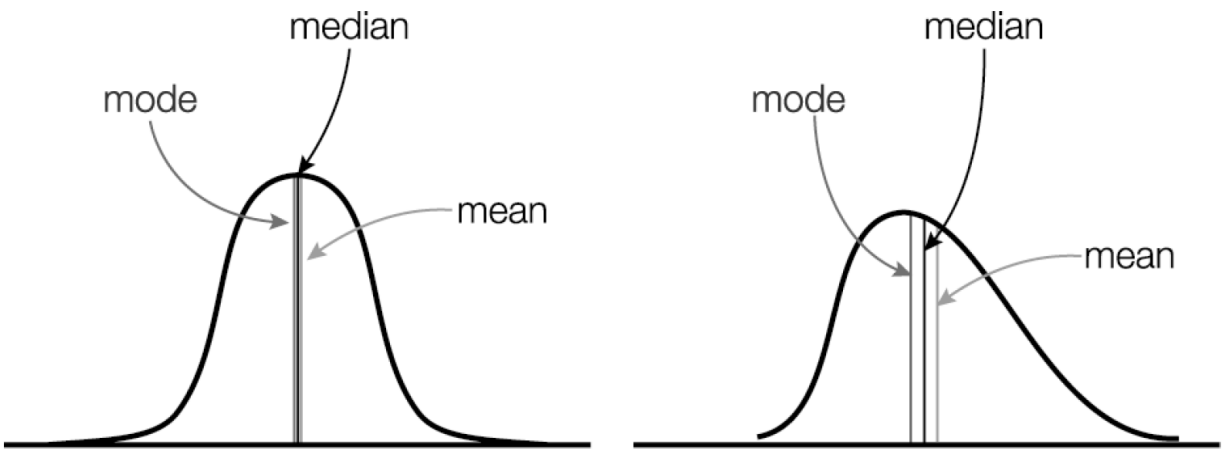
- 정규분포(normal distribution)일 때 세 중심경향 요약통계량은 모두 일치한다.
- 정규분포가 흐트러져 오른쪽으로 꼬리가 긴 양(+)의 왜도를 가지면 평균(mean)이 우측으로 이동하고 중앙값(median)도 살짝 따라온다(Why?)