사회통계

산포경향 측도

김현우, PhD[1]

[1] 충북대학교 사회학과 조교수

March 11, 2022

진행 순서

1. 데이터의 요약(II): 산포경향
2. 데이터의 요약(III): 그 밖의 경향

데이터의 요약(II): 산포경향

데이터의 요약(II): 산포경향

과연 중심경향으로만 충분히 자료를 잘 요약할 수 있을까?

- 두 예제를 통해 중심경향의 근본적인 한계를 살펴보자.
- 다음의 데이터가 주어졌다: $\{-10, 0, 10\}$
- 평균(mean), 중앙값(median), 최빈값(mode)는 각각 얼마인가?
- 다음의 데이터가 주어졌다: $\{-100, 0, 100\}$
- 평균(mean), 중앙값(median), 최빈값(mode)는 각각 얼마인가?
- 두 데이터는 어떻게 다른가?
- 중심경향에 근거하여 두 데이터가 잘 요약되었나?

데이터의 요약(II): 산포경향

그러므로 관측치들이 자료 안에서 얼마나 흩어져 있는가(산포; dispersion)를 측정하는 통계량이 필요하다.

- 가장 간단한 산포경향(dispersion tendency)의 통계는 범위(range)다.

$$\text{범위} = \text{최대값(maximum)} - \text{최소값(minimum)}$$

- e.g., 주가의 일일등락폭, 하루 온도의 일교차
- 다음의 자료로부터 범위를 구해보자: $\{-10, 0, 10\}$.
- 그러나 간단한 만큼 범위는 몇 가지 치명적인 결함을 갖고 있다.
- 다음의 자료로부터 범위를 구해보자: $\{0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 100\}$.
- 평균보다 더 극단치에 민감하다.

데이터의 요약(II): 산포경향

이 문제에 대한 임시대응책은 이른바 사분위수간 범위를 사용하는 것이다.

- 이에 앞서 분위수(quantile)라는 용어에 친숙해져야 한다.
- 분위수(quantile)와 사분위수(quartile)의 영어 단어는 살짝 다르다.
- p번째 백분위수(pth percentile): "이 값보다 작은 값들이 관측치들의 p%이고, 이 값보다 큰 값들이 $(100-p)$%인 값."
- e.g., "지윤의 점수는 80 퍼센타일이야" 라고 말할 때, 그의 점수보다 낮은 점수들이 80%이고 높은 점수들이 20% 라는 의미(즉 80 퍼센타일은 상위 20%)임에 주의!
- 당연히 백분위수의 범위는 0~100% 사이에 놓인다.

데이터의 요약(II): 산포경향

- 사분위수는 다음 4개의 분위수를 지칭한다.

  (1) 첫번째 사분위수(Q1; 25번째 백분위수)
  (2) 두번째 사분위수(Q2; 50번째 백분위수; median)
  (3) 세번째 사분위수(Q3; 75번째 백분위수)
  (4) 네번째 사분위수(Q4; 100번째 백분위수)

- (다시 돌아와서) 사분위수간 범위(interquartile range; IQR)는 세번째 사분위수(Q3)와 첫번째 사분위수(Q1) 간의 차이를 의미한다.

$$\mathrm{IQR} = \mathrm{Q3} - \mathrm{Q1}$$

- 따라서 관측치들의 중간 50%가 흩어져 있는 정도만 측정한다!
- IQR이 큰 값을 가진다는 것은 첫번째 사분위수(Q1)와 세번째 사분위수(Q3)가 멀리 떨어져 있어 자료의 변동성(variation)이 크다는 것을 의미한다.

데이터의 요약(II): 산포경향

예제 4. airpollution.zip의 2021년 3월.xlsx를 다시 엑셀에 불러오시오. [데이터]-[필터]를 사용해 다음의 조건을 특정하시오: 〈지역〉은 충북 청주시, 〈망〉은 도시대기, 측정일시는 〈2021031114〉. 초미세먼지 (PM2.5)의 사분위수를 구하시오.

데이터의 요약(II): 산포경향

- 필터링된 자료를 복사하여 다른 새 탭에 붙여넣고 작업하자.
- PM2.5의 범위와 사분위간 범위를 구하기 위해 다음의 세 가지 함수를 사용한다: MAX(·), MIN(·), QUARTILE(·).
- 범위는 정의상 =MAX(·)-MIN(·) 로 계산한다.
- 사분위간 범위(IQR)는 정의상 =QUARTILE(·, 3)-QUARTILE(·, 1) 로 계산한다.

데이터의 요약(II): 산포경향

IQR은 "첫번째 사분위수와 네번째 사분위수에 극단치가 있을 수 있다"라는 전제에 입각해 있다.

- 이런 방식으로도 여전히 범위가 가진 근본적인 결함은 해소되지 않는다.
- 문제의 본질에는 범위나 IQR 모두 정보의 손실(loss of information)이 심하다는 사실이 있다.
- 다시 말해, 크고 작은 두 값(최대/최소 또는 Q3/Q1)만 사용하고 나머지는 모두 버리기 때문이다.
- 말하자면 통계적으로 비효율적(inefficient)이다.

데이터의 요약(II): 산포경향

- 그러다보니 범위나 IQR로는 “범위는 같으나 분포(distribution)가 다른 경우”를 제대로 요약하지 못한다.

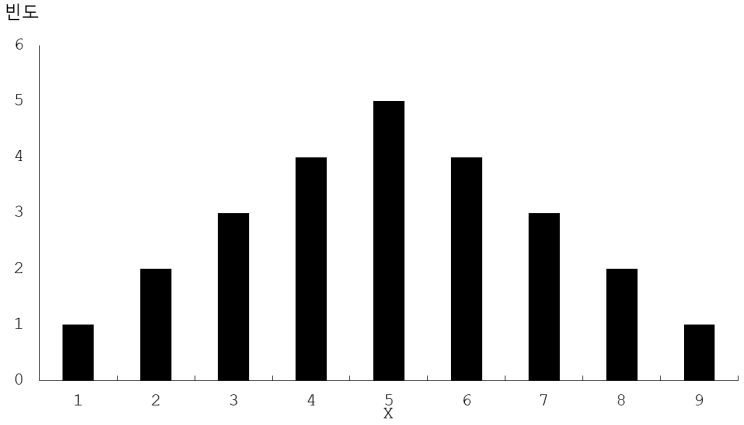

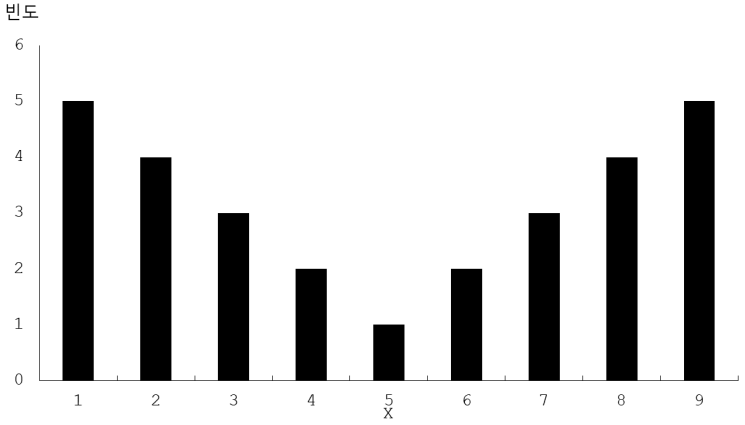

데이터의 요약(II): 산포경향

분산은 범위나 IQR보다 훨씬 "정보를 효율적으로" 활용한다.

- 분산(variance)을 계산하기 위해 모든 관측치에 대해 편차(deviation)를 먼저 계산한다.

$$(x_i - \mu)$$

- 편차가 크다면 평균에서 개별값들이 많이 이탈해 있다는 의미이므로 변동성이 높다고 할 수 있다!
- (IQR과는 달리) 분산은 "모든 관측치를 하나도 버리지 않고" 활용하면서 산포경향을 측정하므로, 모든 측정치들에 대해 편차를 전부 구한다.
- 그렇다고 모든 관측치에 대해 구해진 이 편차들을 그냥 더하면 곤란하다(Why?) "이 문제"를 피하기 위해 편차들을 제곱해서 더한다.

$$\sum_{i=1}^{n}(x_i - \mu)^2$$

데이터의 요약(II): 산포경향

- 편차의 제곱합을 모집단의 크기(N)로 나누어 모분산(population variance)을 구할 수 있다.

$$Var(X) \equiv \sigma^2 = \frac{(x_1-\mu)^2 + (x_2-\mu)^2 + \cdots + (x_N-\mu)^2}{N}$$
$$= \frac{1}{N}\sum_{i=1}^{N}(x_i-\mu)^2$$

- 표본에 대해서도 똑같은 발상을 적용하여 표본분산(sample variance)을 계산할 수 있다.

$$S^2 = \frac{1}{n-1}\sum_{i=1}^{n}(x_i-\bar{x})^2$$

데이터의 요약(II): 산포경향

- 분산의 단점 하나는 편차의 제곱합을 하는 과정에서 그 값이 과장스럽게 커진다는 점이다.
- 수학에서 제곱(square)의 반대는 제곱근(square root)이다. 예컨대, $\sqrt{7^2} = 7$ 이다.
- 그러므로 구해진 분산에 대해서도 제곱근을 취하면 아까 커진 부분이 도로 작아지게 된다. 다시 말해, "분산의 제곱근"을 일컫어 표준편차(standard deviation)라고 부른다.
- (분산과 마찬가지로) 모표준편차(population standard deviation)와 표본표준편차(sample standard deviation)을 구분할 수 있다.

$$\sigma = \sqrt{\sigma^2} = \sqrt{Var(X)}$$
$$S = \sqrt{S^2}$$

데이터의 요약(II): 산포경향

예제 5. 약수터수질현황.csv를 엑셀에 불러오시오. 이것은 물박사인 채민이 우리나라 몇몇 약수터의 수질검사 결과지를 가져온 것이다. 질산성질소의 모분산, 모표준편차, 표본분산, 표본표준편차를 각각 구하시오.

데이터의 요약(II): 산포경향

- 먼저 질산성질소의 평균을 구하자. 평균을 구하는 함수는 AVERAGE(·)이다.
- 마우스로 드래그할 때, $을 활용하면 편리하게 셀 참조(cell reference)를 고정시킬 수 있다.
- 개별 질산성질소의 관측치에서 평균을 빼고 그것들의 제곱을 구한다(괄호에 주의!)
- 편차의 제곱들을 모두 합한 뒤, 표본 크기(N)로 나누어준다. 이것이 모분산이다.
- 모분산에 제곱근하여 모표준편차를 구하자. 제곱근의 함수는 SQRT(·)이다.
- 엑셀 함수로 모분산과 모표준편차를 구하기 위해 각각 VAR.P(·)과 STDEV.P(·)를 사용할 수 있다. 답이 일치하는지 확인해보자.
- 표본분산과 표본표준편차는 각각 VAR.S(·)과 STDEV.S(·)로 구할 수 있다.

데이터의 요약(II): 산포경향

조금 다른 이야기지만, 불확실한 수익이라는 측면에서 보면 평균은 크고 분산은 작은 것이 좋다.

- 그러나 현실에서는 대체로 평균이 크면 분산도 크고(high risk, high return), 평균이 작으면 분산도 작다(low risk, low return).
- 노벨상 수상자 William Sharpe는 변동성 대비 보상을 측정하는 샤프 지수(Sharpe Ratio)를 개발하기도 했다. 어떤 투자의 샤프지수가 높을수록 투자자는 위험에 대해 더 잘 보상받는다.

데이터의 요약(II): 산포경향

- 애초에 표본편차조차도 해석상 모호함이 여전히 남아있다. 표준편차가 10이라면 변동성이 크다고 할 수 있을까? 평균(μ)이 10일 때 표준편차(σ^2) 10이라면 상당히 큰 것 같다. 하지만 평균이 500이라면 그 정도 표준편차가 나오더라도 별로 변동성이 큰 것 같지는 않다.
- 변동계수(coefficient of variation)는 표준편차를 평균으로 나누어 구한다. 이 값은 산포경향을 상대적(또는 비례적)으로 보여준다.

$$\text{Population CV} = \frac{\sigma}{\mu}$$

$$\text{Sample CV} = \frac{S}{\bar{x}}$$

데이터 요약 연습

예제 6. queue.csv를 엑셀에 불러오시오. 상화는 정환과 승원이 운영하는 두 패스트푸드 가게를 컨설팅하기 위해 이 자료를 수집하였다. WAITTIME 변수는 고객 주문 후 음식 수령까지 대기시간을 기록한 표본이다. 이 자료의 관찰단위는 개별 주문(order)이다. 대기시간 외에 모든 요소가 같다는 전제 아래 정환이 운영하는 1번 레스토랑과 승원이 운영하는 2번 레스토랑의 장단점에 대해 변동지수를 토대로 논평하시오.

데이터의 요약(II): 산포경향

자료가 정규분포한다면 아래의 세 가지 경험법칙이 성립한다.

- 모든 관측치의 약 68%는 평균으로부터 1 표준편차 안에 속한다(왼쪽).
- 모든 관측치의 약 95%는 평균으로부터 2 표준편차 이내에 속한다(중앙).
- 모든 관측치의 약 99.7%는 평균으로부터 3 표준편차 이내에 속한다(오른쪽).

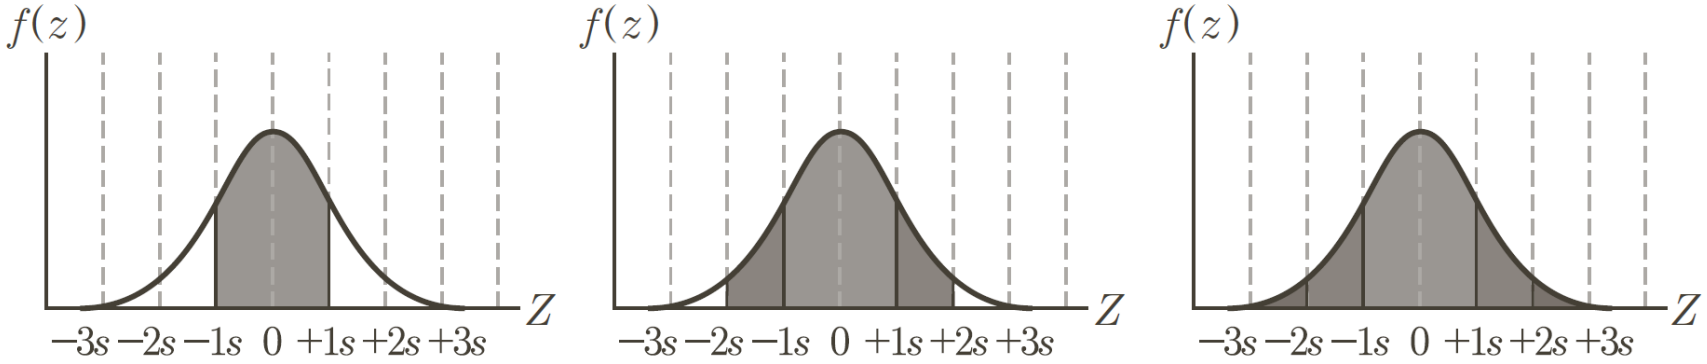

±1 SD (68%) ±2 SD (95%) ±3 SD (99.7%)

데이터의 요약(II): 산포경향

- 자료가 정규분포하지 않으면 경험법칙(the Empirical Rule)이 성립하지 않을 수도 있다.
- 자료가 정규분포하지 않더라도 체비셰프 부등식(Chebyshev' s inequality)은 성립한다(교과서 63페이지).
- 경험법칙이나 체비셰프의 부등식이 시사하는 바는 명확하다: 표준편차 값을 알면 자료의 분포를 대충 짐작할 수 있다는 것이다.

데이터의 요약(III): 그 밖의 경향

데이터의 요약(III): 그 밖의 경향

왜도와 첨도 역시 자료의 분포를 요약하기 위해 종종 사용된다.

- 왜도(skewness)는 분포가 정규분포보다 삐뚤어진(왜곡) 정도를 의미한다.
- "꼬리의 방향에 따라" 양(+)의 왜도(positive skewness 또는 right-skewed)와 음(-)의 왜도(negative skewness 또는 left-skewed)로 나뉜다.

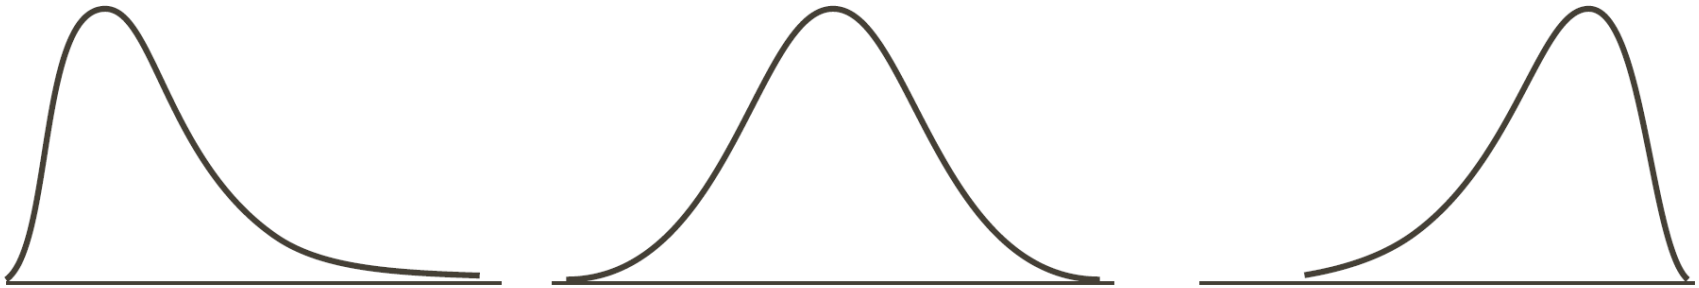

양(+)의 왜도 정규분포 음(−)의 왜도

데이터의 요약(III): 그 밖의 경향

- 첨도(kurtosis)는 분포가 정규분포보다 뾰족한(첨단) 정도를 의미한다.
- "꼬리의 두께에 따라' 두꺼운 꼬리(heavy-tailed)와 얇은 꼬리(light-tailed)로 나뉜다.

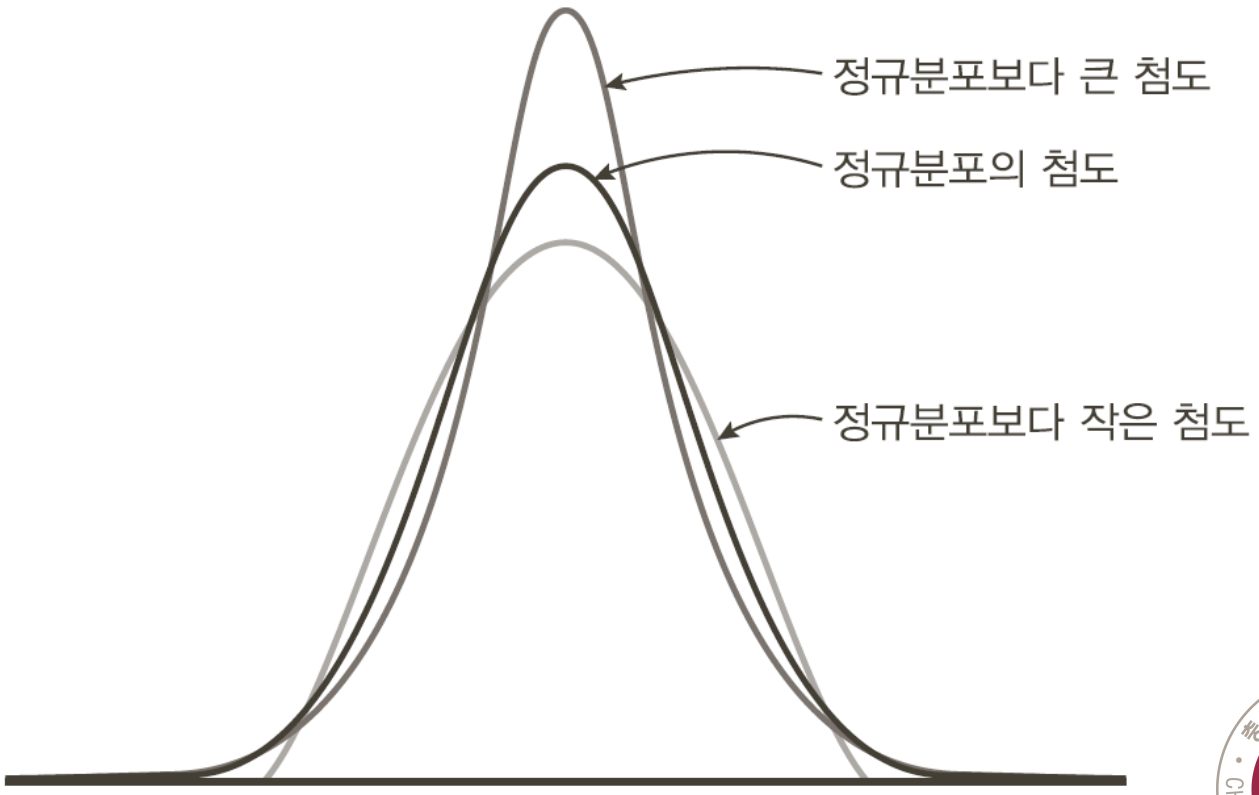

데이터의 요약(III): 그 밖의 경향

- 수학적으로 왜도와 첨도는 분산과 굉장히 밀접한 관계를 갖고 있다.

$$\text{분산} = \frac{1}{N}\sum_{i=1}^{N}(x_i - \mu)^2$$

$$\text{왜도} = \frac{1}{\sigma^3 N}\sum_{i=1}^{N}(x_i - \mu)^3$$

$$\text{첨도} = \frac{1}{\sigma^4 N}\sum_{i=1}^{N}(x_i - \mu)^4$$

끝!

와~ 또 숙제다~