사회통계

두 양적 변수 사이의 관계

김현우, PhD[1]

[1] 충북대학교 사회학과 조교수

March 18, 2022

진행 순서

1. 지난 주 리뷰
2. 과학적 이론과 변수 사이의 관계
3. 두 양적 변수 사이의 연관성

지난 주 리뷰

지난 주 리뷰

1. 충북 청주시와 대전 유성구의 PM10 평균값을 각각 구하고 (문장들을 제대로 갖추어) 미세먼지 수준을 비교하시오(25점).

- 충북 청주의 PM10 평균은 약 37.92이고 대전 유성의 PM10 평균은 약 31.10이므로 충북 청주의 미세먼지 수준이 더 높다고 결론 내릴 수 있다.

2. 충북 청주시와 대전 유성구의 PM2.5 중앙값(medians)을 각각 구하고 (문장들을 제대로 갖추어) 초미세먼지 수준을 비교하시오(25점).

- 충북 청주의 PM2.5 중앙값은 약 18이고 대전 유성의 PM2.5 중앙값은 약 10이므로 충북 청주의 초미세먼지 수준이 더 높다고 결론 내릴 수 있다.

지난 주 리뷰

3. 충북 청주시와 대전 유성구의 PM10에 대한 사분위수간 범위(IQR)를 각각 구하고 (문장들을 제대로 갖추어) 미세먼지 수준을 비교하시오(25점).

- 충북 청주의 PM10 사분위수간 범위는 14이고 대전 유성의 PM10 사분위수간 범위는 12이므로 충북 청주의 미세먼지 수준의 산포경향이 더 높다고 결론 내릴 수 있다.

4. 충북 청주시와 대전 유성구의 PM2.5에 대한 표준편차(standard deviations)을 각각 구하고 (문장들을 제대로 갖추어) 초미세먼지 수준을 비교하시오(25점).

- 충북 청주의 PM2.5 표본표준편차는 약 6.00이고 대전 유성의 PM2.5 표본표준편차는 약 4.45이므로 충북 청주의 미세먼지 수준의 산포경향이 더 높다고 결론 내릴 수 있다.

지난 주 리뷰

퀴즈 코멘트

- 중심경향(mean, mode, median)을 통해 높고 낮음을 비교할 수 있고, 산포성향(range, IQR, SD)을 통해 변동성을 비교할 수 있다. 변동성을 물어보는데 중심성향 이야기를 하면 틀린다. 혼동하지 말 것!
- 소숫점은 대체로 2-3 자리 정도면 충분하다.
- 위 문제에서 "문장들을 제대로 갖추어" 라고 쓴 이유는 그냥 요약통계량만 툭 던지면 안되고 쉬운 말로 그 의미를 풀어 제시해야 하기 때문이다.
- 가령, "A지역은 평균은 6이고, B지역의 평균의 3이다" 혹은 "A지역은 표준편차는 10이고, B지역의 표준편차는 5이다" 로 끝내서는 안된다! 반드시 "A지역에서 미세먼지는 B지역보다 평균적으로 농도가 짙지만 변동성은 낮다" 하는 식의 평범한 우리말 표현이 뒤따라야 한다.
- 사람들이 표준편차 같은 통계학 용어를 당연히 알아들을 거라고 전제하고 글을 써서는 안된다.

과학적 이론과 변수 사이의 관계

과학적 이론과 변수 사이의 관계

곰곰히 생각해보면 지난 주에는 단지 "하나의 변수"를 요약하였을 뿐이었다.

- 저번 주에는 요약통계량과 관련하여 중심경향과 산포경향을 공부했다.
- 변수 하나에 대해 각각의 요약통계량을 하나씩 제시하는 방식으로 공부했을 뿐이고, 설령 두 개의 변수(e.g., PM10과 PM2.5)가 주어질 때도 각각 따로 보았다.
- 다시 말해, 우리는 변수가 두 개 주어졌을 때 그 사이의 연관성(association) 혹은 관계(relationship)에 대해서 살펴보지 않았다.
- 그래서 이번 주에는 둘 이상의 변수 사이의 연관성 또는 관계를 살펴보기로 한다.

과학적 이론과 변수 사이의 관계

이론의 정의와 역할에 대해 잠깐 생각해보자.

- 경험과학(empirical science)에서 이론(theory)이란 경험적으로 검증가능한, 상호연관된 일련의 명제들(propositions)이다.
- 명제란 둘 이상의 개념들(concepts) 사이의 관계에 대한 진술이다(e.g., "X가 증가하면 Y는 감소한다").
- 수학의 언어로 표현한다면 명제는 함수(function)의 꼴로 표현될 수 있다

$$Y = f(X)$$

- 명제는 수행하는 역할에 따라 공리(axiom), 정리(theorem), 가설(hypothesis), 발견(finding) 등 다양한 형태를 가질 수 있다.

과학적 이론과 변수 사이의 관계

경험과학에서 개념이란 무엇인가?

- 개념(concept)이란 세상에 관한 체계적으로 가다듬어진 정신적 표상(mental representation)이다.
- 개념은 특히 여러 관념들(notions)로부터 일반적인 요소를 추출하고 종합하여 얻는다.
- 사태와 현상을 어느 정도 경계지어 개념의 외연과 내포를 설정해야 한다.
- 개념은 경험과학적 연구를 위해 조작적 정의(operational definition)를 통해 변수로 측정(measure)되어야 한다.

과학적 이론과 변수 사이의 관계

경험과학에서 가설과 발견이란 무엇인가?

- 가설(hypothesis)이란 (연구를 수행하기에 앞서 제시된) 둘 이상의 개념들 사이의 관계에 대한 "잠정적인(tentative)" 진술이다.
- 발견(finding)이란 (연구를 통해 어느 정도 입증된) 둘 이상의 개념들 사이의 관계에 대한 진술(=명제)이다.
- 흥미롭게도 경험과학에서는 법칙(law)이나 사실(fact)과 같은 표현이 거의 나오지 않는다. 오히려 그런 말은 저널리즘에서 폭넓게 쓰인다.

과학적 이론과 변수 사이의 관계

경험과학에서 이론이란 근본적으로 둘 이상의 변수 사이에 어떤 관계가 있는지를 다루는 것이다!

- 하나의 변수를 요약하는 통계로는 이론을 세우거나 테스트할 수 없다.
- 적어도 이론이라고 불리려면 두 개 이상의 변수의 관계를 분석해야만 한다.

과학적 이론과 변수 사이의 관계

종속변수와 독립변수의 역할을 명확하게 인식해야 한다.

- 종속변수(dependent variable)란 다른 무언가에 종속되어 설명되어지는 변수이고, 독립변수(independent variable)란 다른 무언가로부터 독립되어 설명하는 변수다.
- 관행상 종속변수는 Y, 독립변수는 X로 표기된다.

$$Y = f(X)$$

$$\boxed{X} \longrightarrow \boxed{Y}$$

과학적 이론과 변수 사이의 관계

독립변수는 하나 이상 있을수도 있다.

- 여러 독립변수들을 관심변수(variable of interest)와 통제변수(control variable) 그룹으로 나누어 접근할 수 있다. 다시 말해, 통제변수의 동시적 영향력을 배제한 상태에서(controlled out), 관심변수와 종속변수의 관계를 좀 더 집중해서 살펴볼 수 있다.
- 하지만 근본적으로 무엇이 관심변수이고 통제변수인가는 하는 것은 연구자의 주관에 달렸다.

$$Y = f(X_1, X_2)$$

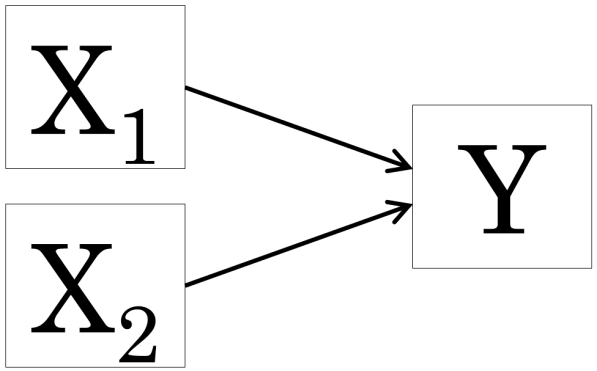

과학적 이론과 변수 사이의 관계

독립변수와 종속변수의 사이에 좀 더 복잡한 관계가 있을 수도 있다.

- 매개변수(mediating variables)라는 형태도 있다. 아래 식에서 M_e는 X와 Y 사이에서 매개변수 역할을 수행한다.

$$Y = f_2(M_e) = f_2(f_1(X))$$

$$\boxed{X} \rightarrow \boxed{M_e} \rightarrow \boxed{Y}$$

과학적 이론과 변수 사이의 관계

- 조절변수(moderating variables)라는 형태도 있다. 아래 식에서 M_o는 X와 Y 사이에서 조절변수의 역할을 수행한다.

$$Y = f(X, M_o, X \cdot M_o)$$

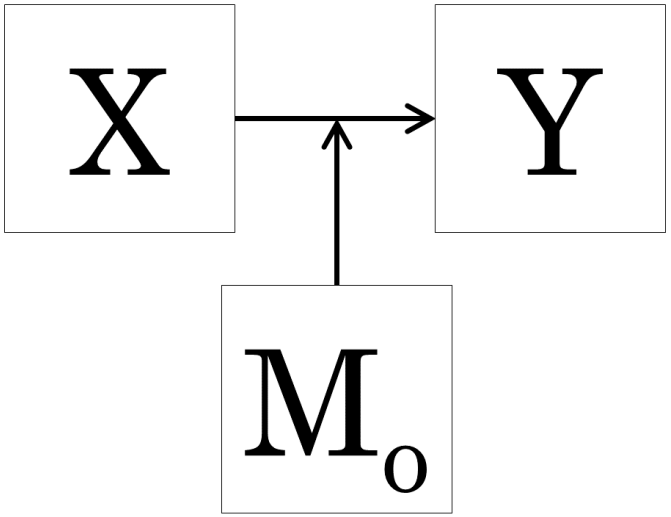

과학적 이론과 변수 사이의 관계

둘 이상의 변수 사이의 관계를 살펴볼 때도 자료유형에 주의를 기울여야 한다.

- 변수의 척도(scale)에 따라 조금씩 다른 방법을 필요로 한다.
- 두 변수 모두 등간형(interval), 비율형(ratio)인 경우(=양적변수)에는 상관계수(correlation coefficient)를 자주 사용한다.
- 두 변수 모두 명목형(nominal), 서열형(ordinal)인 경우(=질적변수)에는 교차표(cross-tabulation)를 자주 사용한다.
- 해석 방법과 주의사항을 혼동하지 않도록 주의해야 한다. 결국 많은 연습이 답이다.

두 양적 변수 사이의 연관성

두 양적 변수 사이의 연관성

둘 이상의 양적 변수 사이의 관계를 볼 때는 일차적으로 상관계수를 살펴본다.

- 상관계수(correlation coefficient)는 두 양적 변수 사이 선형관계(linear relationship)의 방향(direction)과 강도(strength)를 나타낸다.
- 상관계수가 양(+)인 경우 두 변수는 같은 방향으로 변화한다(X가 증가하면 Y도 증가한다).
- 상관계수가 음(-)인 경우 두 변수는 다른 방향으로 변화한다(X가 증가하면 Y는 감소한다).
- 상관계수가 큰 값이면 두 변수는 좀 더 밀접하게 함께 움직인다(X가 변화하면 Y도 민감하게 변화한다).
- 상관계수가 작은 값이면 두 변수는 훨씬 느슨한 관계를 갖는다(X가 변화해도 Y는 둔감하게 변화할 뿐이다).
- 상관계수를 계산하려면 먼저 공분산(covariance)에 대해 이해할 필요가 있

두 양적 변수 사이의 연관성

- 다시 한 번 X의 분산(variance) 공식을 돌이켜보자.

$$Var(X) = \sigma_X^2 = \frac{1}{N}\sum_{i=1}^{N}(X_i - \mu)^2$$
$$= \frac{1}{N}\sum_{i=1}^{N}(X_i - \mu)(X_i - \mu)$$

- 변수가 하나(X_i) 주어져 있을 때 편차(deviation)를 구해 제곱했는데 이걸 이렇게 바꾸면 어떨까?

$$Cov(X, Y) = \sigma_{XY} = \frac{1}{N}\sum_{i=1}^{N}(X_i - \mu_X)(Y_i - \mu_Y)$$

두 양적 변수 사이의 연관성

- 공분산과 분산의 아이디어는 거의 똑같다!
- 다만 X_i의 편차를 제곱하는 대신, X_i와 Y_i의 편차를 서로 곱했을 뿐이다.
- 그렇게 두 변수의 편차끼리 곱한다면 어떤 값이 나올지 상상해보자.
- 모두 양수(+)이거나 음수(-)이면 공분산은 양수(+)가 되고,
- 한쪽이 양수(+)이고 다른 쪽이 음수(-)이면 공분산은 음수(-)가 된다.

두 양적 변수 사이의 연관성

예제 1. sociologists.csv를 엑셀로 불러오시오. 이것은 10명의 학생들이 다섯 명의 사회학자에 대한 선호도를 0점과 100점 사이에서 평가한 결과이다. (1) Marx 점수와 Weber 점수, (2) Marx 점수와 Parsons 점수, (3) Marx 점수와 Burawoy 점수 간 공분산을 각각 구하시오. 이 분석에 따를 때 Marx를 선호하는 사람은 누구를 더 선호한다고 말할 수 있는가?

두 양적 변수 사이의 연관성

- Marx 점수와 Weber 점수 사이의 공분산을 다음의 공식에 따라 계산해보자.

$$Cov(X, Y) = \sigma_{XY} = \frac{1}{N}\sum_{i=1}^{N}(x_i - \mu_X)(Y_i - \mu_Y)$$

- 엑셀에서 COVARIANCE.P(·) 함수를 사용해서 검산해보자.
- Marx 점수와 Parsons 점수 사이의 공분산과 Marx 점수와 Burawoy 점수 사이의 공분산도 엑셀 함수로 계산해보자.
- Marx를 선호하는 사람은 둘 중 누구를 더 선호한다고 말할 수 있을까?

두 양적 변수 사이의 연관성

공분산은 흥미로운 아이디어를 제시하고 있지만 명확한 단점이 있다.

- 공분산 $Cov(X, Y)$은 X 내부(within X)의 분산과 Y 내부(within Y)의 분산이 다를 수 있다는 점을 고려하지 않는다.
- 둘을 비교하려면 일단 표준화를 해야 하는데 제대로 표준화가 안되었다는 의미다.
- 표준화가 되지 않은 숫자가 그냥 계산되었기 때문에 공분산값은 직관적으로 그 의미를 파악하기 어렵다.
- "아니, 공분산이 241.12 이라고 나왔는데 대체 이게 뭘 뜻하지?"

두 양적 변수 사이의 연관성

- 무슨 소리인지 잘 이해가 가지 않으니 직접 자료를 통해 살펴보자!
- showmethemoney.csv를 엑셀에 불러와 살펴보자. 이 자료는 8명의 시민들이 설문에 참여하여 월 소득(income), 월급 백만원 단위 카테고리(income_cat), 그리고 거주지 평수(housesize)를 보고한 자료이다.
- income과 housesize의 공분산을 계산해보자. 또 income_cat과 housesize의 공분산도 계산해보자.
- 결과가 같은가? 다른가?
- income과 income_cat은 같은 변수인가? 아니면 다른 변수인가?

두 양적 변수 사이의 연관성

Karl Pearson은 공분산의 한계를 보완하는 천재적인 접근을 제시했다.

- 그는 공분산을 두 변수 X와 Y의 각각의 표준편차로 나누어줌으로서, 공분산을 X 내부의 분산과 Y 내부의 분산에 대해 표준화했다(Why?).
- 뿐만 아니라, 일부러 분산이 아닌 두 개의 표준편차 곱으로 나누어주었기 때문에 표준화된 값은 절묘하게 -1과 1 사이에 놓인다.
- 이것이 이른바 피어슨 적률상관계수(Pearson's product-moment correlation coefficient)이다. 줄여서 상관계수(ρ)라고 한다(ρ는 rho라고 읽는다).

$$\rho = \frac{\sigma_{XY}}{\sigma_X \sigma_Y}$$

두 양적 변수 사이의 연관성

다시 showmethemoney.csv로 돌아가 상관계수를 계산해보자.

- 먼저 income과 housesize의 공분산을 다시 계산해보자. 엑셀 함수는 COVARIANCE.P(·)이다.
- 다음으로 income의 표준편차와 housesize의 표준편차를 각각 계산해보자. 엑셀 함수는 STDEV.P(·)이다.
- 아래 식에 따라 엑셀에서 계산해보자. 괄호에 주의할 것!

$$\rho = \frac{\sigma_{XY}}{\sigma_X \sigma_Y}$$

- 상관계수는 엑셀에서 CORREL(·) 함수로 편리하게 구할 수 있다. 검산을 해보자.

두 양적 변수 사이의 연관성

상관계수의 해석은 익숙해지기 전까지 다소 혼동스러울 수도 있다.

- 상관계수는 반드시 -1과 1사이에 놓인다.
- 상관계수가 0보다 크면 두 변수는 서로 같은 방향으로 움직인다("X가 증가하면 Y도 증가한다"). 상관계수가 0보다 작으면...
- 상관계수는 산점도(scatterplot)를 통해 시각화(visualization)할 수도 있다.

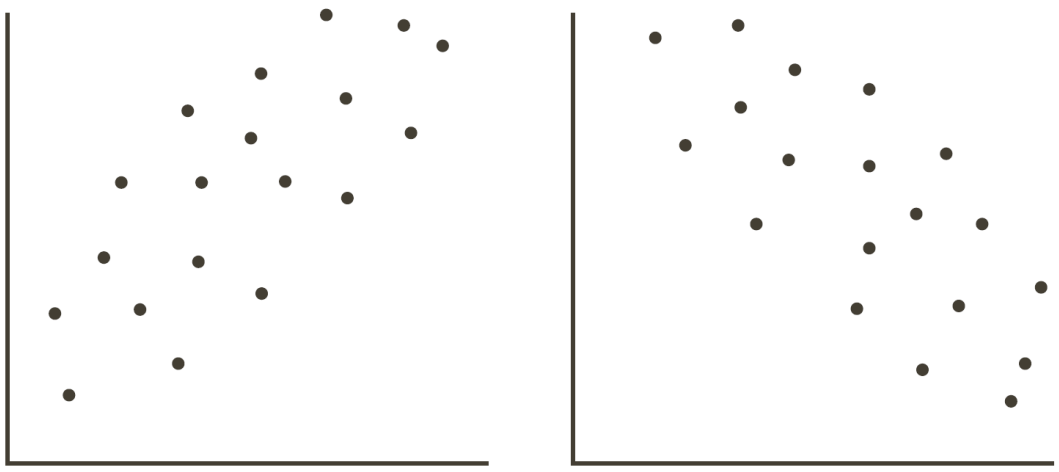

$+0.5$ $\qquad$ -0.5

두 양적 변수 사이의 연관성

- 상관계수가 1에 가까울수록 두 변수 사이 양(+)의 상관성이 높아진다. 상관계수가 -1에 가까울수록...
- 극단적으로 상관계수가 -1 혹은 1 인 경우를 완전상관(perfect correlations), 상관계수가 0인 경우를 무상관(no correlations)이라고 부른다. 그림 4-6
- 기울기는 의외로 상관계수의 본질이 아니다. 관찰값 사이의 흩어짐(산포경향)이 상관계수의 본질이다.

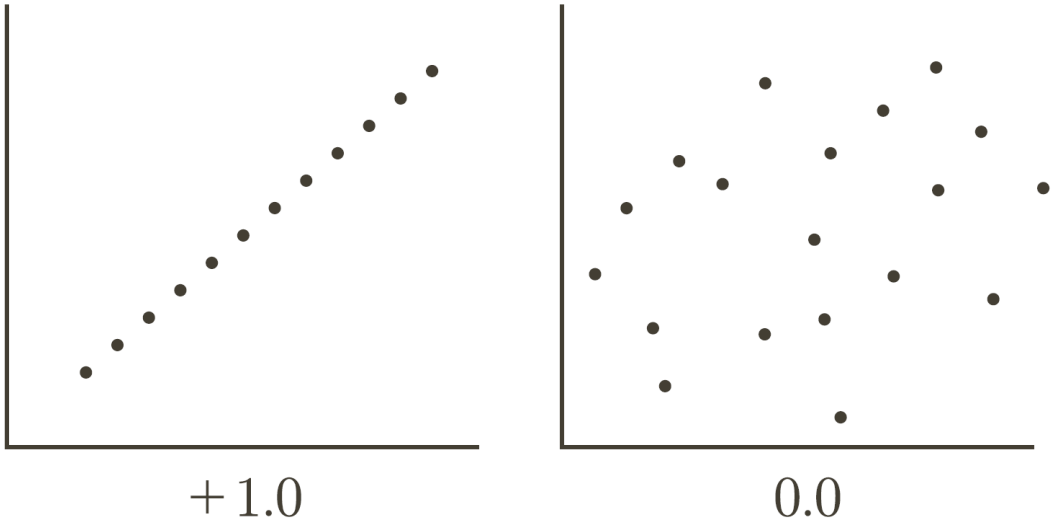

두 양적 변수 사이의 연관성

- 상관계수의 절대값(absolute value)이 보여주는 의미도 해석할 수 있다.
- 몇 가지 기준이 있다(교과서 81페이지를 보라). 또다른 방식은 0과 1 사이를 적당히 사분위수(quartiles)로 나눈 뒤, 각각 리커트 4점 척도(1사분위수=매우 약한 상관성; 2사분위수=다소 약한 상관성; 3사분위수=다소 강한 상관성; 4사분위수=매우 강한 상관성)처럼 해석하는 것이다.

|상관계수|	상관성의 해석
0 ~ 0.25	매우 약한 상관성
0.25 ~ 0.5	다소 약한 상관성
0.5 ~ 0.75	다소 강한 상관성
0.75 ~ 1	매우 강한 상관성

두 양적 변수 사이의 연관성

상관계수는 두 변수 사이의 선형관계를 전제로 한다.

- 그런데 아까 showmethemoney.csv에서 income (또는 income_cat)과 housesize 사이의 관계는 사실 비선형적(non-linear)이다.

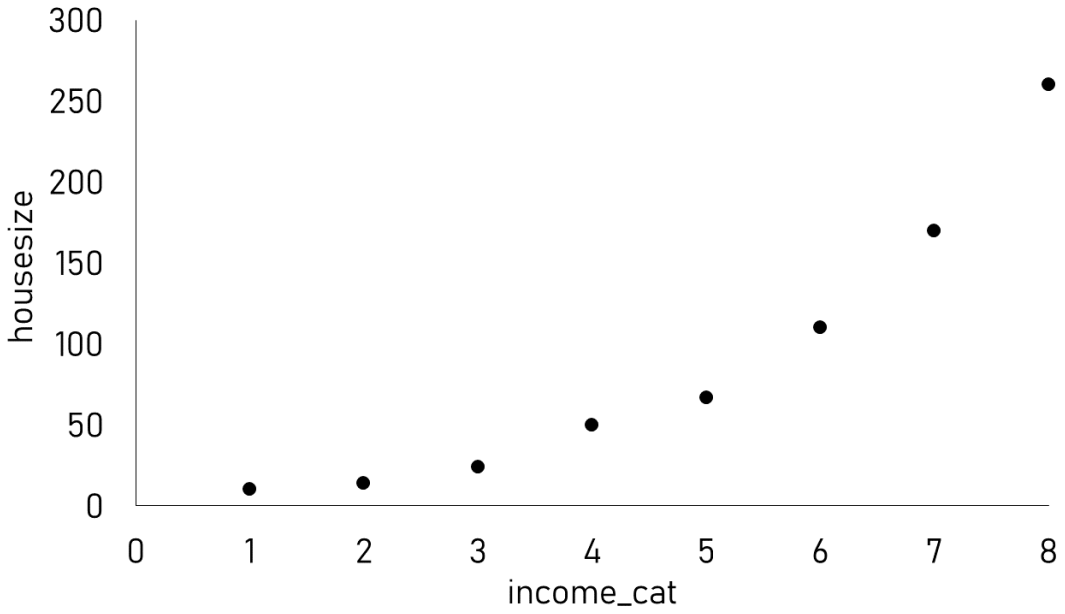

두 양적 변수 사이의 연관성

- X와 Y의 관계는 경우에 따라서 U자형, 역U자형, W자형 등등 다양할 수도 있다.
- 그러면 어떻게 상관계수를 확인하기 전에 두 변수의 관계가 선형적인지 알 수 있나?
- 산점도를 그려보면 알 수 있다. 그러므로 반드시 상관계수를 계산할 때는 산점도를 함께 확인해야 한다.
- 산점도 그리는 법은 다음 주에 배운다.

두 양적 변수 사이의 연관성

예제 2. 유동인구수.xlsx를 엑셀로 불러오자. 유유상종의 원리 (homophily principle)에 따라 거리를 활보할 때 남녀도 같은 또래끼리 함께 다닐 것이라는 가설(hypothesis)을 세웠다. 이 자료에서 주어진 유동인구수 변수는 어떤 척도인지 답하시오. 가설에 따라 연령별 유동인구수 변수의 연관성을 파악하기 위해 어떠한 분석기법이 가장 적절한지 고르고 그 이유를 설명하시오. 해당 분석을 수행하고 결론과 해석을 내리시오.