사회통계

단일 변수의 시각화

김현우, PhD[1]

[1] 충북대학교 사회학과 조교수

March 25, 2022

진행 순서

1. 지난 주 리뷰
2. 데이터 시각화의 시작
3. 단일변수의 시각화

지난 주 리뷰

지난 주 리뷰

1. HAPPINESS와 HEALTH 두 변수의 자료유형을 설명하고 가장 적절한 분석 기법을 고르시오. 이유를 함께 설명하시오(10점).

- 두 변수는 모두 질적 변수이다. 리커트 척도의 꼴을 따르므로 서열 척도인 셈이다. 두 변수가 질적 변수이므로 교차표를 사용하여 분석할 수 있다.

지난 주 리뷰

2. 위에서 선택한 분석을 직접 수행하고 그 결과를 해석과 함께 제시하시오. 해석에 필요하다고 판단되는 모든 절차를 함께 수행하시오(40점).

		Happiness				
		매우 행복	다소 행복	다소 불행	매우 불행	총합계
Health	나쁘다	0	1	2	1	4
	좋지도 나쁘지도 않다	1	3	3	1	8
	좋다	3	2	3	0	8
	총합계	4	6	8	2	20

		Happiness			
		매우 행복	다소 행복	다소 불행	매우 불행
Health	나쁘다	0	0.25	0.5	0.25
	좋지도 나쁘지도 않다	0.125	0.375	0.375	0.125
	좋다	0.375	0.25	0.375	0
	총합계	0.2	0.3	0.4	0.1

- "건강이 나쁘다고 응답한 사람의 25%가 다소 행복하다고 응답하였다."
- "건강이 나쁘다고 응답한 사람의 50%가 다소 불행하다고 응답하였다."
- ...

지난 주 리뷰

3. MATH와 ENGLISH 두 변수의 자료유형을 설명하고 가장 적절한 분석 기법을 고르시오. 이유를 함께 설명하시오(10점).

- 성적을 평가하는 점수는 등간 척도인가, 비율 척도인가 하는 것은 의외로 중요하지 않다. 어찌되었든 두 변수는 양적 변수이므로 상관계수를 통해 두 변수의 관계를 분석할 수 있기 때문이다.

지난 주 리뷰

4. 위에서 선택한 분석을 직접 수행하고 그 결과를 해석과 함께 제시하시오. 해석에 필요하다고 판단되는 모든 절차를 함께 수행하시오(40점).

- 주관적 건강상태와 행복감 사이의 상관계수는 약 0.754이다. 엑셀 함수를 사용하면 금방 계산할 수 있다. 이 값은 양수이므로 양(+)의 상관관계가 있다.
- 교과서 기준에 따르면 강한 양의 상관관계라고 할 수 있다.
- 상관계수의 절대값을 리커트 4점 척도처럼 해석하면 0.75와 1사이에 있으므로 매우 강한 양의 상관관계라고도 할 수 있다.

지난 주 리뷰

퀴즈 코멘트

- 과제는 hxk271@cbnu.ac.kr로 제출할 것. 다른 메일 계정을 사용하지 말 것.
- 파일 제목은 “3주차_2019010017.docx”같은 식으로 통일할 것. 위반시 감점함.

데이터 시각화의 시작

데이터 시각화의 시작

왜 사회학도가 시각화를 배우나?

- 데이터의 경향이나 패턴을 이해하는데 (단순히 숫자를 나열할 때보다) 큰 도움이 된다.
- 변수의 분포(variable distribution)를 보여주어 데이터의 문제를 파악하거나 다음 분석을 계획하는데 용이하다.
- 여러 변수들 사이에 혹시 어떤 관계가 있지 않나 하는 의문을 빠르게 해소하는데 유리하다.

데이터 시각화의 시작

가장 먼저 데이터 시각화는 요약 및 분석 시나리오에 따라 두 종류로 나뉜다.

- 단일변수의 시각화(univariate data visualization). 다시 양적 변수(quantitative variable)를 시각화하는 경우와 질적 변수(quantitative variable)를 시각화하는 경우가 다르다.
- 둘 이상의 변수 사이 관계의 시각화(bivariate/multivariate data visualization). 다시 (1) 양적 변수인 경우, (2) 모두 질적 변수인 경우, (3) 양적 변수와 질적 변수가 뒤섞인 경우가 다르다.

단일변수의 시각화

단일변수의 시각화

자료의 체계적 요약은 빈도분포표를 만드는 것에서 출발한다.

- "질적 변수"가 주어져 있으면 각 범주별로 하나하나 세서(tally) 즉각 빈도분포표 (frequency distribution table) 안에 요약하여 나타낼 수 있다.

ID	female	socialclass	IQ	income
1	1	3	135	250
2	0	2	110	310
3	1	1	128	1500
4	0	2	98	122
5	1	2	106	450
6	0	3	102	190

X	Frequency	Cum. Perc.
0	3	50.00%
1	3	100.00%

단일변수의 시각화

- "양적 변수"가 주어져 있다면 먼저 계급구간(class intervals)에 따라 값을 나누고 빈도분포표로 나타낼 수 있다.

ID	female	socialclass	IQ	income
1	1	3	135	250
2	0	2	110	310
3	1	1	128	1500
4	0	2	98	122
5	1	2	106	450
6	0	3	102	190

X	Frequency	Cum. Perc.
$X \leq 100$	1	33.33%
$100 < X \leq 200$	1	33.33%
$200 < X < 300$	1	50.00%
$300 < X < 400$	1	66.67%
$400 \leq X$	2	100.00%

단일변수의 시각화

- 가장 먼저 계급구간의 수를 결정한다. 너무 적어도 너무 많아도 곤란하다.
- 계급구간의 크기를 결정할 때, 각 계급구간 간에 충분한 의미가 있도록 주의해야 한다. 하나의 구간에 충분한 사례가 들어가도록 설정한다.
- 앞 테이블은 계급구간이 100 단위 씩 나뉘었지만 아래의 식을 사용할 수도 있다. 이것은 어디까지나 참고용이다.

$$\text{구간의 크기} = \frac{(\text{자료의 최대값} - \text{자료의 최소값})}{\text{구간의 수}}$$

단일변수의 시각화

도수분포표를 그림으로 표현하면 히스토그램이 된다.

- 히스토그램(histogram)은 가장 널리 알려진 단일변수의 시각화 기법이다.

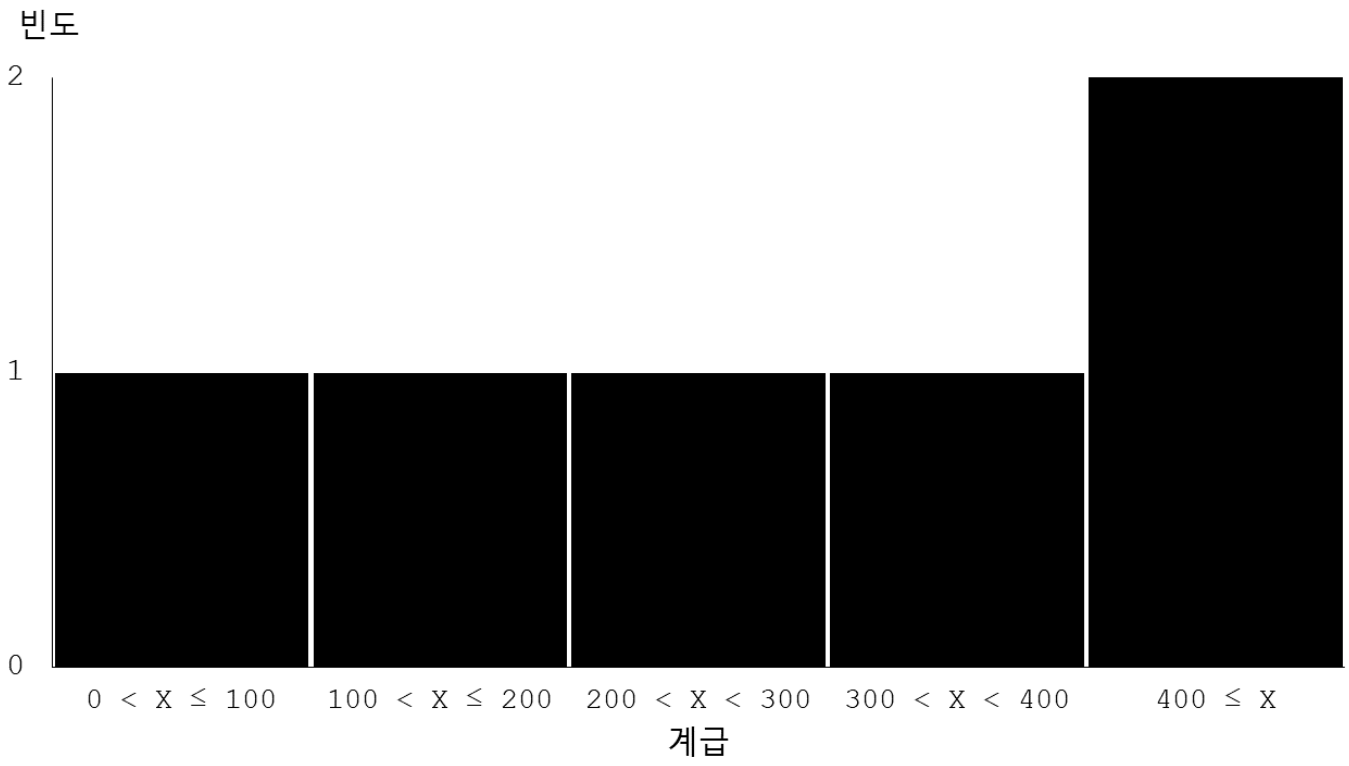

단일변수의 시각화

- 도수분포표와 히스토그램은 나도 거의 매일같이 사용한다. “새로운 데이터의 새로운 변수다” 싶으면 일단 그것의 도수분포표와 히스토그램을 본다.
- 솔직히 말해 두 기법은 워낙 중요하기 때문에 자료유형이고 뭐고 생각하기도 전에 일단 둘 다 보는 것이 좋다.
- 아주 간단한 것들인데 이걸 미처 확인하지 않아서 문제가 되는 경우는 무척 많아도, 확인해서 문제가 된 경우는 들어본 적이 없다.

단일변수의 시각화

원칙적으로 보면 히스토그램은 막대 그래프와는 구별된다.

- 교과서에 따르면 (거의 같은 그림인데) 질적 변수에 대해서는 막대 그래프(bar chart), 양적 변수에 대해서는 히스토그램을 사용해야 한다.
- 나는 그런 구분이 솔직히 우스꽝스럽다고 생각한다. 히스토그램과 막대 그래프의 유일한 차이는 막대(bins)가 서로 붙어있나 붙어있지 않나 정도에 불과하다(심지어 미적인 이유로 인해 히스토그램에서도 막대를 아주 살짝 떼놓기도 한다).
- 히스토그램이 양적 변수에 대응한다는 점도 곰곰히 생각해보면 다소 어색하다. 결국 도수분포표의 계급구간을 나누면서 양적변수를 질적변수로 변환(recoding)하기 때문이다.

단일변수의 시각화

예제 1. midterms.csv를 엑셀에 불러오시오. 이는 통계학을 수강하는 40명 학생의 중간고사 점수 자료이다. 이 자료의 변수 유형은 무엇인가? 이 자료를 10점 단위 구간으로 도수분포표와 히스토그램을 작성하시오.

71	71	73	74	76	77	77	78	79
36	53	57	62	63	65	68	69	69
86	88	88	88	89	90	92	92	93
79	80	80	81	81	91	82	83	83

단일변수의 시각화

- 엑셀에서 데이터분석을 하려면 분석 도구를 설치해야 한다.
- 분석도구(Analysis ToolPak)는 무료인데다 몇 가지 초보적인 데이터 분석에 유용하지만 엑셀을 기동시킬 때마다 느려진다는 흠이 있다.
- 메뉴에서 [파일]-[옵션]-[추가 기능]으로 들어가 메뉴 화면 하단에 "이동(G)"를 고르고 "분석 도구"를 체크하면 된다.
- "분석 도구" 밑에 "해 찾기 추가 기능"은 수리사회학 등 여러 분야에서 최적화 문제 (optimization problems)를 풀 때 제법 쓸모있지만 우리 수업에서는 다루지 않는다.
- "분석 도구"가 제대로 설치되었다면 [데이터] 메뉴를 선택했을 때 우측 끄트머리에 [데이터 분석]이 새로 생겨난다.
- 안 생겨났으면 엑셀을 껐다가 다시 켜자.

단일변수의 시각화

- 양적 변수를 분석한다면 각 범주별로 상한값을 다른 칸에 먼저 입력해 두어야 한다. 40부터 10씩 증가시키는 쉬운 방법이 있다.
- 히스토그램 메뉴에서 “입력” 섹션의 “계급 구간” 안에 앞서 입력해 둔 상한값을 하이라이트하자.
- “이름표”는 하이라이트 부분 안에 변수 이름(variable name)을 포함하고 있을 경우 체크한다.
- 빈도분포표와 히스토그램은 약간의 문제가 있다. 표와 그래프를 꾸미자.
- 축 제목에서 “계급”은 너무 일반적인 표현이므로 “점수”와 같이 구체적인 표현으로 바꾸자.
- (경우에 따라) “기타”를 제거해야 할 수도 있다.
- 누적 %의 [축 서식]을 수정할 수도 있다.

단일변수의 시각화

- 히스토그램만 작성하고 싶다면 사실은 좀 더 편리한 방법도 있다!
- 해당 변수를 하이라이트하고 [삽입] 메뉴에서 [통계 차트 삽입] 아이콘을 눌러 "히스토그램"을 곧바로 고르는 것이다.
- 엑셀에 사소한 글리치(glitch)가 있어 구간 크기나 숫자를 조절하거나 할 때 오른쪽 윈도우를 확대해야만 보인다.
- 안타깝게도 도수분포표를 함께 얻을 수는 없다. 나중에 피벗 테이블(pivot table)로 도수분포표만 따로 쉽게 만들 수 있다.

단일변수의 시각화

- 히스토그램을 그릴 때 빈도(frequency)를 y축으로 삼을 수도 있지만, 밀도(density) 또는 백분위(percentage)를 사용할 수도 있다.
- 그림 자체야 둘 다 비슷하지만 해석상 밀도나 백분위 쪽이 좀 더 편하다(Why?).
- 엑셀의 SUM(· 함수를 사용하여 각 항목별 백분위를 계산한 뒤, 그쪽으로 하이라이트를 옮겨 히스토그램을 수정해보자.

단일변수의 시각화

같은 자료라도 히스토그램의 구간 설정에 따라 완전히 다른 자료처럼 보인다.

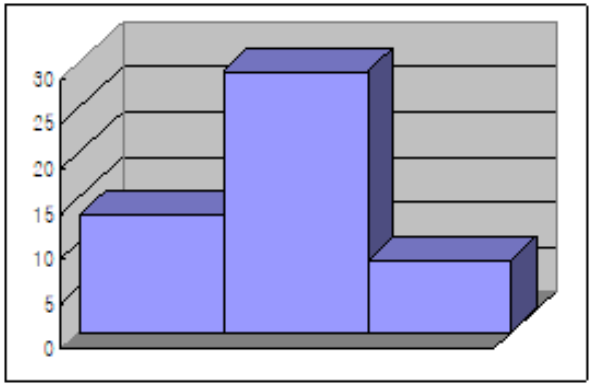

계급 구간=3

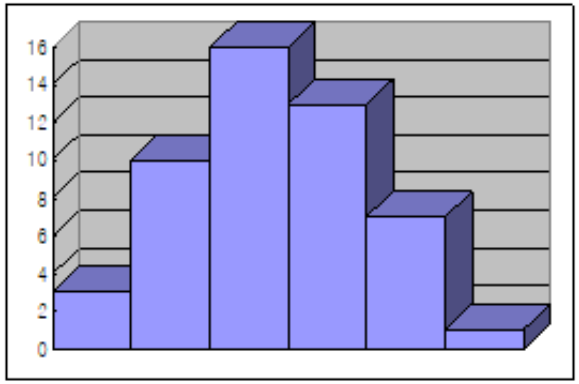

계급 구간=6

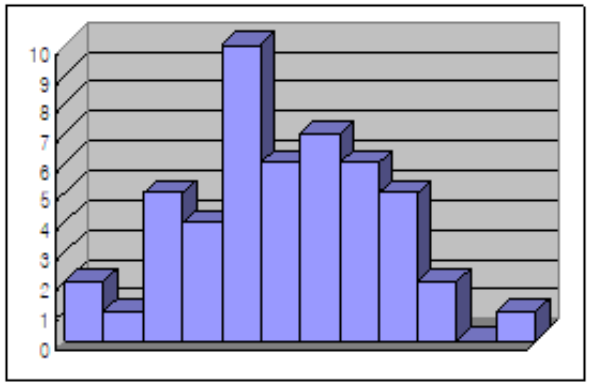

계급 구간=12

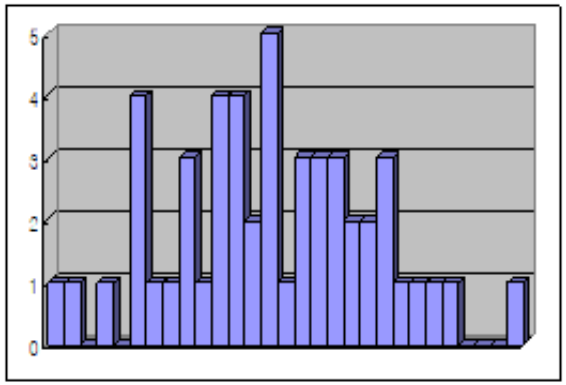

계급 구간=30

단일변수의 시각화

질적 변수를 나타낼 때는 파이 차트도 제법 쓰인다.

- 앞서 예제 1에서 사용한 자료의 소득 변수는 아래와 같은 파이 차트(pie chart)로 나타낼 수 있다.

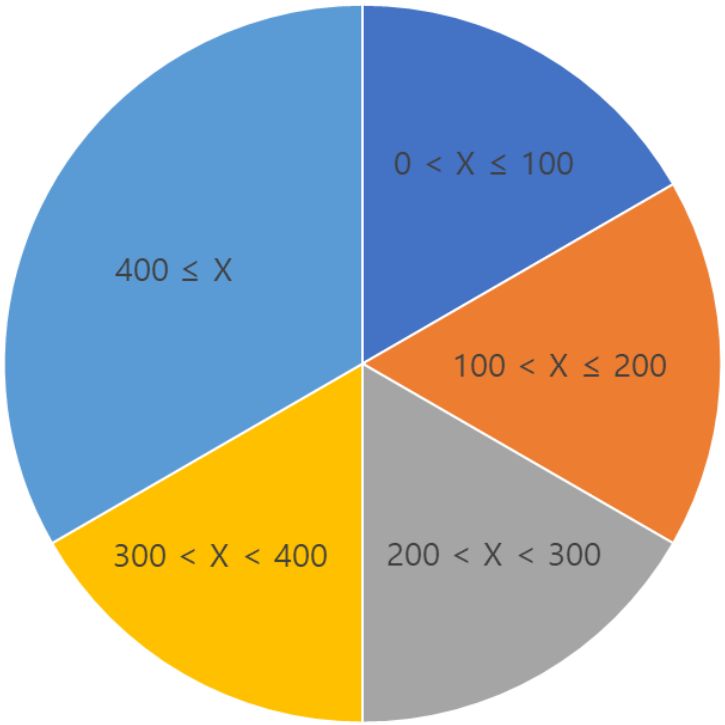

단일변수의 시각화

- 하지만 몇몇 전문가들은 파이 차트를 제한적으로 사용하도록 충고한다.
- 사실 파이 차트는 아주 조금만 복잡해져도 정보전달이 안되고, 정보전달이 쉽게 될 정도로 단순하게 만들면 그림을 그리는 의미가 없어진다. 게다가 히스토그램보다 특별히 더 나은 것 같지도 않다.
- 다만 파이 차트도 꾸미기에 따라서는 나름 예술적인 요소와 정보 전달 요소를 함께 갖출 수 있다. 여러분의 센스에 달렸다.

단일변수의 시각화

예제 2. employed.csv를 엑셀에 불러오시오. 다음은 지역주민 600명의 취업상태를 조사한 결과를 정리한 도수분포표이다. 이를 토대로 취업 상태를 파이 차트로 나타내시오.

코드	취업상태	도수	상대도수
1	정규직	243	0.41
2	비정규직	98	0.16
3	휴직/실업	32	0.05
4	은퇴	76	0.13
5	학생	45	0.08
6	주부	83	0.14
7	기타	23	0.04
	합계	600	1.00

단일변수의 시각화

파이 차트는 사실 통계학 분야에서 독특한 역사를 가지고 있다.

- 19세기 중반 Florence Nightingale은 평범한 간호사(“the lady with the lamp”) 이상의 역할을 수행했다. 그녀는 어쩌면 역사상 최초의 실무형 보건통계학자이자 현장연구(field work) 전문가였다. 직접 병원 자료를 수집하고 통계를 구축한 뒤 분석을 수행하였다. 특히 파이 차트를 능숙하게 사용했다.

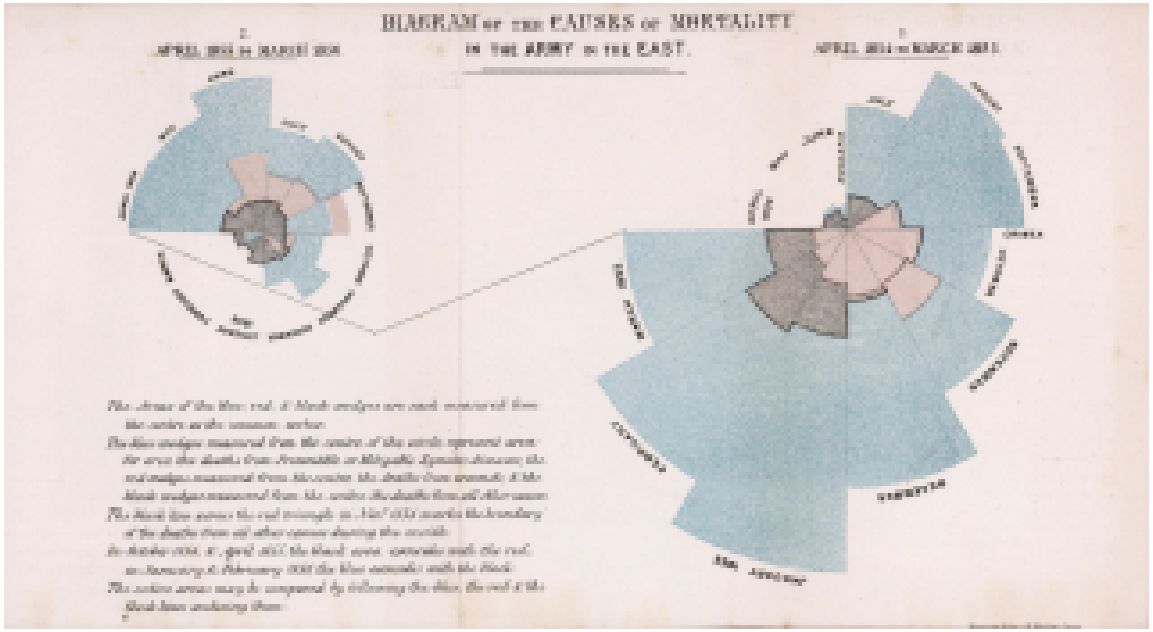

단일변수의 시각화

상자-수염 그림은 양적 변수를 요약하는데 사용될 수 있다.

- 상자-수염 그림(Box-Whisker plot)은 중심경향과 산포경향의 주요 요약통계량을 그림 하나로 전달한다는 장점이 있다.
- 특히 상자-수염 그림을 통해 이상점(outliers)도 한눈에 파악할 수 있다.

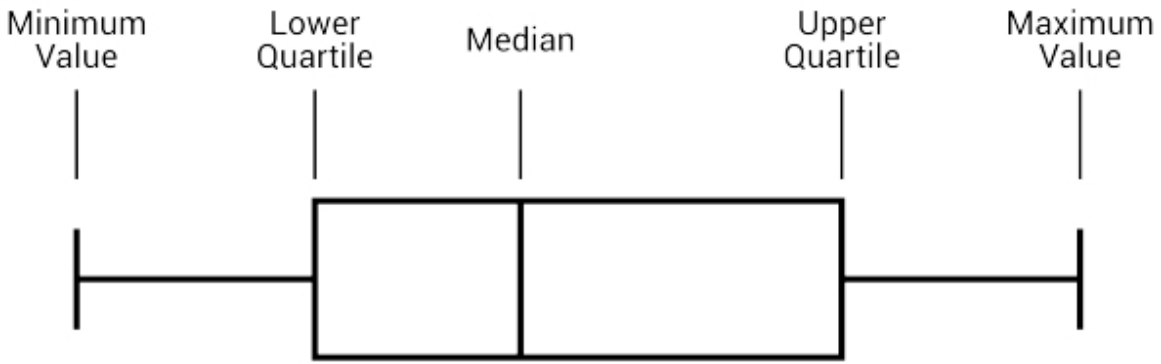

단일변수의 시각화

예제 3. 서울시수돗물 수질검사.csv를 엑셀에 불러오시오. 이것은 서울특별시 상수도사업본부 수질과에서 2020년에 발표한 자료이다. “검사실적” 변수의 상자-수염 그림을 그리고 해석하시오.

단일변수의 시각화

- 검사실적을 하이라이트하고 [삽입] 메뉴에서 [통계 차트 삽입] 아이콘을 눌러 “상자수염”을 고르면 된다.
- 해석할 때는 최소값(minimum), 첫번째 사분위수(quartile), 두번째 사분위수(=Median), 평균, 세번째 사분위수, 네번째 사분위수(=최대값)를 언급하면 된다.
- 각각을 엑셀 함수로 구해 답을 확인해 볼 수 있다.
- 튀어나온 점들은 극단치(outliers)라고 볼 수 있다. 이 점들은 서울시 어느 구의 검사실적인가?

단일변수의 시각화

줄기-잎 그림은 양적 변수의 윤곽을 표로 나타낸다.

- 줄기-잎 그림(stem-and-leaf plot)의 전체적인 윤곽은 수평으로 눕힌 히스토그램과 비슷하다.
- 모든 자료를 하나도 빼놓지 않고 나타내므로 자료가 조금만 커져도 표현하기 어렵다.
- 예제 1에서 사용한 자료를 다음과 같이 줄기-잎 그림으로도 나타낼 수 있다.

줄기	잎
3	6
4	
5	37
6	235899
7	011346778999
8	00111233568889
9	02238

단일변수의 시각화

오자이브는 구간별 누적백분율을 시각화한다.

- 오자이브(ogive)의 x축은 (나타내고자 하는 변수의) 도수(frequency) 혹은 계급구간(class interval)을 나타내고, y축은 누적백분율(cumulative percentage)을 나타낸다.

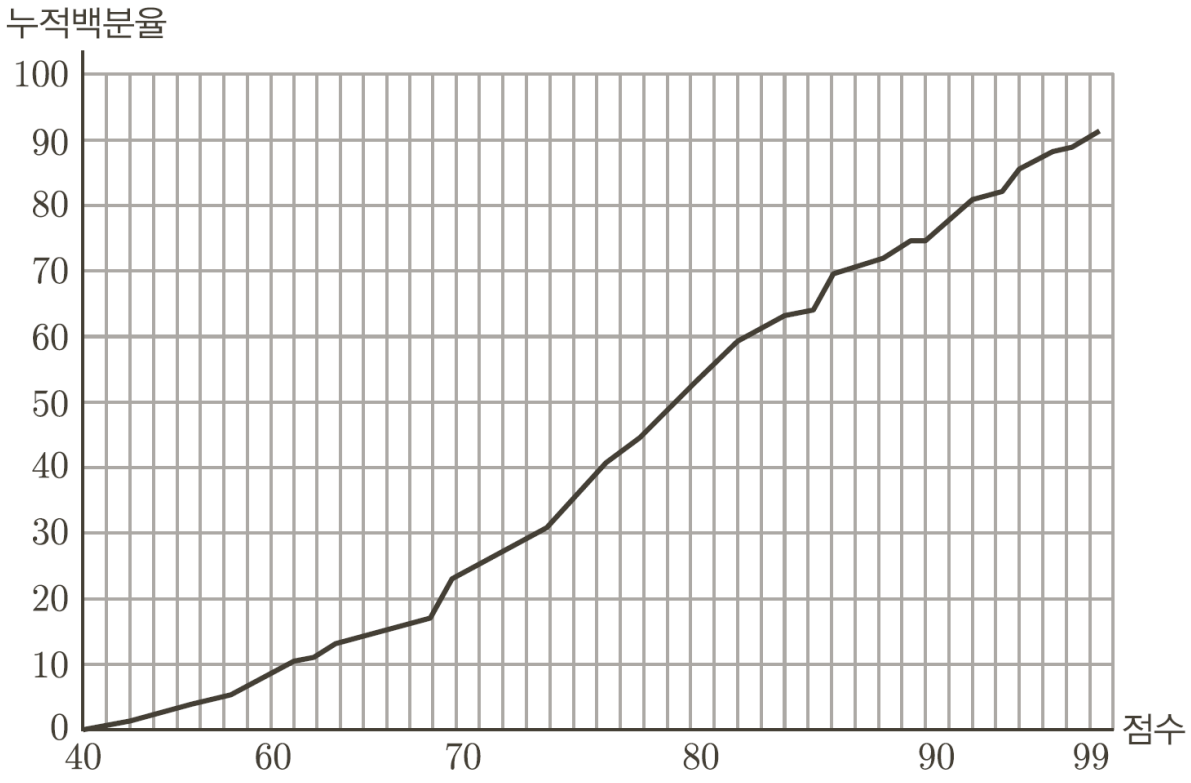

단일변수의 시각화

예제 4. KGSS_income.csv를 엑셀에 불러오시오. 이 자료는 2018년 KGSS 자료로 (만 원 단위) 월 소득을 자기보고한 것이다. 이 변수의 자료유형은 무엇인가? 이 변수를 10만 원 단위로 오자이브를 작성하시오.

단일변수의 시각화

- 먼저 피벗 테이블을 만든 다음, 50만 원 단위로 그룹화(grouping) 한다.
- 그룹화된 계급구간을 잘 살펴보면 빠져있는 구간들이 있다! [필드 설정]에서 "레이아웃 및 인쇄" 탭을 눌러 나오는 "데이터가 없는 항목 표시(W)"를 체크해야 한다.
- 누적도수(cumulative frequency)와 누적백분율을 옆에 각각 새로 계산한다. 이때 셀 참조가 어긋나지 않도록 유의해야 한다.
- "꺾은선형" 그림을 그리고 적절히 꾸며 오자이브를 표현할 수 있다.
- 이 오자이브의 의미를 해석해보자.