사회통계연습
확률의 기초

김현우, PhD[1]

[1] 충북대학교 사회학과 조교수

April 1, 2022

진행 순서

1. 지난 주 리뷰
2. 확률 개념의 이해
3. 확률법칙
4. 결합확률, 한계확률과 조건부확률
5. 베이즈 정리

지난 주 리뷰

지난 주 리뷰

1. 사회적 지지 변수의 자료유형을 설명하고 가장 적절한 시각화 기법을 골라 충실히 수행하시오. 이유와 해석을 함께 제시하시오(20점).

- 사회적 지지 변수는 양적 변수이다. 그러므로 시각화를 위해 히스토그램을 사용한다.

2. 건강수명 변수의 자료유형을 설명하고 가장 적절한 시각화 기법을 골라 충실히 수행하시오. 이유와 해석을 함께 제시하시오(20점).

- 사회적 지지 변수는 양적 변수이다. 그러므로 시각화를 위해 히스토그램을 사용한다.

지난 주 리뷰

행 레이블	개수 : Social support
0.4-0.5	3
0.5-0.6	5
0.6-0.7	17
0.7-0.8	28
0.8-0.9	56
0.9-1	40
총합계	**149**

행 레이블	개수 : Social support	
0.4-0.5	3	0.020134
0.5-0.6	5	0.033557
0.6-0.7	17	0.114094
0.7-0.8	28	0.187919
0.8-0.9	56	0.375839
0.9-1	40	0.268456
총합계	149	1

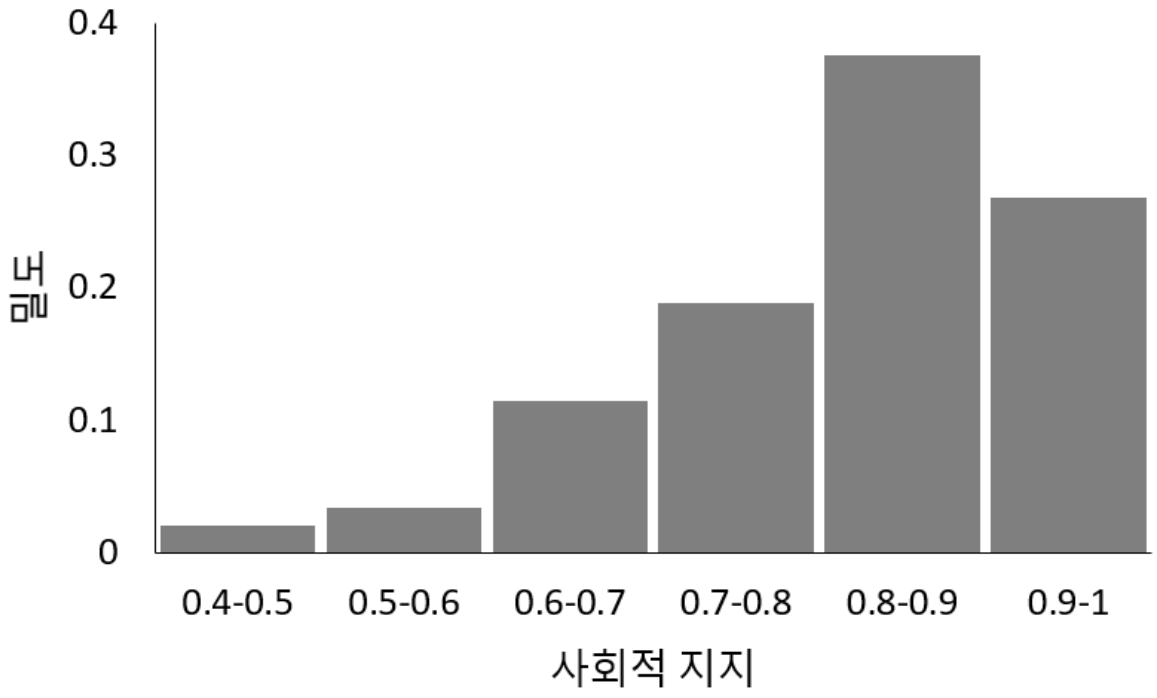

지난 주 리뷰

3. 사회적 지지와 건강수명 변수의 관계를 살펴보기에 가장 적절한 시각화 기법을 골라 충실히 수행하시오. 이유와 해석을 함께 제시하시오(20점).

- 두 변수 모두 양적 변수이므로 산점도와 적합선을 그릴 수 있다.
- 두 변수는 양의 상관관계를 보이고 있다.

	A	B	C	D
1	Country name	Regional indicator	Social support	Healthy life expectancy
2	North Macedonia	Central and Eastern Europe	0.884	75.1
3	Alba			
4	Bulg			
5	Mon			
6	Bosn			
7	Croa			
8	Hun			
9	Latv			
10	Serb			
11	Rom			
12	Pola			
13	Esto			
14	Lith			
15	Slov			
16	Kos			
17	Slov			
18	Cze			
19	Ukr			
20	Geo			
21	Turk			
22	Aze			

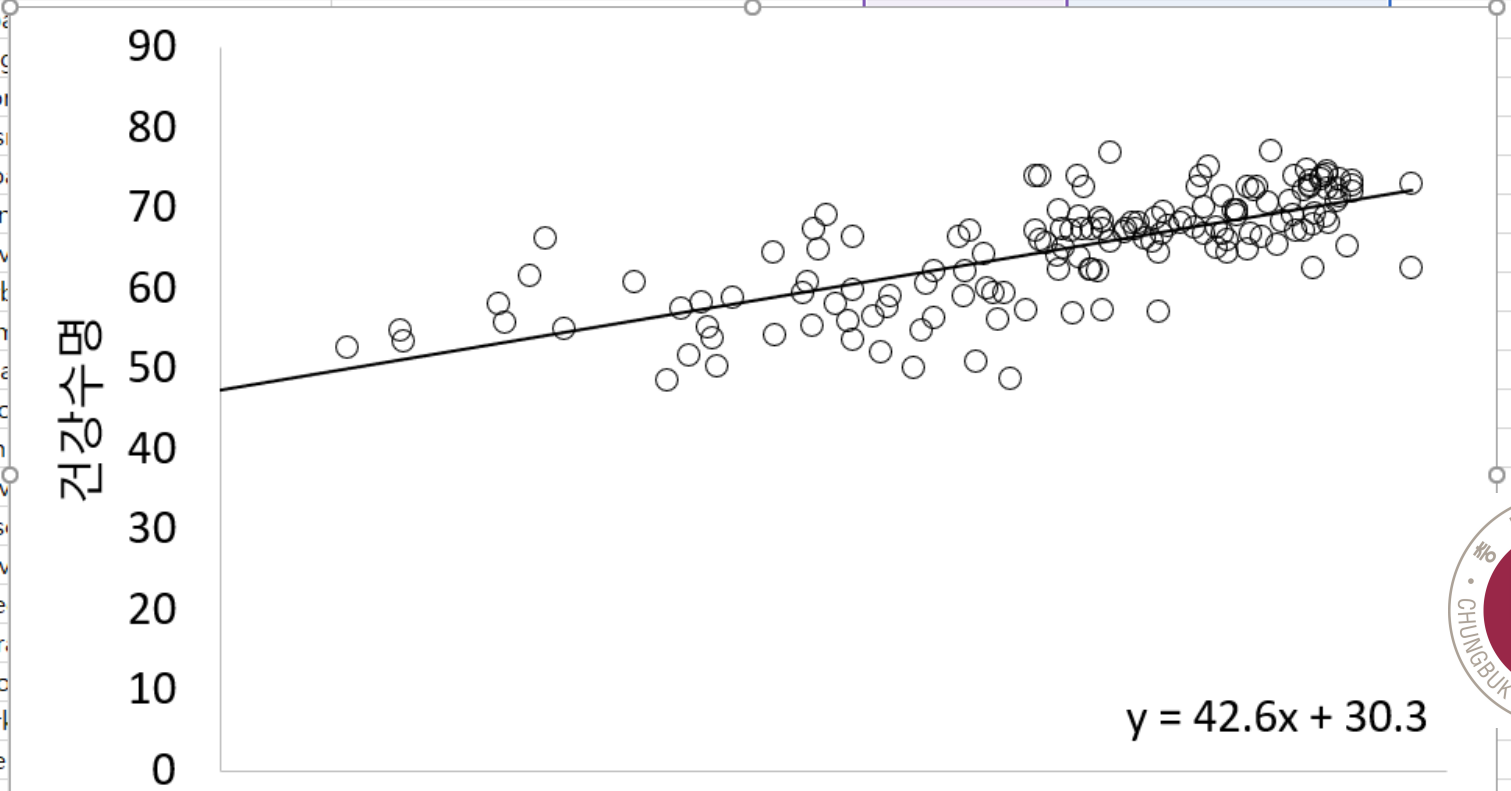

지난 주 리뷰

4. 사회적 지지가 해외지역 별로 어떻게 다른지 살펴보기 위해 가장 적절한 시각화 기법을 골라 충실히 수행하시오. 이유와 해석을 함께 제시하시오 (20점).

- 사회적 지지는 양적 변수인 반면, 해외지역 변수는 질적 변수이다. 그러므로 해외지역 별로 사회적 지지의 평균을 계산하여 비교할 수 있다.

4. 건강수명이 해외지역 별로 어떻게 다른지 살펴보기 위해 가장 적절한 시각화 기법을 골라 충실히 수행하시오. 이유와 해석을 함께 제시하시오 (20점).

- 건강수명은 양적 변수인 반면, 해외지역 변수는 질적 변수이다. 그러므로 해외지역 별로 건강수명의 평균을 계산하여 비교할 수 있다.

지난 주 리뷰

행 레이블	평균 : Social support
Central and Eastern Europe	0.77
Commonwealth of Independent States	0.82
East Asia	0.83
Latin America and Caribbean	0.78
Middle East and North Africa	0.85
North America and ANZ	0.66
South Asia	0.89
Southeast Asia	0.82
Sub-Saharan Africa	0.90
Western Europe	0.71
(비어 있음)	
총합계	

행 레이블	평균 : Social support
Sub-Saharan Africa	0.90
South Asia	0.89
Middle East and North Africa	0.85
East Asia	0.83
Southeast Asia	0.82
Commonwealth of Independent States	0.82
Latin America and Caribbean	0.78
Central and Eastern Europe	0.77
Western Europe	0.71
North America and ANZ	0.66

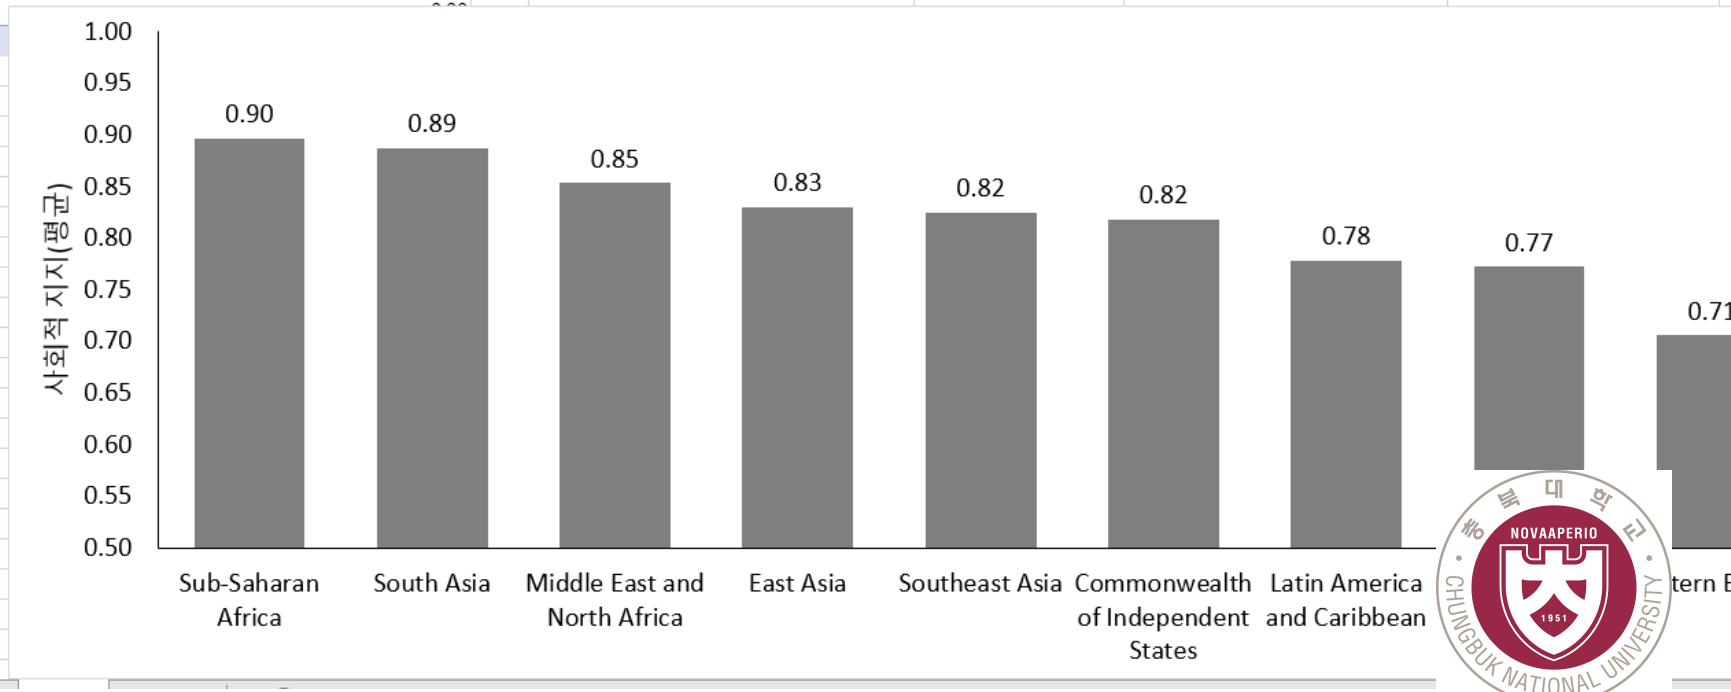

지난 주 리뷰

총평

- 숙제에 앞서 강의안과 교과서를 통해 꼼꼼히 복습해야 한다. 가령 히스토그램에서 y 축은 무엇이 되어야 할까? 히스토그램의 계급구간을 지나치게 뭉뚱그리면 그냥 틀린다.
- 제출된 숙제에 해석을 요구했는데 없어면 감점이다. 그래프를 첨부하지 않았으면 당연무효이다.
- 숙제를 대충하면 티가 확 난다. 이미 숙제로 인해 점수 차가 꽤 벌어지고 있다.
- 파일 제목은 "3주차_2019010017.docx"같은 식으로 통일할 것. 위반시 감점함.

확률 개념의 이해

확률 개념의 이해

확률이론의 역사는 도박과 밀접한 연관을 갖고 있었다.

- 17세기 프랑스 도박사였던 Antoine Gombaud는 도박과 판돈의 분배 문제에 관해 고민하다가 결국 해법을 찾는데 실패하고, 당대의 천재 수학자였던 Blaise Pascal과 Pierre de Fermat에게 이에 관해 물어보았다.
- 이에 Pascal과 Fermat는 서신을 교환하면서 확률이론(probability theory)의 토대를 쌓기 시작했다.
- 이들 덕택에 여러분이 이 고생을 하는 거다.

Gombaud

Pascal

Fermat

확률 개념의 이해

왜 사회학에서 확률이론을 필요로 할까?

- (나중에 더 자세히 다루겠지만) 우리는 모집단(population)에서 표본(sample)을 골라낼 것이다.
- 그 뒤, (모집단은 내버려두고) 표본만을 관찰하여 어떤 성질을 발견해 낼 것이다.
- 우리는 그 표본의 성질로부터 모집단의 성질을 유추해 내고(make inference) 싶다.
- 이 표본으로부터 유추된 성질이 (모집단과는 상관없이) 그저 표본만에서 우연히 나타났을 확률을 알고 싶기 때문에 확률이론을 필요로 한다.

확률 개념의 이해

예제 1. 동전을 한 번 던져서 앞면이 나올 가능성은 1/2이다. 그렇다면 동전을 두 번 던져서 두 번 모두 앞면이 나올 가능성은 얼마인가?

확률 개념의 이해

- 일단 동전을 (한 번) 던졌을 때, 있을 수 있는 모든 결과(all possible outcomes)는 암만 생각해도 두 가지 뿐이다: 앞면(head)과 뒷면(tail).
- 앞면(head)이 나올 확률은 1/2, 뒷면(tail)이 나올 확률도 1/2.
- 이제 두 번 던졌을 때, 나올 수 있는 모든 결과들(outcomes)의 집합(set)은 {HH, HT, TH, HH}.
- "응, 답은 1/4이야."
- 이 아이디어를 동전 던지기를 넘어 모든 현상에 일반화할 수 있다.

확률 개념의 이해

이 사고실험은 우리에게 몇 가지 유용한 개념이 있음을 시사한다.

- 확률(probability)이란 "어떤 사건(event)이 발생할 가능성을 나타난 값"이다.
- 사건(event)이란 "표본공간(sample space)의 특정 부분집합"을 의미한다.
- 앞의 예제에서 사건은 "두 번 모두 앞면(HH)"으로 주어졌다.
- 표본공간(sample space; S)이란 "어떤 시행(trial) 또는 실험(experiment)에서 가능한 모든 결과(all possible outcomes)의 집합"을 의미한다.
- 앞의 예제에서 표본공간은 $S = \{HH, HT, TH, TT\}$이다.

확률 개념의 이해

- 결과(outcome)은 시행 또는 실험에서 수집된 관측치를 뜻한다.
- 앞의 예제에서 "동전을 두 번 던진" 결과들은 HH, HT, TH, TT 모두 4개가 있다.
- 결과와는 달리 사건은 연구자의 관심에 따라 달라질 수 있다.
- 앞에서는 "두 번 모두 앞면"이라는 사건에 관심을 두었는데, 만일 "적어도 한 번은 앞면"이라는 사건으로 관심을 바꿀 수도 있다. 이 경우 HH, HT, TH가 사건이 된다.

확률 개념의 이해

확률을 몇 가지 방식으로 정의할 수 있다.

- 고전적 확률(classical probability)은 "논리적으로 생각하여" 알 수 있는 가능성을 확률로 정의하는 입장이다.
- 경험적 관찰에 근거하지 않고 논리적 판단에 의해 정의된다. 이 때문에 분석적(analytic) 확률이라고도 불리운다.
- 표본공간 $S = \{s_1, s_2, ..., s_N\}$에서 각각의 결과(outcome)가 일어날 가능성이 동등하다면, m개의 결과(outcomes)를 포함하는 사건(event)의 확률은 다음과 같다.

$$P(E) = \frac{m}{N}$$

확률 개념의 이해

- 경험적 확률(empirical probability)은 "장기간에 걸쳐 사건의 발생을 관찰하여(in a long run of observations) 얻은 상대적인 빈도"로 확률을 정의하는 관점이다.
- 주사위를 단 몇 차례만 던졌다면, 6이 나올 확률은 1/6이 아닐 수도 있다.
- 그러나 주사위를 제법 여러 차례 던졌다면, 6이 나올 확률은 1/6에 제법 근접할 것이다.
- 주사위를 무한히 많이 던진다면, 6이 나올 확률은 1/6에 무한히 근접할 것이다.
- 고전적 접근은 확률을 분석적으로 연역하고 있지만, 경험적 접근은 확률을 자료로부터 귀납한다.

확률 개념의 이해

확률은 사건에 대응하여 정의된다.

- 경험과학에서 개념의 내포(connotation)를 밝히는 방법을 정의라고 부르고, 개념의 외연(denotation)을 밝히는 방법을 구분이라고 부른다.
- "오늘 비가 내릴" 가능성이나 "동전을 열 번 던져 모두 뒷면이 나올" 가능성과 같이 사건(event)이 먼저 정의되어 있어야 한다.
- 일단 정의했다면 구분도 해야 하는데, 구분할 때는 반드시 두 가지 법칙을 따라야 한다.

확률 개념의 이해

포괄적이고 상호배타적 사건들의 확률의 합은 1이다.

- 첫째, (구분한 후에 얻어진) 자항의 총합이 모항과 같아야 한다(exhaustive).
- 예컨대 "10대", "20대', "30대 이상"은 자항의 총합이 모항과 같지 않은 구분이다.
- 둘째, (구분한 후에 얻어진) 자항들은 서로 배제해야 한다(mutually exclusive).
- 예컨대 "군필", "미필", "장교 전역"은 서로 배제하지 못하는 구분이다.
- 표본공간 S에 대하여 $P(S) = 1$이다.

확률법칙

확률법칙

둘 이상의 사건들 사이 관계를 그림으로 표현할 수 있다.

- 흔히 벤 다이어그램(Venn Diagram)으로 두 사건의 확률을 나타낸다.
- A와 B의 합사건(union)은 $A \cup B$ 로 표현한다
- A와 B의 교사건(intersection)은 $A \cap B$ 로 표현한다.
- A의 여사건(complement)은 A^C 로 표현한다

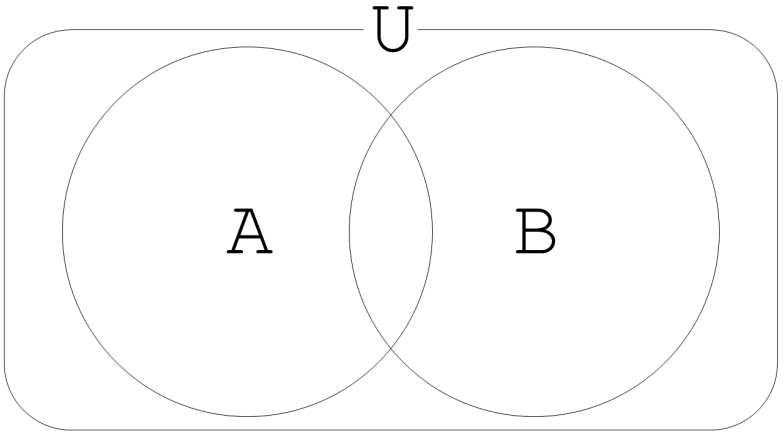

확률법칙

둘 이상의 사건들 사이 관계에 관하여 두 가지 기본 법칙이 성립한다.

- 첫째, 두 사건 A와 B 중 최소한 한 사건이 발생할 확률에 관해 다음의 덧셈 법칙 (addition rule)이 성립한다.

$$P(A \cup B) = P(A) + (B) - P(A \cap B)$$

- 여기서 $P(A \cap B)$는 (곧 설명할) 결합확률(joint probability)이다.
- 만일 사건 A와 B가 상호배타적이라면 다음과 같이 단순화된다.

$$P(A \cup B) = P(A) + (B)$$

확률법칙

- 둘째, 두 사건 A와 B가 동시에 발생할 확률에 관해 다음의 곱사건 법칙 (multiplication rule)이 성립한다.

$$P(A \cap B) = P(A|B) \cdot P(B) = P(B|A) \cdot P(A)$$

- 여기서 $P(A|B)$ 또는 $P(B|A)$ 는 (곧 설명할) 조건부확률(conditional probability)이다.

확률법칙

두 사건의 관계를 독립사건 혹은 종속사건으로 이해할 수 있다.

- 두 사건 A와 B가 있을 때, $P(A|B) = P(A)$ 이거나 $P(B|A) = P(B)$ 이면 두 사건은 독립(independent) 사건이다(Why?).
- (두 사건은 독립 아니면 종속이므로) 위 식이 성립하지 않으면 두 사건은 종속(dependent) 사건이다.
- A와 B가 독립적인 사건들이라면 덧셈 법칙은 더욱 단순해진다(Why?).

$$P(A \cup B) = P(A) + P(B)$$
$$P(A \cap B) = P(A) \cdot P(B)$$

확률법칙

- 연습삼아 세 독립사건인 경우에 다음이 성립함을 증명해보자.

$$P(E_1 \cup E_2 \cup E_3) = P(E_1) + P(E_1) + P(E_3)$$

- 이 설명을 일반화하여 E_1, E_2, $\cdots$, E_k가 상호배타적인 k개의 사건이라면 다음의 덧셈법칙이 성립한다

$$P(E_1 \cup E_2 \cup \cdots \cup E_k) = P(E_1) + P(E_1) + \cdots + P(E_k)$$

결합확률, 한계확률과 조건부확률

결합확률, 한계확률과 조건부확률

지금까지 배운 것을 토대로 자료 설명에 유용한 확률 개념을 도출한다.

- 어떤 자료가 주어졌을 때, "두 사건이 동시에 일어날 확률"을 결합확률(joint probability)이라고 부른다.

$$\begin{aligned} P(A \cap B) &= P(A|B) \cdot P(B) \\ &= P(B|A) \cdot P(A) \end{aligned}$$

- 결합확률은 곱셈법칙을 그대로 이용한다.

결합확률, 한계확률과 조건부확률

- 조건부확률(conditional probability)이란 "다른 사건(B)이 이미 있어났다는 전제 아래, 한 사건(A)이 일어날 확률"을 의미한다.

$$P(A|B) = \frac{P(A \cap B)}{P(B)}$$

- 조건부확률 또한 곱셈법칙을 그대로 이용한다(Why?).
- 결합확률과는 달리 조건부확률에서는 교환법칙(commutative property)이 성립하지 않는다.

$$P(A \cap B) = P(B \cap A)$$
$$P(A|B) \neq P(B|A)$$

결합확률, 한계확률과 조건부확률

- 한계확률(marginal probability)은 "연관된 결합확률의 합"이다.

$$P(A) = P(A \cap B) + P(A \cap B^C) \tag{1a}$$
$$= P(A|B) \cdot P(B) + (A|B^C) \cdot P(B^C) \tag{1b}$$

- (1b)는 조건부확률 $P(A|B)$의 정의를 이용하여 (1a)에서 도출된 것이다.

결합확률, 한계확률과 조건부확률

우리는 사실 이 개념들을 이미 배웠고 심지어 엑셀에서 활용까지 했다.

- 자료부터 교차표를 만든 뒤, 행 합계(row total)로 표준화한다.
- 아래 교차표를 들여다보면 $P(\text{종교인}|\text{여자}) = 0.44$, $P(\text{비종교인}|\text{여자}) = 0.56$, $P(\text{종교인}|\text{남자}) = 0.23$, $P(\text{비종교인}|\text{남자}) = 0.77$ 임을 알 수 있다.
- 이것이 바로 조건부확률(conditional probability)이다.

	종교인	비종교인	행 합계
여자	97	124	221
남자	68	232	300
열 합계	165	356	521

	종교인	비종교인	행 합계
여자	0.44	0.56	1
남자	0.23	0.77	1
열 합계	0.32	0.68	1

결합확률, 한계확률과 조건부확률

- 만약 열 합계(column total)로 표준화한 경우 다른 해석을 해야 한다(Why?)
- 아래 교차표를 들여다보면 P(여자|종교인), P(남자|종교인), P(여자|비종교인), P(남자|비종교인)을 구할 수 있다.
- 이것들도 물론 조건부확률(conditional probability)이다.

	종교인	비종교인	행 합계
여자	97	124	221
남자	68	232	300
열 합계	165	356	521

	종교인	비종교인	행 합계
여자	0.59	0.35	0.42
남자	0.41	0.65	0.58
열 합계	1	1	1

결합확률, 한계확률과 조건부확률

- 마지막으로 총 합계(grand total)로 표준화한 경우 다른 해석을 해야 한다.
- 아래 교차표를 들여다보면 $P(\text{종교인} \cap \text{여자}) = 0.19$, $P(\text{비종교인} \cap \text{여자}) = 0.24$, $P(\text{종교인} \cap \text{남자}) = 0.13$, $P(\text{비종교인} \cap \text{남자}) = 0.45$ 임을 알 수 있다.
- 이것이 바로 결합확률(joint probability)이다.

	종교인	비종교인	행 합계
여자	97	124	221
남자	68	232	300
열 합계	165	356	521

	종교인	비종교인	행 합계
여자	0.19	0.24	0.42
남자	0.13	0.45	0.58
열 합계	0.32	0.68	1

결합확률, 한계확률과 조건부확률

- 교차표와 오늘 배운 확률 개념은 사실 연관된 내용이다.

$$
\begin{aligned}
P(\text{종교인}) &= P(\text{종교인} \cap \text{여자}) + P(\text{종교인} \cap \text{남자}) \\
&= P(\text{종교인}|\text{여자}) \cdot P(\text{여자}) + P(\text{종교인}|\text{남자}) \cdot P(\text{남자})
\end{aligned}
$$

$$
\begin{aligned}
P(\text{비종교인}) &= P(\text{비종교인} \cap \text{여자}) + P(\text{비종교인} \cap \text{남자}) \\
&= P(\text{비종교인}|\text{여자}) \cdot P(\text{여자}) + P(\text{비종교인}|\text{남자}) \cdot P(\text{남자})
\end{aligned}
$$

결합확률, 한계확률과 조건부확률

$$
\begin{aligned}
P(\text{여자}) &= P(\text{여자} \cap \text{종교인}) + P(\text{여자} \cap \text{비종교인}) \\
&= P(\text{여자}|\text{종교인}) \cdot P(\text{종교인}) + P(\text{여자}|\text{비종교인}) \cdot P(\text{비종교인})
\end{aligned}
$$

$$
\begin{aligned}
P(\text{남자}) &= P(\text{남자} \cap \text{종교인}) + P(\text{남자} \cap \text{비종교인}) \\
&= P(\text{남자}|\text{종교인}) \cdot P(\text{종교인}) + P(\text{남자}|\text{비종교인}) \cdot P(\text{비종교인})
\end{aligned}
$$

이것이 바로 한계확률(marginal probability)이다.

결합확률, 한계확률과 조건부확률

- 교차표가 2×2 가 아니라 3×3 라도 조금 더 길어지지만 본질은 똑같다.

	보수적 성역할 태도	중립적 성역할 태도	진보적 성역할 태도	합계
소득: 상	486	761	279	1526
소득: 중	1024	1080	967	3071
소득: 하	662	822	434	1918
합계	2172	2663	1680	6515

- 여기서도 표준화 방식에 따라 상이하게 조건부확률과 결합확률을 구할 수 있다.
- 한계확률도 마찬가지다. 다만 2×2 방식이 아니므로,

$$P(A) = P(A \cap B) + P(A \cap B^C)$$

대신 다음과 같이 표현한다.

$$P(A) = P(A \cap B_1) + P(A \cap B_2) + P(A \cap B_3)$$

베이즈 정리

베이즈 정리

이제 확률의 첫번째 꽃을 피울 차례가 왔다.

- 지금까지 배운 개념들을 토대로 베이즈 정리(Bayes' Theorem)를 살펴보자

$$
\begin{aligned}
P(A|B) &= \frac{P(A \cap B)}{P(B)} \qquad\qquad (\text{if } P(B) \neq 0) \\
&= \frac{P(B|A) \cdot P(A)}{P(B)} \\
&= \frac{P(B|A) \cdot P(A)}{P(B|A) \cdot P(A) + P(B|A^C) \cdot P(A^C)}
\end{aligned}
$$

- 좌변의 $P(A|B)$가 우변에서는 모두 $P(B|A)$와 같이 바뀌었음에 주목해야 한다.
- 사전확률(prior probability)인 $P(A)$와 $P(A^C)$ 그리고 우도(likelihood)인 $P(B|A)$를 알면 사후확률(posterior probability) $P(A|B)$를 알 수 있다.

베이즈 정리

예제 1. 사지선다 문제를 맞추었을 때 알고 풀었을 확률을 구하시오. 단, 답을 아는 사전확률과 모르는 사전확률은 같다고 전제한다.

베이즈 정리

- "답을 알(K)" 사전확률과 "답을 모르는(DK)" 사전확률이 같다면 이는 상호배타적 사건임을 의미한다.

$$P(A_K) = P(A_{DK}) = \frac{1}{2}$$

- (다른 문제도 그렇지만 특히) 베이즈 확률을 계산할 때는 문제가 묻는 것이 정확히 무엇인지 먼저 식별해야 한다. 여기서는 "답을 맞추었다(C)"는 조건 아래 답을 알(A_K) 확률, 즉 $P(A_K|C)$를 묻고 있다.

$$P(A_K|C) = \frac{P(C|A_K) \cdot P(A_K)}{P(C|A_K) \cdot P(A_K) + P(C|A_{DK}) \cdot P(A_{DK})}$$

베이즈 정리

- 곰곰히 생각하면 우도(likelihood)가 무엇인지 알 수 있다(Why?).

$$P(C|A_K) = 1$$
$$P(C|A_{DK}) = \frac{1}{4}$$

- 그러므로 문제가 찾는 답은 다음과 같다.

$$P(A_K|C) = \frac{1}{1+\frac{1}{4}} = \frac{4}{5}$$

- 베이즈 정리에 따르면 문제를 맞췄다고 하여 반드시 답을 알고 있었던 것은 아닌 셈이다.

베이즈 정리

베이즈 정리에는 독특한 역사가 있다.

- 장로교 목사이자 아마추어 수학자였던 Thomas Bayes (1701?–1761)는 David Hume의 회의주의적 경험론에 반발하여 (아마도) 신의 존재를 수학으로 증명하고자 논문을 한 편 작성했다.
- 이것은 완전히 잊혀졌다가 Pierre-Simon Laplace (1749–1827)에 의해 재발견되었다.
- 그러나 20세기 들어 통계학이 급성장하면서 Karl Pearson, Ronald Fisher, Jerzy Neyman 등이 베이즈의 관점과 상이한 통계추론의 논리를 제시하면서 다시 한 번 잊혀졌다.

Bayes

Laplace

Pearson

Fisher

Neyman

베이즈 정리

- 21세기 들어 인공지능(AI)과 기계학습(machine learning)의 시대가 도래하면서 다시 한 번 베이즈 통계학(Bayesian statistics)이 부상하게 되었다.
- 20세기 통계학의 관점을 빈도주의 통계학(frequentist statistics)이라고도 부른다.
- 우리 수업은 빈도주의 통계학의 기초를 배우는 과정이다.
- 뇌의 작동 방식이 베이즈 정리에 의해 잘 설명된다는 주장이 있지만, 아쉽게도 베이즈 통계학은 계산집약적(computationally intensive)인 점이 흠이다.

베이즈 정리

- 확률의 기초는 베이즈 정리(Bayes' theorem)를 알기 전과 이것을 안 뒤로 나뉜다.
- 몇 가지 흥미로운 논리적 문제를 풀 수 있다: 몬티 홀(Monty Hall) 문제, 다운증후군 임신 테스트 신뢰성 문제 등등...
- 그 밖에도 몇 가지 실생활에서 할 수 있는게 있다: 사람의 말과 글을 알아듣는 기계나 자율주행하는 자동차를 만든다던가 등등...
- (R이나 Python 등을 통해) 20–30줄 정도의 코드로도 꽤 쓸모있는 인공지능을 구현할 수 있다.