사회통계
이산확률분포

김현우, PhD[1]

[1] 충북대학교 사회학과 조교수

April 8, 2022

진행 순서

1. 지난 주 리뷰
2. 이론적 확률분포
3. 베르누이 분포
4. 이항분포

지난 주 리뷰

지난 주 리뷰

1. 토익시험 점수의 자료유형을 설명하고 적절한 시각화 기법을 골라 이를 충실히 수행하시오(25점).
   - 토익시험 점수는 엄밀하게 말해 이산확률변수이다(Why?). 그러나 이것은 동시에 거의 연속(approximately continuous)이다(교재 21페이지). 그러므로 양적확률변수라고 말해도 큰 문제가 없다.
   - 연속이 아닌 것을 연속으로 취급하여 계산하였으므로 당연히 소숫점에서 차이가 나타난다.

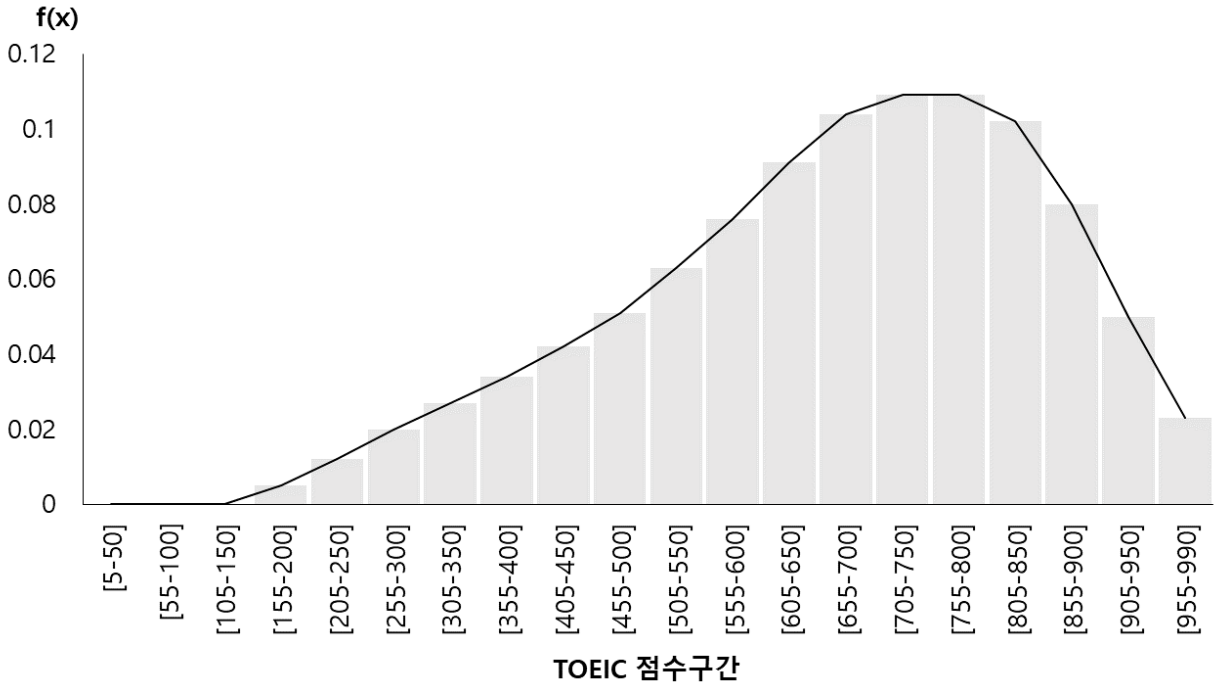

누적분포함수

2. 토익 점수가 750점보다 낮을 확률을 수학적으로 표현하고 계산하시오 (25점).

$$P(X \leq 750) = 0.634$$

3. 토익 점수가 505점보다 높고 650점보다 낮을 확률을 수학적으로 표현하고 계산하시오(25점).

$$P(505 \leq X \leq 650) = P(X \leq 650) - P(X \leq 500) = 0.23$$

4. 토익 점수가 905점보다 높을 확률을 수학적으로 표현하고 계산하시오 (25점).

$$P(X > 905) = 1 - P(X \leq 900) = 0.075$$

누적분포함수

보너스 문제. A는 정기 암 건강검진을 통해 양성 판정을 받았다. 의사는 검사 정확도가 90%라고 알려주었다. A가 정말로 암에 걸렸을 확률을 구하시오. 참고로 성인의 암 유병률은 약 1%이다(10점).

- 문제가 $P(\ |\ )$을 묻고 있음을 파악하는 것이 가장 어렵다.
- 이제 베이즈 정리를 적고 각각의 항(term)에 대응하는 수치를 대입하면 그만이다.

$$
\begin{aligned}
P(\text{진}|\text{양성}) &= \frac{P(\text{양성}|\text{진}) \cdot P(\text{진})}{P(\text{양성}|\text{진}) \cdot P(\text{진}) + P(\text{양성}|\text{위}) \cdot P(\text{위})} \\
&= \frac{0.9 \cdot 0.01}{0.9 \cdot 0.01 + 0.1 \cdot 0.99} \\
&= 0.083
\end{aligned}
$$

지난 주 리뷰

총평

- 숙제에 앞서 강의안과 교과서를 통해 꼼꼼히 복습해야 한다. 아직도 히스토그램을 제대로 이해하지 못한 학생이 몇몇 눈에 띤다. 기계적으로 흉내내지 말고 자신이 지금 무엇을 하고 있는지 생각을 해야하고, 제시된 결과가 무엇을 의미하는지 되새겨야 한다.
- 제출된 숙제에 답만 던지면 (옳고 그름을 떠나) 틀린 것으로 간주한다.
- 파일 제목은 “3주차_2019010017.docx”같은 식으로 통일할 것. 위반시 감점함.

이론적 확률분포

이론적 확률분포

몇몇 확률분포는 수리적으로 아름다울 뿐 아니라 문제해결에도 유용하다.

- 이런 확률분포에 대해서는 특별히 많은 논의가 이루어졌다. 그러므로 이론적 확률분포(theoretical probability distribution)라는 이름 아래 좀 더 신경써서 배워야 할 필요가 있다.
- 일단 확률분포가 주어지면 그것의 평균과 분산을 계산할 수 있다는 것을 꼭 기억하자!
- 수리통계학(mathematical statistics)에서는 꽤 공들여 여러 종류의 이론적 확률분포를 공부한 다음, 각각의 평균과 분산을 도출하고 각종 수학적 테크닉을 동원해서 다양하게 증명한다.

이론적 확률분포

- 다양한 유형의 시행 또는 실험 결과는 상이한 확률분포를 생성한다.
- 확률변수가 이산형과 연속형으로 나뉘듯, 확률분포 역시 이산확률분포(discrete probability distribution)와 연속확률분포(continuous probability distribution)로 구분된다.

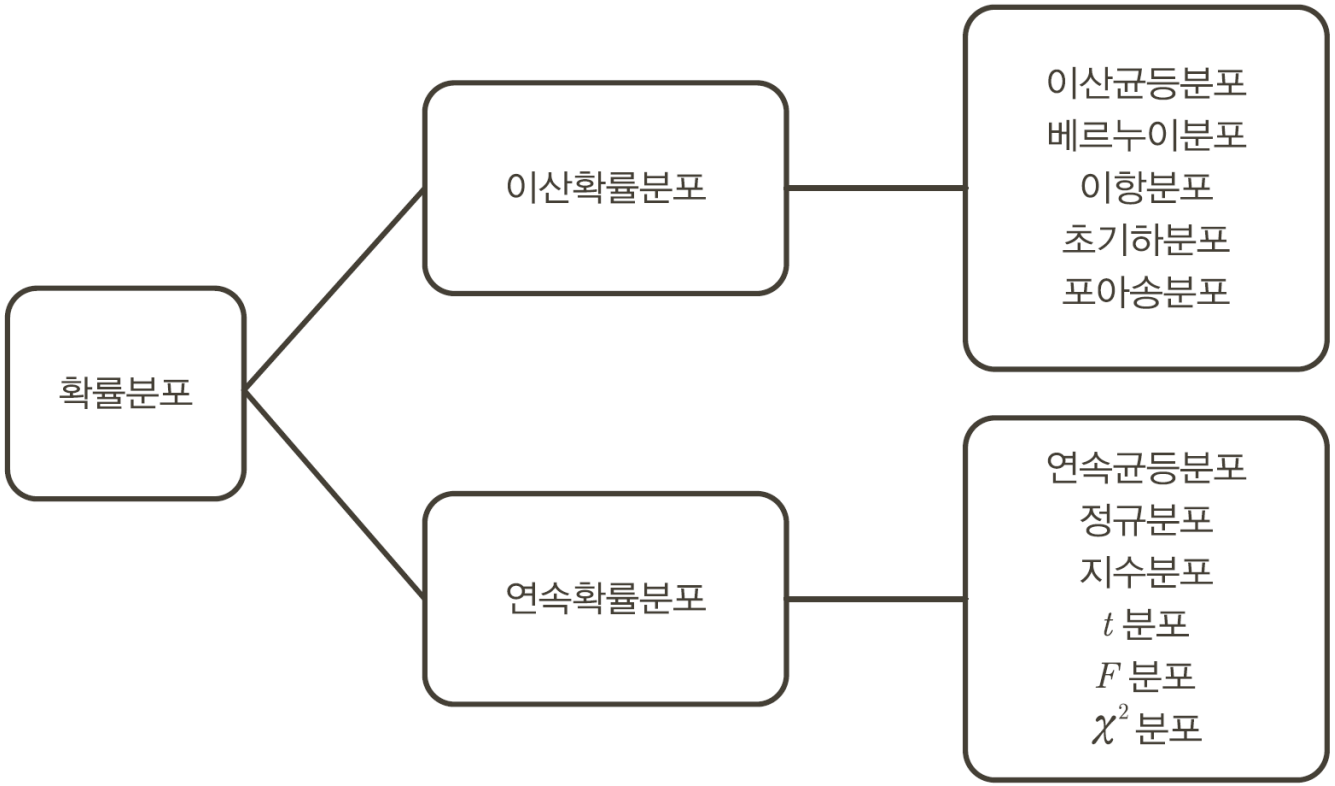

이론적 확률분포

- 수업시간에서 우리는 오로지 몇 가지 이론적 확률분포만 간략히 공부한다.
- 수업에서 다룬 이론적 확률분포만 시험 범위로 다루어진다.
- 이것만으로는 실무와 연구에서 당연히 한계가 있음을 기억하자.
- 다루지 않은 중요한 이론적 확률분포는 교과서에 잘 설명되어 있으므로 참고로 하자.

베르누이 분포

베르누이 분포

동전 던지기의 결과를 수학적으로 일반화해보자.

- 동전 던지기의 결과를 앞면(H)과 뒷면(T)으로 나타내듯 두 가지 결과가 예상되는 시행 내지 실험을 상상해보자.
- 인생의 어떤 순간에서 성공 혹은 실패를 구분해볼 수도 있다(이것은 인생의 성공과 실패와는 다른 관념이다).
- Daniel Bernoulli (1655-1700)가 이 문제에 관해 처음으로 수학적 상상력을 발휘하여 정리하였으므로 그 이름을 따서 베르누이 과정(Bernoulli process)이라고 부른다.

베르누이 분포

- 베르누이 과정에서는 딱 한 번의 시행이 이루지고 각 시행의 사건(event) X는 두 가지 뿐이다(e.g., 성공/실패, H/T, 1/0).
- 두 사건의 확률은 각각 $P(X=1)=p$ 와 $P(X=0)=1-p$ 로 표현할 수 있다.

$$f(X;p)=\begin{cases} p & \text{if } x=1 \\ 1-p & \text{if } x=0 \end{cases}$$

- 좀 더 축약해서 표현할 수도 있다.

$$f(X;p)=p^x(1-p)^{1-x}$$

- 이때 p는 성공 확률(e.g., 동전 던지기라면 0.5), X는 성공 여부(i.e., 1이 성공, 0이 실패)를 나타낸다.

베르누이 분포

- 위 식의 좌변(left-hand side) $f(X;p)$는 이것이 확률질량함수(PMF) 또는 확률밀도함수(PDF)임을 나타낸다. X는 이산확률변수이므로 $f(X;p)$ 은 확률질량함수이다.
- 참고로 (p같이) 어떤 확률질량함수 또는 확률밀도함수를 정의하기에 (확률변수 외에도) 꼭 필요한 값들을 패러미터(parameter)라고 부른다.
- 때때로 학생들은 X가 확률변수인 반면, p는 상수(constant)라는 점을 이해하지 못하는데 꽤 중요한 기초이므로 신중히 고민해보자.

베르누이 분포

- 확률질량함수란 이산확률변수에서 어떤 확률변수 X가 주어지면 그에 따른 확률질량 $f(x)$을 토해내는 함수이다.
- 확률과 확률질량함수, 확률밀도함수를 제대로 이해하기 위해 교재 133페이지를 꼼꼼하게 읽어보자.
- 어떤 확률변수 X에 대해 확률질량함수 $f(x)$를 정의할 수 있었다면 확률분포를 그릴 수 있음을 의미한다. 이것을 베르누이 분포(Bernoulli distribution)라고 부를 수 있다.

베르누이 분포

베르누이 분포 역시 평균과 분산을 갖는다.

- 일단 확률분포가 주어지면 확률변수의 평균과 분산을 계산할 수 있다고 했으므로, 베르누이 분포도 마찬가지이다.
- 베르누이 확률분포의 평균(=기대값)은 $E(X) = p$ 이다.

$$E(X) = p \cdot 1 + (1 - p) \cdot 0 = p$$

- 확률분포표를 그려서 평균을 계산해보면 아주 쉽게 이해할 수 있다.

베르누이 분포

- 베르누이 확률분포의 분산은 $Var(X) = p(1-p)$ 이다.

$$
\begin{aligned}
Var(X) &= \sum (X-\mu)^2 p \\
&= E[(X-E(X)]^2 \\
&= E[X^2 - 2XE(X) + E(X)^2] \\
&= E(X^2) - E(X)^2 \\
&= p - p^2 \\
&= p(1-p)
\end{aligned}
$$

확률분포

예제 1. 효기는 승원은 논쟁을 벌이다 주사위를 던져 누구 말이 맞는지 결정하기로 했다. 주사위에 관해서라면 자신감이 넘치는 효기는 3 이하의 값이 나오면 자기가 진 걸로 쳐도 좋다고 선언하였다. (승원의 관점에서) 이 내기의 확률분포를 표로 나타내고 평균과 분산을 계산하시오. 이 내기를 표현할 수 있는 이론적 확률분포는 무엇인지 판단하고, 그 공식을 사용하여 평균과 분산을 구하시오.

베르누이 분포

- 주사위를 던진 결과는 이산확률변수이므로 다음과 같이 확률변수로 표현할 수 있다:
  "주사위에서 3 이하의 값이 나오는 사건(승리)의 확률은 $P(X \leq 5)$는 $3/6$이다."
  "주사위에서 3보다 큰 값이 나오는 사건(패배)의 확률은 $P(X > 5)$는 $3/6$이다."

x	$P(X=x)$	$x \cdot P(X=x)$	$(x-\mu)^2 \cdot P(X=x)$
0(= 패배)	$3/6$	$3/6 \cdot 0 = 0$	$(0-0.5)^2 \cdot 3/6 = 0.125$
1(= 승리)	$3/6$	$3/6 \cdot 1 = 1$	$(1-0.5)^2 \cdot 3/6 = 0.125$
	합계	0.5	0.25

- 평균은 0.5, 분산은 0.25임을 알 수 있었다.

베르누이 분포

- 이론을 생각한다는 것은 경험을 멈추는 것에서 시작한다.
- 승리와 패배의 일회성 결과와 그 확률 p가 주어져 있으므로 이것은 베르누이 분포를 사용하여 묘사할 수 있다.
- 베르누이 확률분포의 평균(=기대값)은 $E(X) = p = 0.5$ 이고 분산은 $Var(X) = p(1-p) = 0.25$ 이다.
- 이론적인 계산이 확률분포를 표로 직접 그리고 하나하나 계산한 것과 같은 결과를 보여주었다.

베르누이 분포

이렇게해서 벌써 하나의 확률분포를 공부했다.

- 어떤 확률분포가 묘사하고 있는 상황에 관해 수학적 상상력을 발휘하는 것이 중요하다.
- 그 뒤 확률질량함수 또는 확률밀도함수를 이해하고 그것의 평균과 분산을 이해하면 된다.
- 베르누이 분포는 굉장히 단순하기 때문에 이를 새삼 확률분포로 나타내는 것도 웃기지만, (더 중요한) 다음 장의 분포를 공부하기 위해 반드시 필요하다.

이항분포

이항분포

이항분포는 "반복적인 베르누이 과정"을 나타낸 확률분포이다.

- 이항분포(binomial distribution)야말로 가장 대표적인 이산확률분포라고 할 수 있다.
- 앞서 설명한 베르누이 과정은 단 한 번 시행을 염두에 둔 것이였다.
- 이항분포는 베르누이 과정을 n번 독립 시행(n times independent trials)하여 얻은 성공 횟수를 확률변수로 삼는다.
- 이는 n번의 시행들의 결과가 서로에게 영향을 미치지 못하는 경우이다.
- 이항분포는 성공 횟수가 확률변수이고 그에 대응하는 확률인 시행(또는 실험)을 수학적으로 묘사한다.

이항분포

이항분포를 먼저 직관적으로 이해하자.

- "동전을 세 번 던져서 앞면이 한 번 나올 확률은 무엇인가?"
- 여기서 보려는 사건(event)은 다음과 같다.

$$\{H, T, T\}, \quad \{T, H, T\}, \quad \{T, T, H\}$$

- (각 사건과 결부된) 확률은 각각 다음과 같다.

$$p \cdot (1-p) \cdot (1-p), \quad (1-p) \cdot p \cdot (1-p), \quad (1-p) \cdot (1-p) \cdot p$$

- 그러면 찾고 있는 답은 다음과 같다.

$$\begin{aligned} =& 0.5 \cdot (1-0.5) \cdot (1-0.5) + \\ & (1-0.5) \cdot 0.5 \cdot (1-0.5) + \\ & (1-0.5) \cdot (1-0.5) \cdot 0.5 \\ =& 0.375 \end{aligned}$$

이항분포

곰곰히 생각해보면 이 계산을 일반화할 수 있다.

- 특히 경우의 수 계산이라는 수학적 기법이 유용하다!
- 여러분은 고교 시절 여러가지 경우의 수 계산법을 학습하였다.
- 그런데 특히 실무나 연구에서 "가장" 유용한 경우의 수 계산식을 딱 하나 고르라고 한다면 그건 바로 조합(combination)이다.
- 조합은 "순서 없이" 서로 다른 n개 가운데 x개를 선택하는 경우의 수이다.

$$ {}_3C_x = \binom{n}{x} = \frac{n!}{x!(n-x)!} $$

- 여기서 $x!$는 x의 팩토리얼(factorial)을 뜻하며, $x \cdot (x-1) \cdot (x-2) \cdot \cdots \cdot 1$로 계산한다.

이항분포

- 그 유용성을 확인할 수 있는 굉장히 많은 현실 사례가 있다.
- "파티에 3명이 모였다. 둘 씩 서로 악수를 한다면 모두 몇 번 소개해야 할까?"
- "$\{A, B\}$, $\{A, C\}$, $\{B, C\}$. 모두 3번이다."

$$ {}_3C_2 = \binom{3}{2} = \frac{3!}{2!(3-2)!} = 3 $$

- "어떤 수업에 38명이 모였다. 3명 씩 한 조를 짠다면 모두 몇 가지의 가능성이 있는가?"

$$ \binom{38}{3} = \frac{38!}{3!(38-3)!} = 8436 $$

- 엑셀에서는 COMBIN(n, x)를 함수로 입력하여 조합을 계산할 수 있다.

이항분포

- 동전을 한 번 던진 결과는 베르누이 분포로 나타낼 수 있다.
- 동전을 세 번 던지고, 앞면이 한 번만 나오는 "경우의 수"를 계산할 때 이항분포가 사용된다고 하였다.
- 그러므로 베르누이 분포의 확률질량함수 앞머리에 어떤 조합을 가져다 붙이면 이항분포의 확률질량함수를 나타낼 수 있을 것이다!

$$\binom{n}{x} \cdot p^x (1-p)^{n-x} = \frac{n!}{x!(n-x)!} \cdot p^x (1-p)^{n-x}$$

- 그 앞머리를 이항계수(binomial coefficient) 또는 파스칼의 삼각형(Pascal's Triangle)이라고 부른다.

이항분포

- 조합을 사용하여 아까 문제를 다시 계산해보자: “동전을 세 번 던져서 앞면이 한 번 나올 확률은 무엇인가?”
- 세 번 시행하여($n = 3$) 1회 성공이라는 “경우의 수”이므로($x = 1$),

$$\frac{3!}{1!(3-1)!} \cdot 0.5^1 \cdot (1-0.5)^{3-1} = 0.375$$

- 물론 이론적으로 계산한 답과 확률분포를 하나하나 그려 계산한 답은 같다.

이항분포

거듭 말하지만 일단 확률분포가 주어지면 그것의 평균과 분포를 계산할 수 있다.

- 이론적 확률분포를 공부한다는 것은 (1) 그것의 확률질량함수/확률밀도함수가 어떻게 구성되고, (2) 그 확률분포의 평균이 어떻게 계산되고, (3) 그 확률분포의 분산이 어떻게 계산되는지 아는 것이다.
- 평균과 분산 계산의 증명은 응용통계학에서는 사실 그렇게까지 중요하지는 않다.

이항분포

이항분포 역시 평균과 분산을 갖는다.

- 이항분포의 평균은 다음과 같다.

$$E(X) = np$$

- 엄밀한 수학적 증명은 내버려두고 개념적으로만 살펴보자!
- 베르누이 분포는 "단 한 번"의 성공 횟수를 확률로 나타낸다. 그 평균은 p이다.
- 반면 이항분포는 베르누이 과정을 "n번 독립 시행"했을 때 성공 횟수를 확률로 나타낸다.
- 그러므로 이항분포의 평균은 베르누이 분포의 평균 p에 n을 곱한 값과 같다.

이항분포

- 이항분포의 분산은 다음과 같다.

$$Var(X) = np(1-p)$$

- 여기서도 까다로운 수학적 증명은 수학도들에게 맡기고 그저 직관적으로만 살펴보자.
- 베르누이 분포는 "단 한 번"의 성공 횟수를 확률로 나타낸다. 그 분산은 $p(1-p)$이다.
- 반면 이항분포는 베르누이 과정을 "n번 독립 시행"했을 때 성공 횟수를 확률로 나타낸다.
- 그러므로 이항분포의 분산은, 개별 베르누이 시행의 분산 $p(1-p)$이 서로 얽히지 않고 독립적으로 나타나므로, 여기에 n을 곱한 값과 같다.

이항분포

이항분포를 수학적으로 표현할 수 있다.

- 확률변수 X가 (시행횟수가 n이고 확률이 p인) 이항분포를 따른다면 이렇게 표현한다.

$$X \sim \mathcal{B}(n, p)$$

- 확률변수 X가 베르누이 분포를 따른다면 이렇게 표현할 수 있다(Why?).

$$X \sim \mathcal{B}(1, p)$$

이항분포

이항분포를 그래프로도 나타낼 수 있다.

- 아까 사례를 다시 보자: "동전을 세 번 던져서 앞면이 한 번 나올 확률은 무엇인가?"
- 이때 동전을 세 번 던진 결과, 앞면이 나올 수 있는 "모든 경우의 수"를 각각 이항분포에 따라 아래처럼 계산할 수도 있다.

$$P(X=0) = \frac{3!}{0!(3-0)!} \cdot .5^0 \cdot (1-0.5)^{3-0} = 0.125$$

$$P(X=1) = \frac{3!}{1!(3-1)!} \cdot .5^1 \cdot (1-0.5)^{3-1} = 0.375$$

$$P(X=2) = \frac{3!}{2!(3-2)!} \cdot .5^1 \cdot (1-0.5)^{3-2} = 0.375$$

$$P(X=3) = \frac{3!}{3!(3-3)!} \cdot .5^1 \cdot (1-0.5)^{3-3} = 0.125$$

이항분포

- 이 모든 경우의 수를 다시 확률분포로 표현할 수 있다.
- x축은 확률변수 X이고, y축은 이항분포를 따르는 확률질량함수 $f(X)$인 그래프를 그릴 수 있다.

x	$P(X = x)$
0	0.125
1	0.375
2	0.375
3	0.125

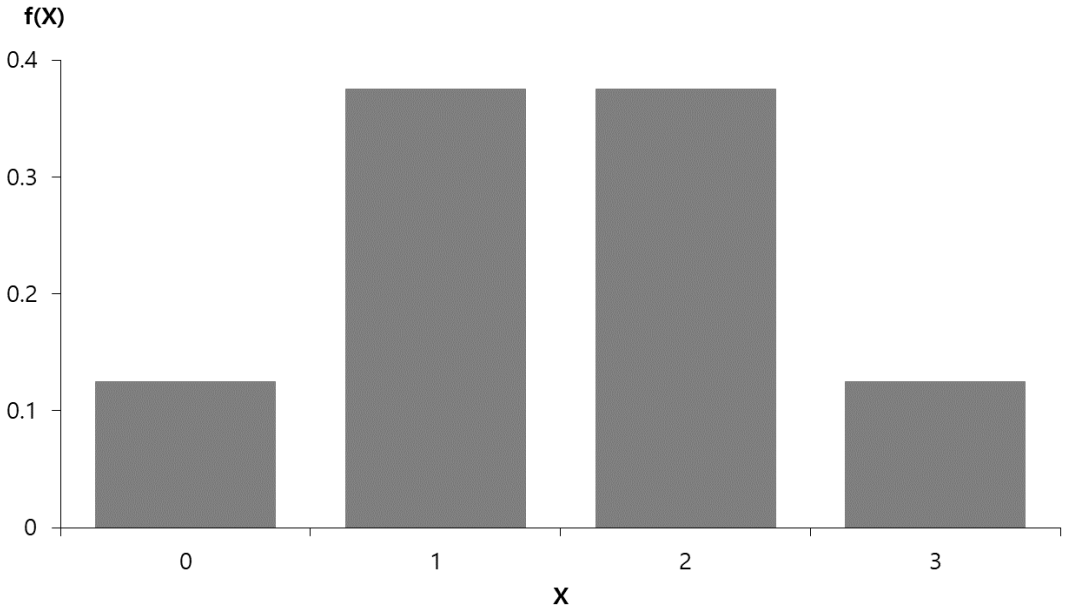

이항분포

- 엑셀에서 이 그림을 연습해보자.
- 먼저 n, x, p의 열을 준비하고, 조합은 COMBIN(n, x) 함수로 쉽게 계산하자.
- 각각의 시나리오 별로 베르누이 분포를 따르는 확률질량함수를 계산하자.

n	x	p	$f(x)$
3	0	0.5	=COMBIN(3,0)*(0.5^0)*(0.5^(3-0))
3	1	0.5	=COMBIN(3,1)*(0.5^1)*(0.5^(3-1))
3	2	0.5	=COMBIN(3,2)*(0.5^2)*(0.5^(3-2))
3	3	0.5	=COMBIN(3,3)*(0.5^3)*(0.5^(3-3))

이항분포

- 엑셀에서 이항분포를 따르는 확률질량함수를 계산할 때마다 매번 이렇게 공식을 사용해야 할까?
- 지금까지 숨겨서 미안하지만 사실 쉬운 함수가 있다. 그것은 BINOM.DIST(x, n, p, FALSE)이다.
- 다시 한 번 각각의 시나리오 별로 베르누이 분포를 따르는 확률질량함수를 계산하자.

n	x	p	$f(x)$
3	0	0.5	=BINOM.DIST(0, 3, 0.5, FALSE)
3	1	0.5	=BINOM.DIST(1, 3, 0.5, FALSE)
3	2	0.5	=BINOM.DIST(2, 3, 0.5, FALSE)
3	3	0.5	=BINOM.DIST(3, 3, 0.5, FALSE)

이항분포

예제 2. 동전을 열 번 던져서 앞면이 세 번 이하로 나올 확률을 구하시오.

이항분포

- 엑셀을 사용해 확률분포를 나타내는 표와 그래프를 그려보고 x에 따라 상이한 확률질량함수를 직접 계산해보자.
- 참고로 답은 $0.0009765625 + 0.009765625 + 0.043945313 + 0.1171875$ 이다.
- 그러나 더 쉽게 생각할 수도 있다. 바로 지난 주에 배운 누적분포함수(CDF)를 활용하는 것이다.
- 엑셀 함수가 BINOM.DIST(x, n, p, FALSE)라고 했는데 이때 FALSE 대신 TRUE를 입력하면 누적분포함수를 바로 계산할 수 있다.
- 다시 말해 답은 BINOM.DIST(3, 10, 0.5, TRUE)=0.171875 로 더 쉽게 계산할 수 있었던 셈이다.