사회통계
표집분포

김현우, PhD[1]

[1] 충북대학교 사회학과 조교수

April 15, 2022

진행 순서

1. 지난 주 리뷰
2. 표본의 추출
3. 표본평균의 표집분포
4. 표본비율의 표집분포

지난 주 리뷰

지난 주 리뷰

1. 지난 해 정부에서 발표한 용역연구 보고서에 따르면 공직자적성검사의 점수는 평균 72점과 표준편차 8점으로 정규분포한다고 알려졌다. 무작위로 뽑은 사람의 공직자적성검사 점수가 60점 이상일 확률은 얼마인가? (30점).

- 먼저 무엇과 관련된 주제인지 눈치채야 한다. 이것은 정규분포의 색칠공부에 관한 문제이다.
- 표준정규분포를 이용하기 위해 Z-점수를 다음과 같이 계산한다.

$$Z = \frac{X - \mu}{\sigma} = \frac{60 - 72}{8} = -1.5$$

- 곡선 아래 면적은 다음과 같이 구한다:

  1-NORM.DIST(-1.5, 0, 1, TRUE)

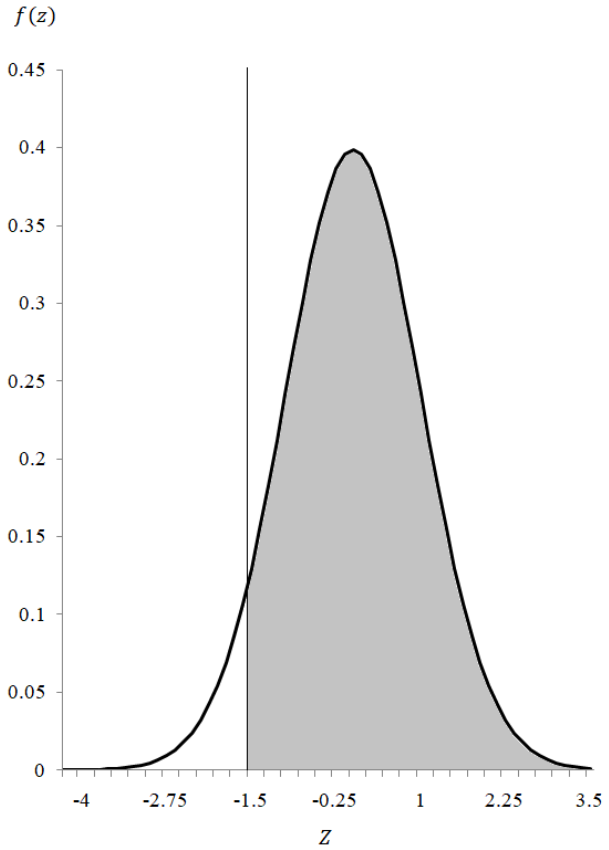

지난 주 리뷰

2. P국가의 국회의원 선거통계 자료집에 따르면, 선거구별 투표율의 평균은 65%였고 표준편차는 6%였다. 전문가에 따르면 투표율은 정규분포 한다고 알려졌다. 만일 무작위로 뽑은 한 지역의 투표율이 70% 이상 80% 미만일 확률은 얼마인가? (30점).

- 무엇을 묻고 있을까?

$$P(70 \leq X < 80) = P(X < 80) - P(X < 70)$$

- 투표율 80%과 70%의 Z-점수는 각각 다음과 같다.

$$Z_{80\%} = \frac{80 - 65}{6} = 2.5 \qquad Z_{70\%} = \frac{70 - 65}{6} = 0.83$$

- 무작위로 뽑은 한 지역의 투표율이 70% 이상 80% 미만일 확률은 20%이다.
  NORM.DIST(2.5, 0, 1, TRUE) - NORM.DIST(0.83, 0, 1, TRUE)=0.2

지난 주 리뷰

3. K시 지역통계에 따르면 해당 지역의 소규모 상가의 평균 임대료는 제곱미터당 12,000원이고 표준편차는 1,500원이며, 임대료는 정규분포를 따른다. 어느 부동산 중개인은 임대료의 상위 30%와 상위 10% 사이의 물건을 보고 싶어하는 어느 고객을 맞이하였다. 이 고객이 지불하게 될 임대료는 얼마와 얼마 사이인가? (40점).

- 상위 10%란 하위 90%와 같다. 확률이 주어졌을 때 Z-점수를 알고 싶으므로 NORM.INV(0.9, 0, 1)=1.282와 NORM.INV(0.7, 0, 1)=0.524를 사용한다.
- 이것들은 (임대료 원점수가 아니라) 아직 임대료 Z-점수이므로 각각 변환해야 한다.

$$Z_{80\%} \cdot \sigma + \mu = 1.282 \cdot 1500 + 12000 = 13922.3$$
$$Z_{70\%} \cdot \sigma + \mu = 0.524 \cdot 1500 + 12000 = 12786.6$$

- 즉 13,922원과 12,786원 사이 물건을 보여주어야 한다.
- 가장 흔하게 틀리는 유형은 NORM.INV(0.7, 0, 1) 대신에 NORM.INV(0.3, 0, 1)을 입력하는 경우이다. 이건 하위 30%! 애초에 이렇게 입력하면 아예 원점수가 (상위 기준으로 물어봤는데도) 평균보다 낮게 나온다(자신이 쓴 답에 대해 생각하자).

지난 주 리뷰

퀴즈 총평

- 문제를 푸는 논리적 순서를 철저하게 따르자. 그림을 그리는 순서, 식을 제시하는 순서를 꼼꼼히 따라한다.
- 특히 그림 그리기와 색칠공부를 생략하고 문제를 푸는 버릇은 몹시 좋지 않다.

표본의 추출

표본의 추출

일엽지추(一葉知秋)라는 고사성어가 있다.

- “뜰 안에 잎이 하나 떨어지는 것을 보아 온 천하에 가을이 왔음을 미루어 안다.” ≪회남자(淮南子)≫ 〈설산훈편(說山訓篇)〉
- 무언가를 알기 위해 (설령 전체를 모두 살펴보지 않아도) 부분을 통해 미루어 짐작할 수 있다.
- 지식의 획득에도 어느 정도 경제적 논리가 작동한다.

표본의 추출

모집단과 표본 그리고 모수와 통계량을 짝지어 이해하자.

- 순길은 인구 100만의 대도시 네오청주에서 의료기기 스타트업을 운영하고 있다. 그녀는 지금 시장조사를 위해 모든 네오청주 시민의 "(이완)혈압의 평균"을 알고 싶어 한다.
- 이때, 네오청주의 모든 시민은 모집단(population)이 된다.
- 일개 스타트업 사장인 순길 입장에서 모든 네오청주 전체 시민(=모집단)을 조사하기엔 시간과 비용을 감당할 수 없다.
- 대신 순길은 네오청주 전체 시민 중 일부만을 임의(random)로 골라 표본(sample)을 싼값으로 추출할 수 있다.

표본의 추출

- 이때 모든 네오청주 시민의 "혈압의 평균"은 모수(parameter)가 된다. 모수인 "혈압의 평균"은 그 값을 알 수 없지만 상수(constant)이다. 왜냐하면 답은 이미 정해져 있기 때문이다.
- 순길의 표본에서 얻은 네오청주 시민의 "혈압의 평균"은 통계량(statistic)이 된다. 통계량은 (상수가 아니라) 그 값이 모집단으로부터 임의로 추출된 표본(sample)에 따라 그때그때 달라지는 확률변수(random variable)이다.

표본의 추출

- 모수는 상수이다! 다만 모를 뿐이다.
- 통계량은 알 수 있다! 다만 (그때그때 표본에 따라 달라지는) 확률변수일 뿐이다.

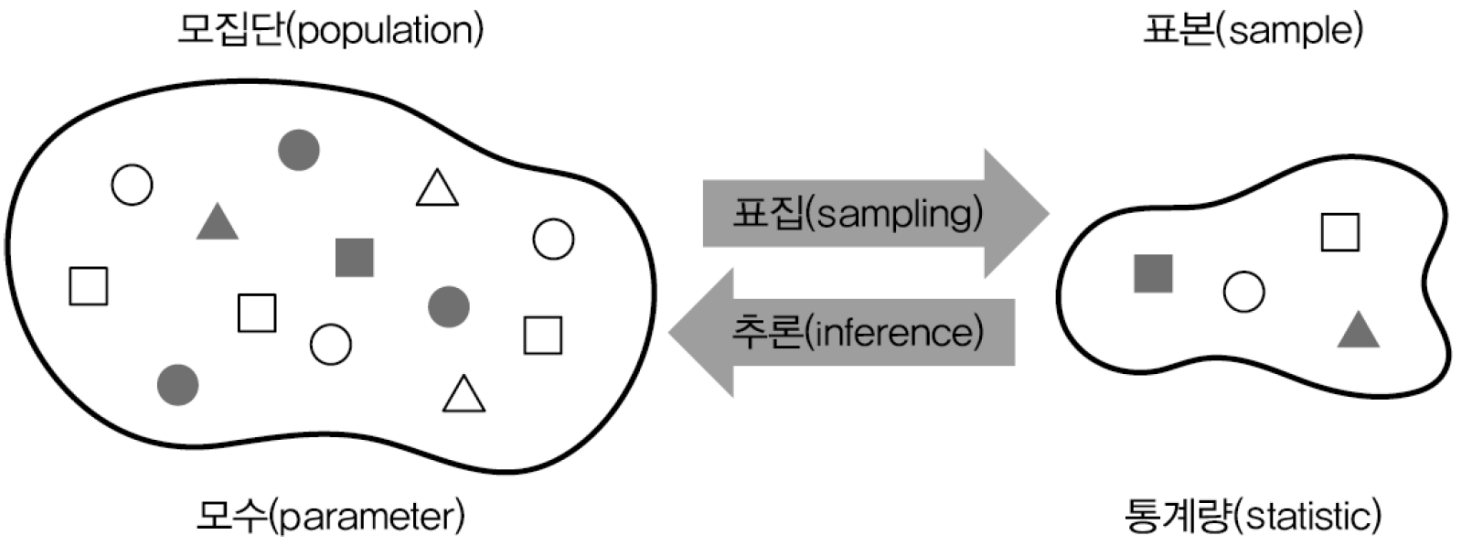

표본의 추출

표집이란 표본의 추출을 의미한다.

- 순길은 네오청주에 사는 시민 30명을 임의표집(random sampling)하였다.
- 그 30명의 혈압을 조사하여 "표본(sample)의 평균(mean)"을 계산해 보았더니 67 mmHg라는 평균값을 얻었다.
- 이때 67 mmHg라는 추정값(estimate)은 순길이 붙잡은 네오청주 시민의 "한 표본(a sample)"으로부터 얻은 값에 지나지 않는다.
- 다시 말해, 표본을 새로 뽑으면 그때그때 달라질 수 밖에 없는 값이다(Why?).
- 사실 표집은 그 자체로 상당히 까다로운 테크닉이다. 내년 사회조사방법론(Social Research Methodology)에서 아주 약간 배운다. 서베이 방법론(Survey Methodology)에서 이 분야를 깊게 다루지만 우리 학과에서는 이 수업이 개설되지 않는다.

표본평균의 표집분포

표본평균의 표집분포

"너의 표본은..."

- 순길과 같은 동네에서 의료기기 가게를 운영하는 경쟁자인 유민과 정환은 네오청주에서 각자 새로운 30명의 표본을 뽑아 각각 75mmHg라는 값과 71.3mmHg라는 값을 얻었다.
- 상식적으로 생각해서 인구 100만의 네오청주에서 30명짜리 표본을 세 번 뽑았을 때, 그 표본의 평균들이 정확히 똑같을리가 없다. 그러면 대체 셋 중 누구의 추정이 정확한가?
- 애시당초 "표본의 통계량"을 통해서는 결코 "모집단의 모수"를 알 수 있기는 한 것일까?
- 다행히 이 문제에 대한 이론적인 답이 있고, 그에 따르면 대답은 "Yes!"이다.

표본평균의 표집분포

이제 어떻게 표본을 통해 모집단을 추정할 수 있는지 상상해보자.

- 나에게 $\{1, 4, 13\}$이라는 모집단이 주어져 있고, 이 모집단에서 $n = 3$인 표본을 뽑는다고 상상해보자.
- 이때 (있을 수 있는) 모든 표본들의 조합은 아래와 같다(직접 만들어보자).

표본	$\bar{x}$	$P(\bar{X} = \bar{x})$	표본	$\bar{x}$	$P(\bar{X} = \bar{x})$	표본	$\bar{x}$	$P(\bar{X} = \bar{x})$
$\{1, 1, 1\}$	1	1/27	$\{4, 1, 1\}$	2	1/27	$\{13, 1, 1\}$	5	1/27
$\{1, 1, 4\}$	2	1/27	$\{4, 1, 4\}$	3	1/27	$\{13, 1, 4\}$	6	1/27
$\{1, 1, 13\}$	5	1/27	$\{4, 1, 13\}$	6	1/27	$\{13, 1, 13\}$	9	1/27
$\{1, 4, 1\}$	2	1/27	$\{4, 4, 1\}$	3	1/27	$\{13, 4, 1\}$	6	1/27
$\{1, 4, 4\}$	3	1/27	$\{4, 4, 4\}$	4	1/27	$\{13, 4, 4\}$	7	1/27
$\{1, 4, 13\}$	6	1/27	$\{4, 4, 13\}$	7	1/27	$\{13, 4, 13\}$	10	1/27
$\{1, 13, 1\}$	5	1/27	$\{4, 13, 1\}$	6	1/27	$\{13, 13, 1\}$	9	1/27
$\{1, 13, 4\}$	6	1/27	$\{4, 13, 4\}$	7	1/27	$\{13, 13, 4\}$	10	1/27
$\{1, 13, 13\}$	9	1/27	$\{4, 13, 13\}$	10	1/27	$\{13, 13, 13\}$	13	1/27

표본평균의 표집분포

- 각 표본들의 평균을 표본평균(sample mean)이라고 부른다. 이것을 확률변수 $\bar{X}$로 생각하여 확률분포를 표현해보자.
- 이런 확률분포를 표본평균의 표집분포(sampling distribution of the sample mean)라고 부르고, 특별히 표집분포(sampling distribution)라고 줄여 말한다.

$\bar{x}$	$P(\bar{X} = \bar{x})$
1	1/27
2	3/27
3	3/27
4	1/27
5	3/27
6	6/27
7	3/27
9	3/27
10	3/27
13	1/27

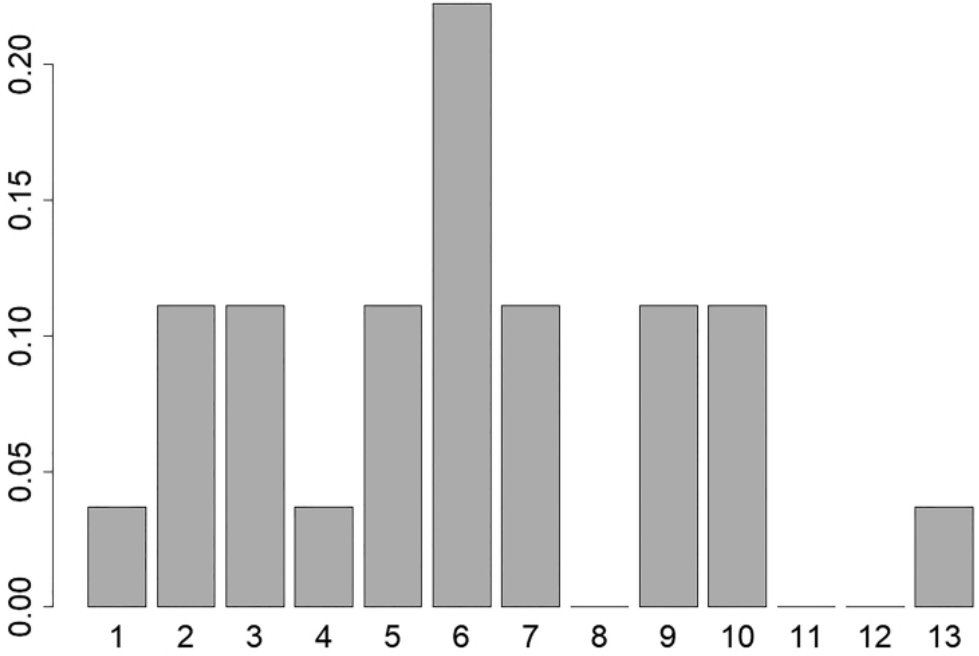

표본평균의 표집분포

예제 1. 모집단 {1, 4, 13}이 주어졌을 때, 모든 표본평균을 확률분포로 나타낼 수 있다. 이 확률분포의 평균과 분산을 구하시오.

표본평균의 표집분포

- 표본평균의 확률분포, 즉 표집분포의 평균은 6이고 분산은 8.667이므로 표준편차는 2.944이다.

$\bar{x}$	$P(\bar{X}=\bar{x})$	$\bar{x}\cdot P(\bar{X}=\bar{x})$	$(\bar{x}-\mu)^2\cdot P(\bar{X}=\bar{x})$
1	0.037	0.037	0.926
2	0.111	0.222	1.778
3	0.111	0.333	1.000
4	0.037	0.148	0.148
5	0.111	0.556	0.111
6	0.222	1.333	0.000
7	0.111	0.778	0.111
9	0.111	1.000	1.000
10	0.111	1.111	1.778
13	0.037	0.481	1.815
	합계	6	8.667

표본평균의 표집분포

- 여기서 멈추지 말고 좀 더 생각해보자. 일반적인 상황과는 달리 이 예제에서 우리는 모집단을 알고 있다. 우리의 모집단은 {1, 4, 13}이다.
- 모집단의 평균, 즉 모평균(population mean)와 모집단의 분산, 즉 모분산(population variance)을 쉽게 계산할 수 있다.

$$\mu = 6, \quad \sigma^2 = 26$$

- 이제 다음의 두 가지 흥미로운 사실을 확인할 수 있다.

(1) 표집분포의 평균은 모평균과 같다.

$$\mu_{\bar{X}} = \mu$$

(2) 모분산을 표본 크기로 나눈 값은 표집분포의 분산과 같다.

$$\sigma^2_{\bar{X}} = \frac{\sigma^2}{n}$$

표본평균의 표집분포

이것은 우연이 아니다.

- 100만 명이 거주하는 네오청주에서도 30명 짜리 표본을 무한히 뽑아 각각 평균을 내보자.
- 이게 무슨 말일까? 세 가지 중요한 요소가 있다.
- (1) 똑같은 크기(e.g., 30명)의 표본을 추출하고, 또 추출하고, ..., 또 추출한다.
- (2) 첫번째 표본에서 평균(a sample mean)을 구하고, 두번째 표본에서 평균(a sample mean)을 구하고, ..., n번째 표본에서 평균(a sample mean)을 구한다.
- (3) 이 짓을 "무한히" 반복한다.
- 이 무한히 많은 표본평균들을 확률변수 $\bar{X}$로 판단하여 (1) 표집분포의 평균을 구하면 정확히 μ와 일치하고,(1) 표집분포의 분산을 구하면 정확히 σ^2/n과 일치한다.

표본평균의 표집분포

표집분포에는 두 가지 중요한 특징이 있다.

- 각각의 표본이 $n \geq 30$라는 조건을 충족한다고 전제하자.
- 우리에게 주어진 무한히 많은 표본평균들을 가지고, 이 표본평균들(sample means)의 평균(mean)을 계산할 수 있다. 말하자면 이것은 "평균들의 평균"이다.
- 그런데 이 표본평균들의 평균은 모집단의 평균(population mean)에 무한히 근접한다(=일치한다).

$$\mu_{\bar{X}} = E(\bar{X}) = \mu$$

표본평균의 표집분포

- 우리에게 주어진 무한히 많은 표본평균들을 가지고, 이 표본평균들(sample means)의 분산(variance)도 계산할 수 있다. 말하자면 이는 평균들의 분산이다.
- 이 표본평균들의 분산은 모집단의 분산을 표본 크기(여기서는 N=100)로 나눈 값에 무한히 근접한다(=일치한다)는 것이 증명될 수 있다.

$$\sigma_{\bar{X}}^2 = Var(\bar{X}) = \frac{\sigma^2}{n}$$

- 이 표본평균들의 표준편차(standard deviation)를 특별히 표준오차(standard error)라고 부른다.

$$\sigma_{\bar{X}} = \frac{\sigma}{\sqrt{n}}$$

표본평균의 표집분포

그리고 여기 통계학사상 가장 위대한 발견이 있다.

- 모집단의 분포가 "어떤 꼴이든 상관없이"
- 표본 크기(sample size)가 충분히 크면($n \geq 30$)
- 표집분포(sampling distribution), 즉 표본평균들의 확률분포는
- 평균이 μ이고 분산이 σ^2/n인 정규분포에
- 근사한다(approximate).
- 이것이 바로 중심극한정리(central limit theorem)이다.

표본평균의 표집분포

왜 그토록 위대한가?

- "모집단의 분포가 어떻게 생겼든 상관없이" 그것의 (무한히 많은) 표본($n \geq 30$)의 평균들은 반드시 정규분포함을 증명해 보였기 때문이다.
- 다시 말해, 정규분포에 관한 성질을 가지고 "모든" 표본평균들의 분포를 설명할 수 있다. 그게 무엇에 관한 모집단이건간에!
- 교과서 중에는 "모집단(population)이 정규분포인가 정규분포가 아닌가"를 구태여 나누어 설명하는 경우도 있다. 그런 것은 표본 크기가 $n \geq 30$만 넘어도 중심극한정리 덕택에 사실 아무런 의미도 없다.

표본비율의 표집분포

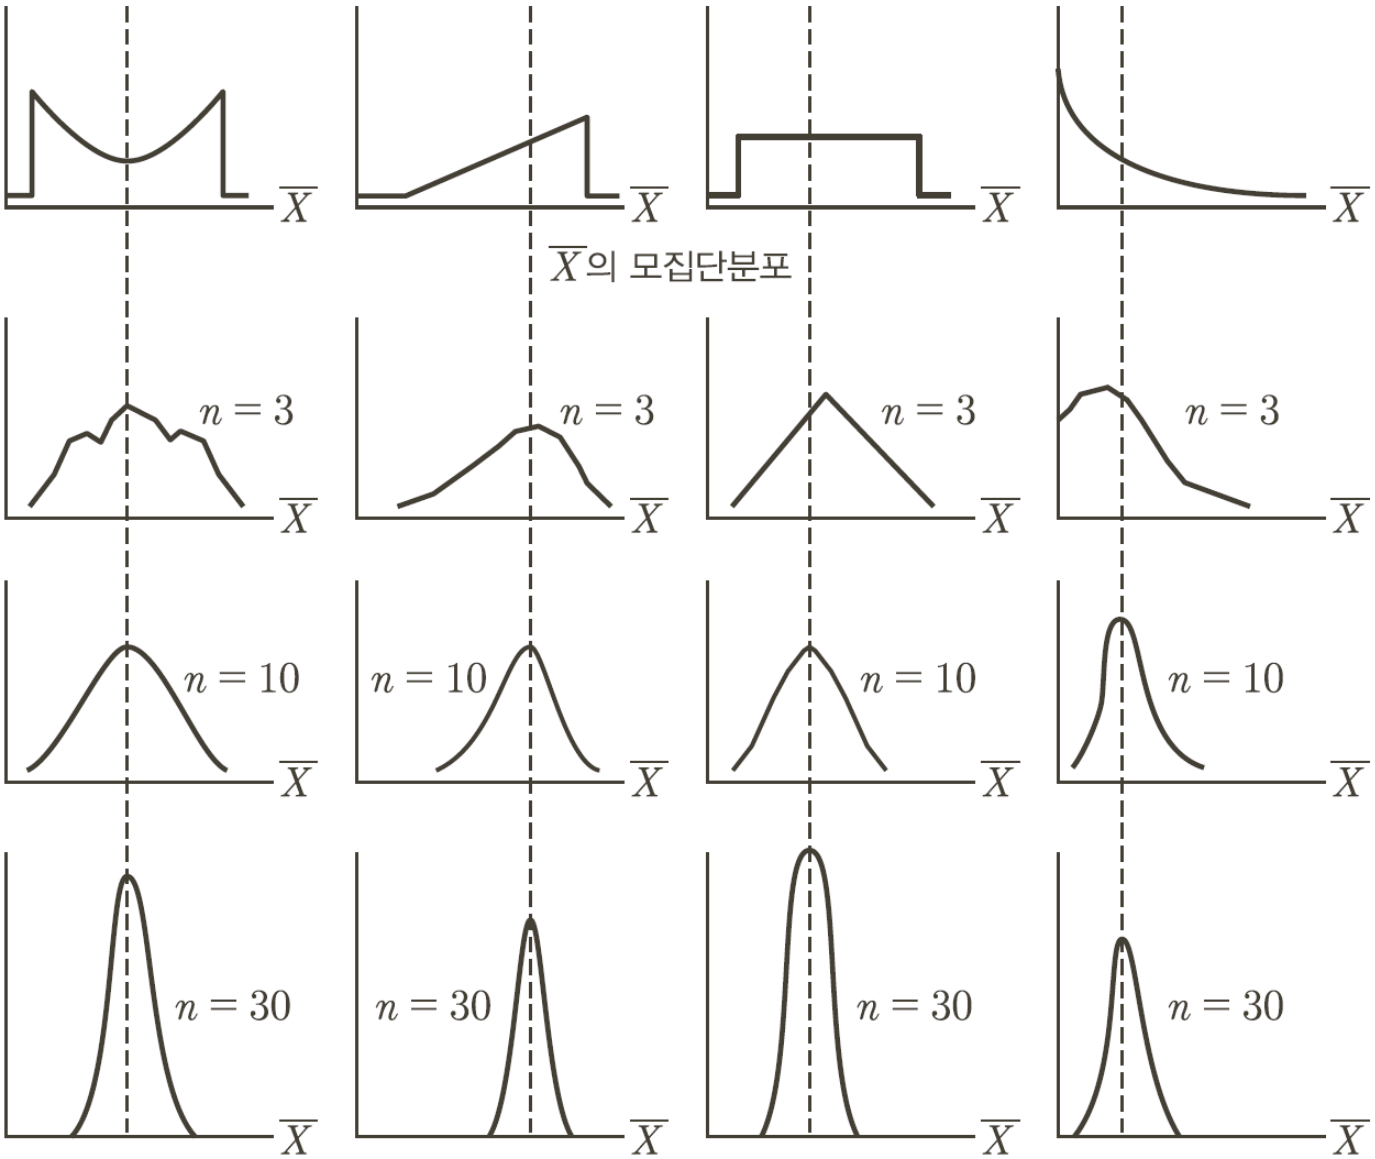

표본평균의 표집분포

예제 2. 정부의 최근 발표에 따르면 네오청주의 대학생은 평균적으로 28,650 천원의 학자금 대출 부채를 가지고 졸업한다. 그 표준편차는 7,000 천원인데, 최근 자산소득 양극화로 인해 정규분포하지 않는다. 세휘는 기말과제를 수행하기 위해 네오청주에서 임의의 대학생 30명에게 학자금 대출액을 조사하였다. 세휘의 표본에서 계산한 부채의 평균이 27,000 천원보다 클 확률은 얼마인가?

표본평균의 표집분포

- (학자금 대출액의 모집단은 정규분포하지 않을지라도) 세휘의 표집분포는 $n \geq 30$ 조건을 충족하므로 정규분포에 근사한다.
- 세휘의 표본에서 부채 평균이 27,000 천원보다 클 확률을 먼저 표현해보자.

$$P(\bar{X} > 27000) = P\left(Z > \frac{27000 - \mu_{\bar{X}}}{\sigma_{\bar{X}}}\right)$$

- 지난 주에 $Z = \dfrac{X - \mu}{\sigma}$ 였지만 지금은 $Z = \dfrac{\bar{X} - \mu_{\bar{X}}}{\sigma_{\bar{X}}} = \dfrac{\bar{X} - \mu_{\bar{X}}}{\sigma/\sqrt{n}}$ 이다(Why?).

표본평균의 표집분포

- 모르는 부분을 채워넣기 위해 이 표집분포의 평균 $\mu_{\bar{X}}$ 과 표준오차 $\sigma_{\bar{X}}$ 를 구해야 한다.

$$\mu_{\bar{X}} = 28,650 \qquad \sigma_{\bar{X}} = \frac{7000}{\sqrt{30}}$$

- 세휘의 표본에서 30명의 부채 평균이 27,000 천원보다 클 확률은 얼마인가?

$$P(\bar{X} > 27000) = P\left(Z > \frac{27000 - 28650}{7000/\sqrt{30}}\right) = 1 - P(Z < -1.29) = 0.90$$

- 세휘의 표본평균이 27,000 천원보다 클 확률은 90%이다.

표본비율의 표집분포

표본비율의 표집분포

아까는 표본평균을 살펴보았지만 이번엔 표본비율을 살펴보자.

- 아까 표본평균을 했는데 왜 표본비율(sample proportion)은 또 할까?
- 평균은 양적 변수(quantitative variable)일 때만 의미를 갖는다. 예컨대 키, 몸무게는 평균이 의미있지만, 질적 변수(qualitative variable)일 때, 가령 성별(1=여성; 0=남성)이나 종교(1=기독교; 2=불교; 3=기타; 0=없음) 등의 평균에는 의미가 없다.
- 반면 비율(proportion)은 질적 변수일 때만 의미를 갖는다. 예컨대 여성의 비율, 기독교의 비율은 의미를 갖는다. 키의 비율이나 몸무게의 비율이라는 말은 어감부터 뭔가 이상하다.
- 표본평균은 정규분포와 관련되어 있으나, 표본비율은 이항분포(binomial distribution)와 관련되어 있다.

표본비율의 표집분포

다행히 비율의 표집분포 논리도 결국 똑같다!

- 먼저 표본비율은 (확률의 고전적 정의와 마찬가지로) 아래처럼 정의된다. 이때, X는 표본에서 (관심있는 사건의) 성공 횟수이고 n은 표본 크기이다.

$$\frac{X}{n}$$

- 무한히 많은 표본을 뽑아 그 비율들을 확률변수 p로 하는 확률분포를 상상해보자. 이를 표본비율의 표집분포(sampling distribution of the sample proportion)라고 부르고, 이것도 표집분포라고 줄여 부를 수 있다.

표본비율의 표집분포

위대한 중심극한정리는 여기서도 적용된다.

- (무한히 많이 뽑은) 표본비율의 표집분포의 평균 μ_p는 모집단의 비율(population proportion), 즉 모비율의 평균 π에 무한히 근접한다(=일치한다).

$$\mu_p = E(p) = \pi$$

표본비율의 표집분포

- 우리에게 주어진 무한히 많은 표본비율들의 분산(variance)은 모집단의 분산을 "표본 크기의 제곱"으로 나눈 값에 무한히 근접한다(=일치한다).

$$\sigma_p^2 = Var(p) = Var\left(\frac{X}{n}\right) = \frac{n\pi(1-\pi)}{n^2} = \frac{\pi(1-\pi)}{n}$$

- 이때 은근슬쩍 제5주차에 배운 확률변수의 분산 특성과 제6주차에 배운 이항분포의 분산을 이용하였다.

$$Var(aX) = a^2 Var(X)$$
$$Var(X) = \pi(1-\pi)$$

- 이 표본비율들의 표준편차(standard deviation)도 표준오차(standard error)라고 부른다.

$$\sigma_p = \sqrt{\frac{\pi(1-\pi)}{n}}$$

표본비율의 표집분포

다만 표본비율의 표집분포에서 중심극한정리의 성립 조건은 살짝 다르다.

- 표본평균의 표집분포의 경우 각각의 표본이 $n \geq 30$라는 조건을 요구하였다.
- 표본비율의 표집분포의 경우 표본 크기 n 뿐 아니라 표본비율 π도 고려해야 한다. 보다 구체적으로 다음의 두 조건이 성립해야 중심극한정리가 성립한다.

$$np \geq 5 \qquad n(1-p) \geq 5$$

- 다시 말해, 발생 확률이 너무 희박하거나 반대로 너무 흔하면 정규분포를 사용하기 위해 표본 크기가 엄청 커져야 한다.

표본비율의 표집분포

예제 3. 네오청주에 HQ를 두고 있는 IT기업들의 55%가 작년에 사이버 공격을 당했다고 한다. 그게 정말일까 하고 궁금했던 희정은 네오청주 시내 IT기업 30곳을 임의로 방문해 사이버 공격을 당했는지 여부를 조사하였다. 희정의 표본에서 사이버 공격을 당했다고 응답한 비율이 70%보다 클 확률은 얼마인가?

표본비율의 표집분포

- 희정이 구하고자 하는 확률을 어떻게 표현할 수 있을지 먼저 생각해보자.

$$P(p > 0.7) = P\left(Z > \frac{0.7 - \pi}{\sqrt{\pi(1-\pi)/n}}\right)$$

- 지난 주에 $Z = \dfrac{X - \mu}{\sigma}$ 였지만 지금은 $Z = \dfrac{p - \pi}{\sigma_p} = \dfrac{p - \pi}{\sqrt{\pi(1-\pi)/n}}$ 이다(Why?).
- 아래의 조건에 따라 사이버 공격을 당했던 비율의 표집분포는 정규분포할 것이다.

$$np = 30 \cdot 0.7 = 21 \qquad n(1-p) = 30 \cdot (1 - 0.7) = 9$$

표본평균의 표집분포

- 모르는 부분을 채워넣기 위해 이 표집분포의 평균 π과 표준오차 σ_p를 구해야 한다.

$$\pi = E(p) = 0.55 \qquad \sigma_p = \sqrt{\frac{.55(1-.55)}{30}}$$

- 희정의 표본에서 사이버 공격을 당했다고 응답한 비율이 70%보다 클 확률은 얼마인가?

$$P(p > 0.7) = P\left(Z > \frac{0.7 - 0.55}{\sqrt{0.55(1-0.55)/30}}\right) = 1 - P(Z < 1.65) = 0.049$$

- 희정의 구한 표본에서 사이버 공격을 당했다고 응답할 비율이 0.7 이상으로 나올 확률은 약 4.9% 이다.