사회통계
통계적 추정

김현우, PhD[1]

[1] 충북대학교 사회학과 조교수

April 15, 2022

진행 순서

1. 신뢰구간과 오차범위
2. 모평균의 신뢰구간
3. 모비율의 신뢰구간

신뢰구간과 오차범위

신뢰구간과 오차범위

아까 배운 표집분포의 이론은 현실 통계분석의 목적과는 동떨어져 있다.

- 표집분포의 이론은 일단 모집단의 평균 μ와 표준편차 σ를 안다고 전제하고 있었다.
- "A학교 전교생의 IQ 점수분포가 $\mu = 105$, $\sigma = 15$일 때, 25명을 임의표집하여 평균을 구하여 108 이상으로 나올 확률은 얼마인가?"

$$P(\bar{X}) = P\left(Z > \frac{108 - 105}{15/\sqrt{25}}\right) = 1 - P(Z < 1) = 0.159$$

- 그럴 확률은 15.9%에 불과하다.

신뢰구간과 오차범위

- 그런데 가만 생각해보면 이건 완전 웃긴 이야기다!
- "이미 모집단의 평균(μ)과 표준편차(σ) 같은 걸 다 아는데 뭐하러 표본을 새로 수집하나?"
- "아니, 그건 좋다구 치자. 표본을 무한히 뽑는다니 미친거 아냐? 차라리 모집단을 전수 조사하고 말지!"
- 현실의 통계분석에서는 오히려 "반대로" 표본에 근거해 바로 그 모집단의 μ와 σ를 추론(inference)해야 할 필요가 있다.

신뢰구간과 오차범위

표본으로부터 모집단의 성격을 추론하는 방식에는 두 가지가 있다.

- 하나는 오늘 배울 추정(estimation)이고, 다른 하나는 그 다음에 배울 가설검정(hypothesis test)이다.
- 다시 추정(estimation)은 점추정(point estimation)과 구간추정(interval estimation)으로 나뉜다.

신뢰구간과 오차범위

먼저 추정에 관한 기초적인 용어를 살펴보자.

- 맥주병 회사에서 일하는 헌서는 제조된 병 가운데 30개의 임의표본(random sample)에서 평균값을 확인해 보았다.
  "음, 병 하나당 용량 평균은 330ml로군."
- 이를 들은 성민이 캐물었다.
  "확실해?"
- 쫄린 헌서는 얼버무렸다.
  "아니, 꼭 그렇진 않고... 내 표본에서 표준오차가 10ml이니 90% 신뢰구간은 313.6ml에서 346.4ml 사이야."

신뢰구간과 오차범위

- (처음에 헌서가 그러했듯) 표본의 평균인 330ml를 가지고 모집단 평균을 예측했다면, (그래프 상에 점을 찍듯) 하나의 숫자로 구한 값이므로 점추정값(point estimate)이다.
- 나중에 헌서가 "313.6ml에서 346.4ml 사이"라고 말한 것은 구간추정값(interval estimate)이 된다.
- 90% 신뢰구간(confidence interval; CI)은 구간추정값의 신뢰할 수 있는 폭에 관한 것이다.
- 추정값(estimate)이란 추정된 구체적인 값이고, 추정값(estimate)을 구하는데 사용되는 통계량(statistic)을 추정량(estimator)이라고 부른다.
- 앞서 헌서와 성민의 대화에서 330ml라는 구체적인 수치는 추정값(estimate)이고, 병에 담긴 용량의 표본평균(sample mean)이라는 확률변수가 곧 추정량(estimator)이다.

신뢰구간과 오차범위

대체 어떻게 헌서는 점추정값을 제시할 수 있었나?

- 중심극한정리를 통해 (모집단의 분포와 무관하게) 표본 크기만 충분히 크면 다음이 성립함을 알 수 있다.

$$\mu_{\bar{X}} = \mu \qquad \sigma_{\bar{X}} = \frac{\sigma}{\sqrt{n}}$$

- 그런데 표집분포이론을 거꾸로 생각해보면, (1) 설령 모평균 μ에 대한 정보가 사전에 주어지지 않았고, (2) 표본을 무한히 뽑지 않았더라도,
- 내가 지금 가지고 있는 하나의 표본로부터 얻은 평균값(a sample mean)은 (굳이 어느 쪽인가 하면) μ를 반영하고 있을 가능성이 제일 높다!
- 다시 말해, 임의표본을 한 번만 뽑고 거기서 평균을 구해 $\bar{x}$를 얻었다면 일단 이것이 모평균에 대한 최선의 추정량(best estimator)인 것이다!

신뢰구간과 오차범위

- 만약 헌서가 무한히 표집(단 $n \geq 30$)하여 그 표본평균들의 확률분포를 구해보면 다음 점선과 같을 것이다.
- 그렇기에 만일 하나의 표본평균을 구한 뒤, 그것이 표집분포 위의 어디에 위치할 것인지 딱 한군데만 판돈을 건다면 μ 일 것이라고 추측하는 것이 합리적이다(Why?).

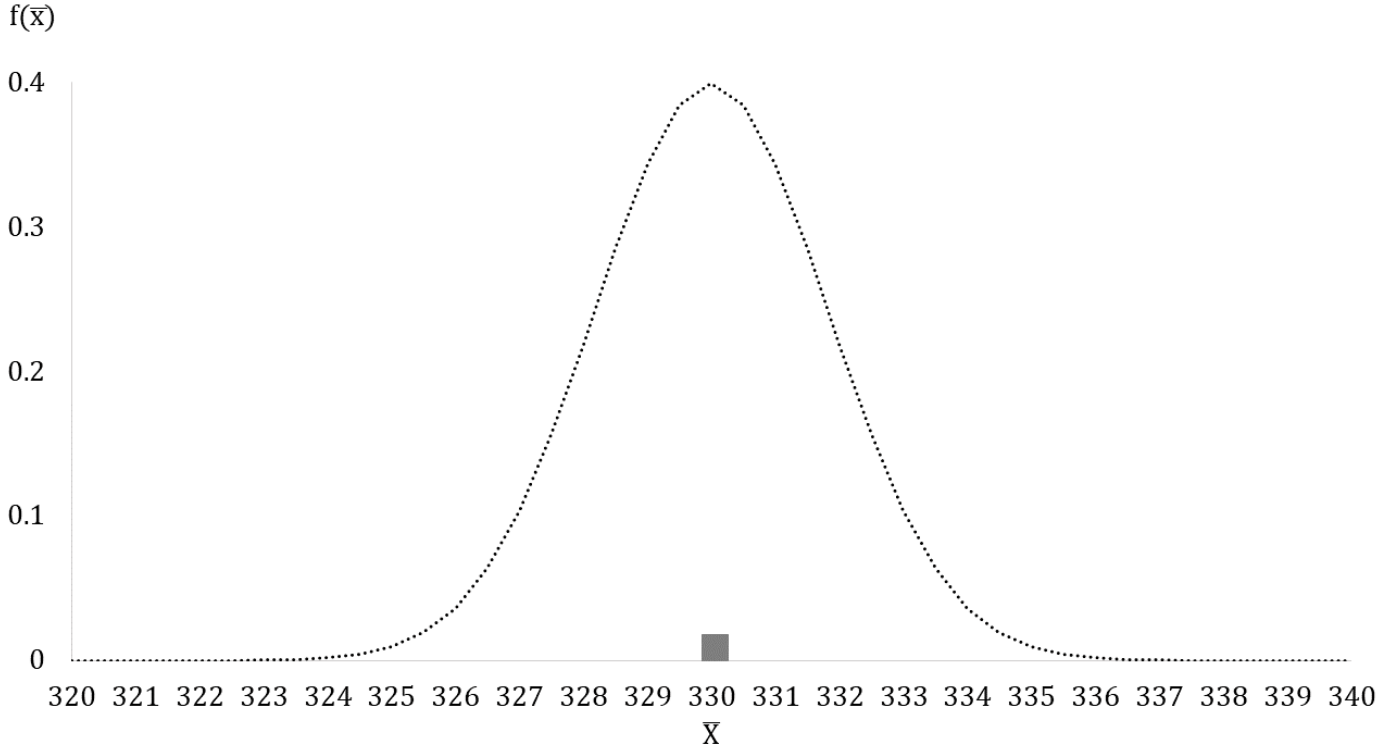

신뢰구간과 오차범위

90% 신뢰구간 같은 건 어떻게 계산할 수 있나?

- 근데 그림을 다시 잘보면, 나의 표본 평균에서 아주 조금만 옆으로 이동해도 그쪽이 모평균일 확률도 제법 높긴 하다. 아무래도 전재산을 걸기엔 좀 틀릴까봐 겁난다.
- 그러니 확률이 높은 순서대로 90%의 면적을 채워나가 보면 어떨까?
- 확률이 높은 쪽은 가운데에 몰려있으니 양 끄트머리를 빼고 90%를 채우는 것이 상식적이다(Why?).
- 정규분포를 직접 그려보고 색칠 공부를 해보자. 90% 구간의 좌우 끄트머리는 각각 몇 %인지도 생각해보자.
- 그 안에 포함되는 $\bar{x}$값들이 바로 90% 신뢰구간이다.

신뢰구간과 오차범위

- 이렇게 양 끄트머리 5%씩을 빼고 가운데 90%의 면적을 계산하는 것이라면 이미 지난 주에 엑셀을 통해 배워 할 수 있다.
- 이제 모집단에서 계산된 평균 μ와 표준편차 σ가 아니라, 표본평균 $\mu_{\bar{X}}$와 표준오차 $\sigma_{\bar{X}}$를 가지고 Z-점수로 표준화하자.

$$Z = \frac{\bar{X} - \mu_{\bar{X}}}{\sigma_{\bar{X}}}$$

- 확률을 주고 Z-점수를 받는 엑셀 함수는 NORM.INV(·) 함수임을 배웠다.
- NORM.INV(0.95, 0, 1)로 오른쪽 끄트머리 경계 Z-점수를,
  NORM.INV(0.05, 0, 1)로 왼쪽 끄트머리 경계 Z-점수를 구할 수 있다(Why?).

신뢰구간과 오차범위

- 엑셀에서 실제로 NORM.INV(0.95, 0, 1)와 NORM.INV(0.05, 0, 1)를 구해보면 각각 1.64와 -1.64가 나온다.
- 물론 이 값들은 표준화된 Z-점수이므로 직관적으로 해석이 안된다. 다시 원점수로 돌리는 방법도 지난 주에 배웠다

$$X = Z \cdot \sigma_{\bar{X}} + \mu_{\bar{X}}$$

- 그러므로 헌서가 말한 90% 신뢰구간은 다음과 같다.

$$\begin{aligned}
&[Z_{0.05} \cdot \sigma_{\bar{X}} + \mu_{\bar{X}},\ Z_{0.95} \cdot \sigma_{\bar{X}} + \mu_{\bar{X}}] \\
=&[-1.64 \cdot 10 + 330,\ 1.64 \cdot 10 + 330] \\
=&[313.6,\ 346.4]
\end{aligned}$$

신뢰구간과 오차범위

90% 신뢰구간은 어떻게 해석해야 할까?

- "표본평균을 무한히 많이 계산했다면 각각의 90% 신뢰구간들(confidence intervals)도 무한히 많이 구할 수 있다. 이 모든 신뢰구간들의 90%는 모평균인 330을 포함하고 있다."
  → 이것이 신뢰구간의 올바른 해석이다.
- "[313.6, 346.4] 사이에 모집단의 평균이 놓일 확률이 90%이다."
  → 이것은 신뢰구간의 잘못된 해석이다.

신뢰구간과 오차범위

두번째 해석은 왜 틀릴까?

- 그것은 모평균 μ는 알려지지 않았을 뿐, 상수(constant)이기 때문이다. 이것은 확률변수가 아니다.
- 오히려 확률변수인 쪽은 표본평균이므로 표집마다 매번 달라지는 것은 신뢰구간이다.
- 따라서 해석할 때 "기준이 되는 쪽"은 당연히 모평균 μ이고, 90%로 이를 맞출 수 있는 것은 신뢰구간들이다.
- 다시 말해, 모평균은 확률을 가질 수 없고 신뢰구간만이 확률을 갖는다.

신뢰구간과 오차범위

개념을 이해했다면 이제 수식으로도 나타낼 수 있다.

- 90% 신뢰구간은 다음과 같이 수학적으로 표현할 수 있다:

$$P(Z_{0.05} \cdot \sigma_{\bar{X}} + \bar{X} \leq \mu \leq Z_{0.95} \cdot \sigma_{\bar{X}} + \bar{X}) = .90$$

- 신뢰구간을 나타낼 때 해석과 일치시키기 위해서 반드시 기준점을 $\bar{X}$가 아닌 μ 로 삼아야 한다!
- 이때, 90%라는 기준을 신뢰수준(confidence level)이라고 부른다. 또 90% 말고 95%나 99% 등 다양한 신뢰수준을 사용할 수도 있다.
- 위에서 $\pm Z \cdot \sigma_{\bar{X}}$ 부분을 특별히 오차범위(margin of error)라고 부른다.

신뢰구간과 오차범위

- 점추정치, 신뢰구간, 오차범위 등 표현이 다소 혼동스러울 수 있으므로 주의깊게 공부하자.

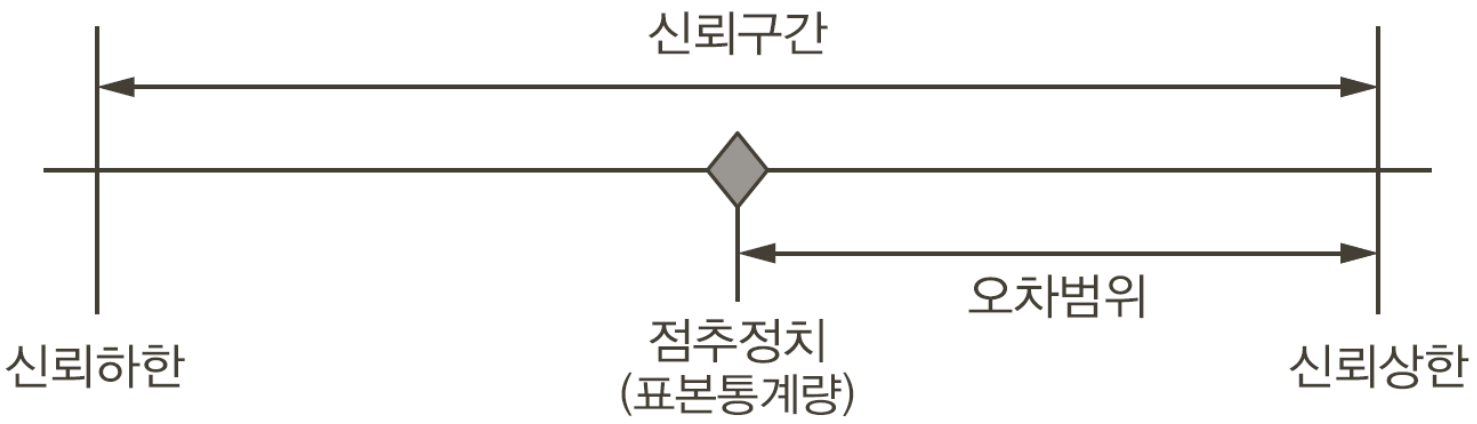

신뢰구간과 오차범위

놓치기 쉬운 부분은 우리가 지금 의사결정의 오류를 다루고 있다는 사실이다.

- 우리는 현실적으로 모집단 μ를 모른다. 표본을 무한히 뽑을 수도 없다. 그래서 하는 수 없이 표본을 한 번만 추출해서 $\mu_{\bar{X}}$를 계산했다. 과연 그 $\mu_{\bar{X}}$는 얼마나 믿을만 한가?
- 애초에 신뢰구간 추정의 목적은 "표본에서의 계산된 우리의 통계량(statistic) $\mu_{\bar{X}}$가 얼마나 믿을만한가(reliable)?"를 파악하는데 있는 셈이다.

신뢰구간과 오차범위

- $\sigma_{\bar{X}}$ 가 작다면 우리의 표본은 $\mu_{\bar{X}}$ 을 중심으로 아주 밀집되어 있다는 의미이므로, $\mu_{\bar{X}}$ 는 꽤 믿을만 할 것이며, 90% 신뢰구간도 좁을 것이다.
- $\sigma_{\bar{X}}$ 가 크다면 우리의 표본이 $\mu_{\bar{X}}$ 가 아닌 여러 값들로 퍼져있다는 의미이므로, $\mu_{\bar{X}}$ 는 믿기 어려울 것이며, 90% 신뢰구간도 넓을 것이다.
- 각각의 상황에 따른 가상의 표집분포를 그리고 색칠 공부도 해보자!
- 다시 말해, 표준오차 $\sigma_{\bar{X}}$ 는 표본평균(sample means)을 이용하여 의사결정을 할 때 예상되는 오류의 크기를 나타낸다.

모평균의 신뢰구간

모평균의 신뢰구간

지금까지 공부한 내용이 사실 모평균의 신뢰구간의 핵심이다.

- 모평균의 신뢰구간(confidence intervals for the population mean)은 구체적인 조건에 따라 접근방법이 살짝 달라진다.

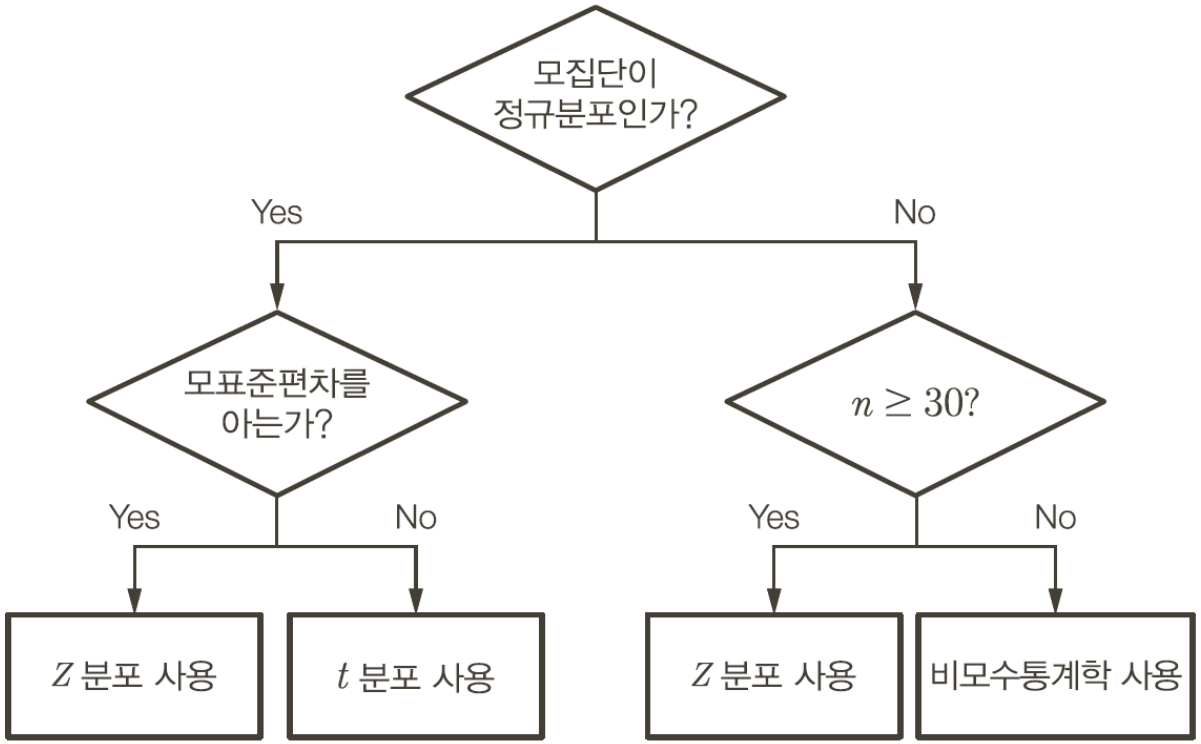

모평균의 신뢰구간

예제 4. 네오청주의 장학사인 예진은 모교인 C대학에서 K교수를 질타하기 위해 〈사회통계〉의 교육효과가 영 부진하다고 의심하고 있다. 그녀는 이 과목 이수자 30명의 표본을 임의로 뽑아, 평균이 75점이고 표준편차가 10점임을 확인하고 자신의 두 눈을 의심하였다. 모평균의 95% 신뢰구간을 구하시오.

모평균의 신뢰구간

- 가장 먼저 문제가 무엇을 묻고 있는지 파악해야 한다.

$$P(? \leq \mu \leq ?) = .95$$

- 다음에 문제에서 주어진 정보를 정리해보자.

$$\mu = ?, \quad \sigma = ?, \quad \bar{x} = 75, \quad s = 10, \quad n = 30$$

- $n \geq 30$이므로 중심극한명제에 따라 예진의 표집분포는 정규분포함을 알 수 있다.
- 이 표집분포의 평균 $\mu_{\bar{X}}$는 무엇인가? 주어진 (한 번의) 표본평균 $\bar{x} = 75$가 현실적으로 모평균 μ에 대한 최선의 추정량(best estimator)이다. 그러므로,

$$\mu_{\bar{X}} = \mu = 75$$

- 이 표집분포의 표준오차 $\sigma_{\bar{X}}$는 무엇인가? 주어진 (한 번의) 표본의 표준편차 s는 10점이고 표본 크기는 $n = 30$이므로,

$$\sigma_{\bar{X}} = \frac{10}{\sqrt{30}}$$

모평균의 신뢰구간

- 일단 (가상적인) 표본평균의 확률분포, 즉 표집분포를 그려본 뒤 구하려는 신뢰구간 95%에 대해 대충 색칠 공부를 해보자.
- 정확한 95% 면적을 결정하는 Z-점수는 엑셀의 NORM.INV(0.975, 0, 1)과 NORM.INV(0.025, 0, 1)로 특정한다(Why?).
- 이제 그 값들을 Z-점수 축에 표시하자.
- 아까 NORM.INV(·) 함수를 통해 구한 값들은 Z-점수이므로 다시 원점수로 환원해야 한다($X = Z \cdot \sigma_{\bar{X}} + \mu_{\bar{X}}$).
- 환원된 그 원점수들을 다시 원점수 축에 표시하고 신뢰구간을 보고한다.

$$P(Z_{0.025} \cdot \sigma_{\bar{X}} + \bar{X} \leq \mu \leq \bar{X} + Z_{0.095} \cdot \sigma_{\bar{X}}) =$$

$$P(-1.96 \cdot \frac{10}{\sqrt{30}} + 75 \leq \mu \leq 1.96 \cdot \frac{10}{\sqrt{30}} + 75) =$$

$$P(71.42 \leq \mu \leq 78.58) = .95$$

모비율의 신뢰구간

모비율의 신뢰구간

이제 모비율의 신뢰구간에 대해서 이야기할 차례이다.

- 앞서 "표본평균"과 "표본비율"의 표집분포들을 대조하여 이야기한 것과 마찬가지로, "모평균의 신뢰구간"과 모비율의 신뢰구간(confidence intervals for the population proportion)을 대조할 수 있다.
- 현실에서 모비율을 추정해야 하는 사례는 얼마든지 있다:

  (1) 학자금 채무불이행 비율
  (2) 비영리 단체에서 기부요청 이메일을 보내자 이에 화답한 회원의 비율
  (3) 제조과정에서 불량품 발견률
  (4) 길거리에서 살펴본 무단횡단의 비율

모비율의 신뢰구간

- 다행히 아까와 마찬가지로 논리 구조는 거의 똑같다.
- 현실적으로 (1) 우리는 모비율 π와 모표준편차 σ_π를 알지 못한다. (2) 표본도 무한히 뽑을 수 없다.
- 대신 크기가 n인 임의표본을 한 번만 수집하여, 그로부터 표집분포의 비율 p과 표준오차 σ_p를 계산한다.
- 중심극한명제에 의지하여 우리는 하나의 표본에서 계산한 p가 (어쨌든) 모비율에 대한 최선의 추정량임을 안다.

모비율의 신뢰구간

- 그런데 모비율의 신뢰구간은 어떻게 구할 수 있을까?
- 중심극한명제에 의지하여 우리는 정규분포에서 (가장 확률이 높은 부분만을 골라) 90%의 면적을 계산할 수 있다.
- 면적의 x축에 대응하는 Z-점수에 원점수를 표준화하여 정확히 구간이 어디에서 어디까지인지 밝힌다.
- 신뢰구간의 기준은 어디까지나 모비율 π이 되어야 한다. (표본에 따라) 확률적으로 변화할 수 있는 것은 p임에 주의하면서 신뢰구간의 의미를 해석한다.

모비율의 신뢰구간

예제 5. 미국 Opinion Today 2019년 7월 1일자에 따르면 트럼프 대통령의 경제정책을 지지하는 사람의 비율은 47%였다. 이 표본은 1,116명의 성인을 대상으로 설계된 것이다. 트럼프의 경제정책에 지지하는 전체 미국인의 비율에 대한 99% 신뢰구간을 구하시오.

모비율의 신뢰구간

- 가장 먼저 문제가 무엇을 묻고 있는지 파악해야 한다.

$$P(? \leq \pi \leq ?) = .99$$

- 다음으로 이 문제에서 얻은 정보는 아래와 같다.

$$\pi = ?, \quad \sigma_\pi = ?, \quad p = .47, \quad n = 1116$$

- 중심극한명제에 따라 이 표집분포는 정규분포함을 알 수 있다.
- 이 (표본비율의) 표집분포의 평균 $E(p)$는 무엇인가? 주어진 (하나의) 임의표본의 평균 $p = 0.47$이 현실적으로 모비율에 대한 최선의 추정량이다. 그러므로,

$$E(p) = 0.47$$

- 이 표집분포의 표준오차 σ_p는 무엇인가? 주어진 (한 번의) 표본비율 p는 0.47이고 표본 크기는 $n = 1116$이므로,

$$\sigma_p = \sqrt{\frac{p(1-p)}{n}} = \sqrt{\frac{0.47 \cdot (1 - 0.47)}{1116}}$$

모비율의 신뢰구간

- 일단 표본비율의 확률분포, 즉 표집분포를 그려본 뒤 구하려는 신뢰구간 99%에 대해 대충 색칠 공부를 해보자.
- 정확한 99% 면적을 결정하는 Z-점수는 엑셀의 NORM.INV(0.995, 0, 1)과 NORM.INV(0.005, 0, 1)로 특정한다(Why?).
- 이제 그 값들을 Z-점수 축에 표시하자.
- 아까 NORM.INV(·) 함수를 통해 구한 값들은 Z-점수이므로 다시 원점수로 환원해야 한다($p = E(p) + Z \cdot \sigma_p$).
- 환원된 그 원점수들을 다시 X-점수 축에 표시하고 신뢰구간을 보고한다.

$$P(p + Z_{0.005} \cdot \sigma_p \leq \pi \leq p + Z_{0.995} \cdot \sigma_p) =$$

$$P\left(0.47 - 2.58 \cdot \sqrt{\frac{0.47 \cdot (1 - 0.47)}{1116}} \leq \pi \leq 0.47 + 2.58 \cdot \sqrt{\frac{0.47 \cdot (1 - 0.47)}{1116}}\right) =$$

$$P(.43 \leq \pi \leq .51) = .99$$

모비율의 신뢰구간

문제를 풀 때는 $E(p)$와 σ_p의 성격을 다소 주의해서 공부해야 한다.

- (표본평균과는 달리) 표본비율은 그 자체가 이미 평균의 성격을 갖고 있다.

$$p = E(p) = \frac{X}{n}$$

- (표본평균과는 달리) 표본비율에서는 표본평균 $E(p)$과 표본표준편차 σ_p를 별개로 줄 필요가 없다. 왜냐하면,

$$\sigma_p = Var(p) = \sqrt{\frac{\pi(1-\pi)}{n}}$$

모비율의 신뢰구간

시험에 대비하여 교재를 반드시 공부하자.

- 특히 확률과 통계는 연습문제를 많이 풀어봐야 통계학적 상상력을 기를 수 있다.
- 다만 수업에서 (아직) 다루지 않은 이론적 확률분포들이 나오는 파트는 시험 범위로 내지 않는다.
- 예를 들어 t 분포와 chi^2 분포는 나중에 다루므로 중간시험 범위는 아니다.

끝!

뭣! 숙제가 없다구?!