사회통계

t 분포와 t 검정의 기초

김현우, PhD[1]

[1] 충북대학교 사회학과 조교수

May 6, 2021

진행 순서

1. 지난 주 리뷰
2. 두 집단에 관한 가설검정
3. t 분포와 자유도
4. 단일 모평균에 관한 가설검정

지난 주 리뷰

지난 주 리뷰

1. 수면시간의 평균, 중앙값, 최빈값, 분산, 표준편차, 그리고 표본 크기를 보고하시오 (20점)

지난 주 리뷰

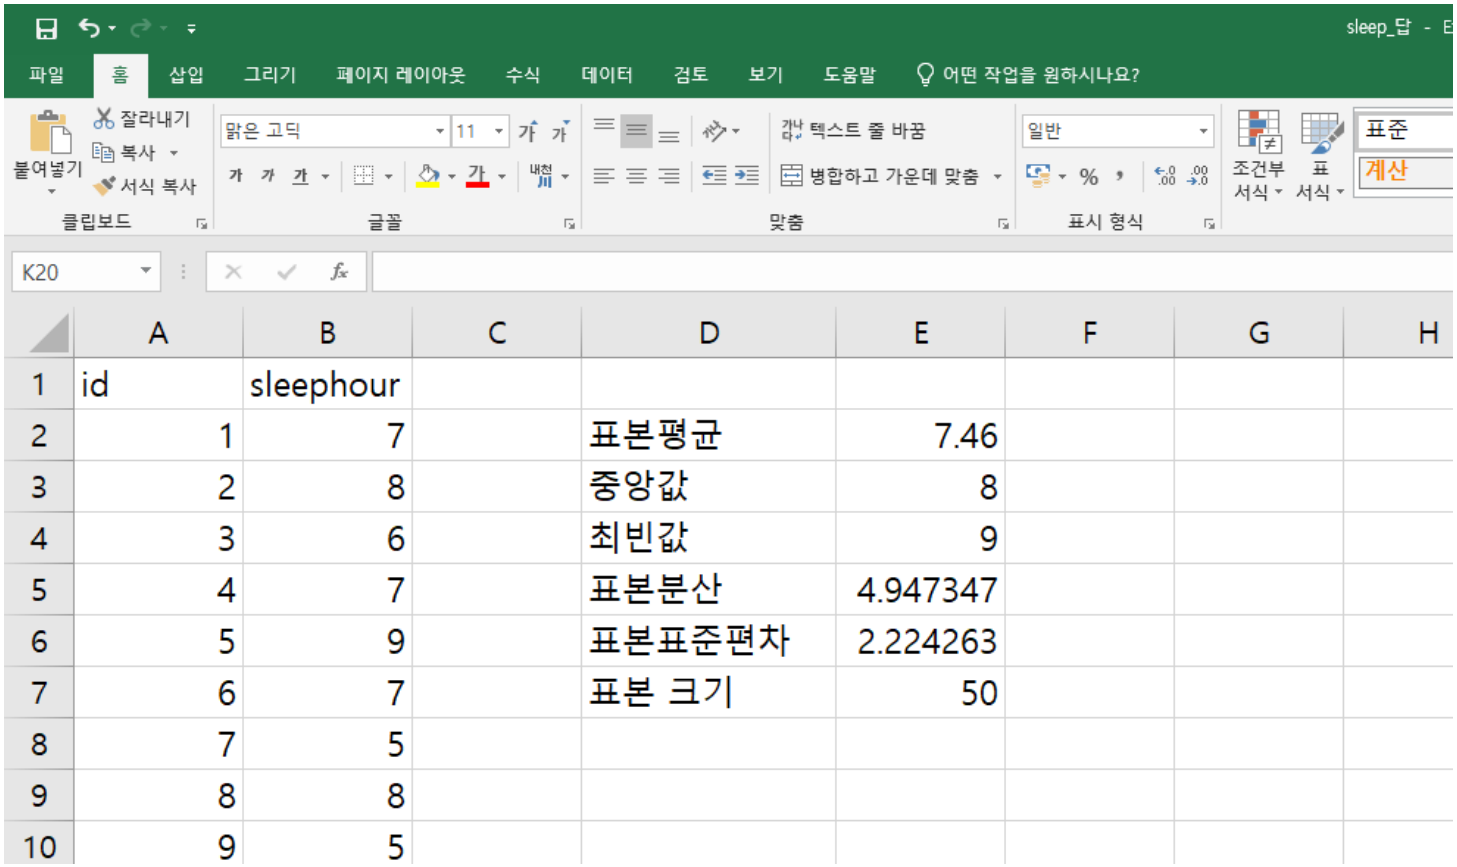

	A	B	C	D	E	F	G	H
1	id	sleephour						
2	1	7		표본평균	7.46			
3	2	8		중앙값	8			
4	3	6		최빈값	9			
5	4	7		표본분산	4.947347			
6	5	9		표본표준편차	2.224263			
7	6	7		표본 크기	50			
8	7	5						
9	8	8						
10	9	5						

지난 주 리뷰

2. 지선은 고교생의 수면시간은 8시간이 아닐까 예상하고 있다. 지선의 가설을 제시하고 95% 신뢰수준에서 유의확률을 이용한 가설검정을 수행하시오. (40점)

지난 주 리뷰

- 귀무가설과 대립가설은 다음과 같으므로 양측검정을 수행해야 한다.

$$H_0 : \mu = 8$$
$$H_a : \mu \neq 8$$

- 귀무가설이 옳다는 가정 아래에서 표집분포를 그린다. 표본이 충분히 크다면 이 표집분포는 정규분포할 것이다.
- 이 표집분포의 표준오차를 구하기 위해 필요한 모든 추정값은 이미 앞에서 계산하였다.
- 귀무가설이 옳다는 가정 아래에 이런 표본평균이 나올 확률을 다음처럼 계산한다.

$$Z = \frac{X - \mu_0}{\sigma_{\bar{X}}} = \frac{7.46 - 8}{2.224/\sqrt{50}} = -1.717$$

지난 주 리뷰

- 표준정규분포 상에서 -1.717보다 작을 확률은 NORM.DIST(·)으로 구한다.
- 답은 0.043이지만 이것이 끝은 아니다. 왜냐하면 양측검정은 표본평균이 8보다 매우 작을 확률과 8보다 매우 클 확률을 모두 살펴보도록 요구하기 때문이다.
- 그러므로 표준정규분포 상에서 1.717보다 클 확률도 계산한다.
- 두 확률을 더하면 0.086이므로 (문제에서 주어진) 유의수준 α인 0.5보다 크다. 그러므로 귀무가설을 95% 신뢰수준에서 기각할 수 없다.
- 결론적으로 고교생의 수면시간이 8시간이라는 가설은 기각될 수 없다.

지난 주 리뷰

	A	B	C	D	E	F
1	id	sleephour				
2	1	7		표본평균	7.46	
3	2	8		중앙값	8	
4	3	6		최빈값	9	
5	4	7		표본분산	4.947347	
6	5	9		표본표준편차	2.224263	
7	6	7		표본 크기	50	
8	7	5				
9	8	8		귀무가설 평균	8	
10	9	5				
11	10	10			양측검정	
12	11	4		표본평균 Z값	-1.71669	
13	12	8		p-value	0.043018	
14	13	6		반대편	1.716693	
15	14	7		p-value	0.043018	
16	15	4		p-value*2	0.086035	

지난 주 리뷰

3. 같은 자료를 들여다보던 효섭은 고교생의 수면시간이 사실 8시간보다 작지 않을까 예상하고 있다. 효섭의 가설을 제시하고 95% 신뢰수준에서 유의확률을 이용한 가설검정을 수행하시오. (40점)

지난 주 리뷰

- 귀무가설과 대립가설은 다음과 같으므로 단측검정을 수행해야 한다.

$$H_0 : \mu \geq 8$$
$$H_a : \mu < 8$$

- 귀무가설이 옳다는 가정 아래에서 표집분포를 그리고, 이런 표본평균이 나올 확률을 다음처럼 계산한다.

$$Z = \frac{X - \mu_0}{\sigma_{\bar{X}}} = \frac{7.46 - 8}{2.224/\sqrt{50}} = -1.717$$

- 표준정규분포 상에서 -1.717보다 작을 확률은 NORM.DIST(·)으로 구한다.
- 답은 0.043이므로 (문제에서 주어진) 유의수준 α인 0.5보다 크다. 그러므로 귀무가설을 95% 신뢰수준에서 기각할 수 있다.
- 결론적으로 고교생의 수면시간이 8시간보다 적다.

지난 주 리뷰

보너스 문제. 채민은 땀을 뻘뻘 흘리며 백사장에서 5,324개의 조개 껍질을 임의표본으로 주웠다. 집에 돌아와 수집한 조개 껍질을 살펴보니 약 37%가 보랏빛과 노란색이 섞인 광채를 나타내고 있었다. 채민의 조사 결과에 따르면 이 백사장에 있는 조개 껍질의 몇 퍼센트나 같은 광채를 나타내는지 평균과 그 99% 신뢰구간을 보고하시오. (10점)

지난 주 리뷰

- 이제부터 보랏빛과 노란색이 섞인 광채를 띤 조개 껍질을 보라노란이라고 부르자.
- 채민이 뽑은 임의표본 안에서 보라노란의 비율 p는 0.37이다.
- 그러나 99% 신뢰구간이라면 (중간시험 이전에 배운) "모비율의 신뢰구간"에 관해 묻고 있는 것임을 눈치채야 한다.
- 무한히 계속해서 표본을 뽑고 보라노란의 "비율의 표집분포"를 그려보면 (간단한 가정 하에) 정규분포한다(Why?).
- 이 표집분포의 평균 $E(p)$는 모비율 π와 같다. 모집단에서 보라노란의 비율 π의 최선의 추정량(best estimator)은 0.37일 것이다.

지난 주 리뷰

- 비율의 표집분포의 표준편차, 즉 표준오차 σ_p는 다음과 같다.

$$\sigma_p = \sqrt{\frac{p(1-p)}{n}} = \sqrt{\frac{0.37 \cdot (1-0.37)}{5324}} = 0.0066$$

- 이제 표집분포에서 99% 신뢰구간을 색칠공부하고 신뢰상한과 하한의 Z-값을 NORM.INV$(\cdot)$으로 구한다.
- 원점수의 99% 신뢰상한과 하한을 구하기 위해 다음의 공식을 적절히 활용한다.

$$Z = \frac{X - \pi}{\sigma_p}$$

- 정답은 $[0.37 \pm 2.57 \cdot 0.0066] = [0.353, 0.387]$ 이다.

두 집단에 관한 가설검정

두 집단에 관한 가설검정

오늘은 두 집단에 관한 가설검정을 공부한다.

- 지난 주에는 단일집단에 관한 가설검정을 공부했다. 공부한 내용을 잘 곱씹어보자! 그때는 오로지 "하나의 집단(=하나의 표본)에 관한 평균"만 공부했다.
- 그러나 가설검정은 둘 또는 그 이상의 집단들의 통계량(e.g., μ, p, σ)을 비교하는 목적에 대해서도 수행할 수 있다.
- 다행히 지난 주까지 배운 내용을 바탕으로 두 집단 가설검정도 쉽게 수행할 수 있다.
- 다만 오늘은 (1) 새로운 이론적 확률분포인 t 분포(t distribution)를 먼저 공부하고 (2) 이 개념을 토대로 두 집단 가설검정을 살펴보기로 한다.

t 분포와 자유도

t 분포와 자유도

이론적 확률분포를 새로 하나 배우기로 한다.

- 몇 주 전에 우리는 이미 몇가지 간단한 이론적 확률분포를 공부한 바 있다(e.g., 베르누이 분포, 이항분포, 정규분포 등)
- 오늘 배울 새로운 이론적 확률분포의 이름은 t 분포(t distribution)이다.
- 기본적으로 t 분포는 표준정규분포와 매우 비슷한 것임을 기억하자.
- 다만 (1) 사례가 적고(small Ns) (2) 모분산을 모르는(unknown variance) 경우라면 표집분포가 표준정규분포한다고 말하기 어렵다.
- t 분포는 이에 대응하여 고안되었다.

t 분포와 자유도

- t 분포는 1908년에 학생(Student)이라는 익명으로 출판된 논문에서 처음 알려졌다.

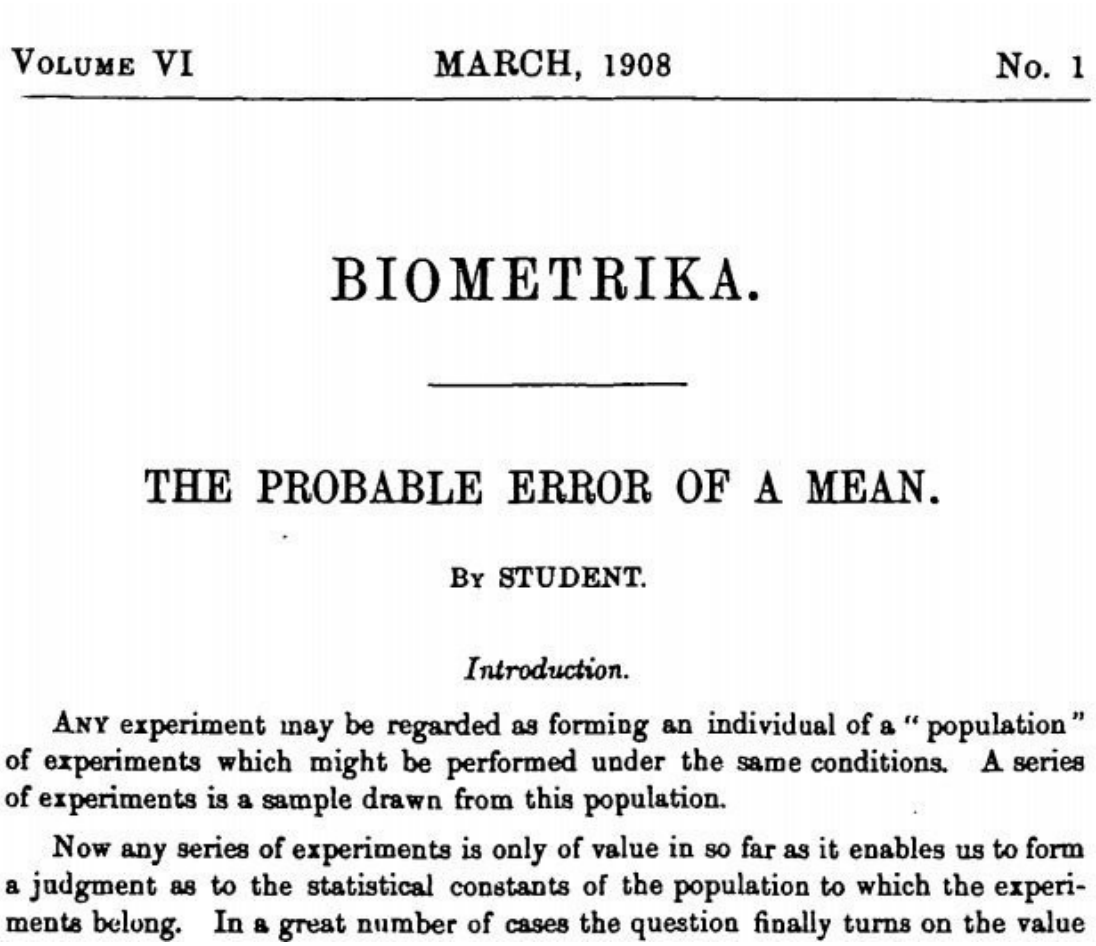

VOLUME VI MARCH, 1908 No. 1

BIOMETRIKA.

THE PROBABLE ERROR OF A MEAN.

BY STUDENT.

Introduction.

ANY experiment may be regarded as forming an individual of a "population" of experiments which might be performed under the same conditions. A series of experiments is a sample drawn from this population.

Now any series of experiments is only of value in so far as it enables us to form a judgment as to the statistical constants of the population to which the experiments belong. In a great number of cases the question finally turns on the value

t 분포와 자유도

소표본을 가지고 수행하는 가설검정은 조금 특수하다.

- 모분산 σ^2는 본래 다음과 같이 정의된다.

$$\sigma^2 = \frac{\sum (x-\mu)^2}{n}$$

- 원칙대로라면 모평균 μ을 사용해야 하지만, (애초에 모평균을 "이미" 아는 상황이 드물기 때문에) 우리는 표본평균 $\bar{x}$를 대신 사용할 수 밖에 없었다.
- 가만 생각해보면 이건 웃긴 것이다. 왜냐하면 우리는 μ의 추정량(estimator)인 s를 구하는 과정에서 (진짜 들어가야 하는 μ 대신) μ의 또다른 추정량인 $\bar{x}$를 이중으로(!) 사용했기 때문이다.
- 정말 이렇게 해도 문제는 없을까?

t 분포와 자유도

- 문제없을 리가 없다. 무엇보다 μ 대신 $\bar{x}$를 쓰면 표본표준편차 s는 진정한 모표준편차 σ보다 작게 된다(Why?).
- 보다 구체적으로, 진정한 모분산 σ_x^2는 (1) 모평균 μ 대신 표본평균 $\bar{x}$를 사용해 추정된 표본분산 s_x^2와 (2) 표본평균 $\bar{x}$을 구하는 과정에서 발생한 표본평균의 분산 $\sigma_{\bar{x}}^2$의 합이다.

$$\sigma_x^2 = s_x^2 + \sigma_{\bar{x}}^2$$

- 즉 $\sigma_x^2 < s_x^2$ 이므로 s_x^2을 사용하는 이상 조금 작아지므로 이를 보정해줄 필요가 있는 것이다.

t 분포와 자유도

- t 분포는 사실 William Gosset이 Ronald Fisher의 도움을 받아 고안한 것이다.
- Gosset은 앞서 언급한 특수성을 인식하였고, 표본 수(n)에서 "어쩔수 없이 사용한 $\bar{x}$ 같은 것, 이른바 제한조건(limiting condition)"의 수를 빼면 이 문제를 해소할 수 있음을 발견했다.

$$s^2 = \frac{\sum (x - \bar{x})^2}{n - 1}$$

- $n - 1$ 부분을 자유도(degree of freedom)라고 부른다(교재 66–67페이지 참고).
- 여러분이 엑셀에서 STDEV.P(·) 함수와 STDEV.S(·) 함수를 사용했을 때 발견한 미세한 차이는 바로 분모에서 표본 크기 n을 썼나, 아니면 자유도 $n - 1$을 썼나의 차이에서 온 것이다.

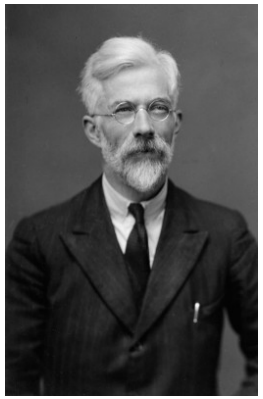

t 분포와 자유도

- 교과서에 따라서 자유도는 종종 "데이터에서 자유롭게 선택될 수 있는 관측치(observations)의 수"라고도 설명된다. 이건 또 무슨 의미일까?
- 만일 $\bar{x} = 0$ 로 이미 정해져 있다면 $\left(\frac{-1+0+x}{3}\right)$ 의 상황에서 x에는 이미 자유가 없다(Why?). 따라서 $n = 3$이지만 $df = 3 - 1 = 2$이다.
- 결론을 내려보자: "분모에서 표본 수 n 대신 자유도 $n - 1$를 사용해야만, 표본의 표준편차 s는 모집단의 표준편차 σ의 최선의 추정량(best estimator), 다른 이름으로 불편추정량(unbiased estimator)이 된다."

t 분포와 자유도

t 분포를 사용하면 $n < 30$이라도 모평균에 관한 가설검정이 가능하다.

- 우리는 대표본을 가지고 모집단의 평균에 관한 가설검정을 할 때, 자유도 개념을 전혀 신경쓰지 않아도 된다(Why?).
- 대표본이라면 n이 크므로 거기에 1을 빼도 차이가 작지만(예컨대 1,000에서 999로), 소표본(small sample)이라면 거기서 1을 뺐을 때 제법 체감이 크다(가령 10에서 9로). 몇 번 계산해보면 쉽게 알 수 있다.
- 빅데이터가 일반화되고 있는 오늘날, 자유도 개념은 다소 시대착오적으로 느껴질 수 있다.
- 더이상 t 분포에 집착할 필요가 없고 표준정규분포(=Z 분포)를 그냥 사용해도 되는데 (특정 상황에서) 여전히 t 분포를 사용하는 관행은 계속되고 있으므로 아예 안 배울 수는 없다.

t 분포와 자유도

t 분포는 표준정규분포와 사실 매우 비슷하게 생겼다.

- (수학적으로 엄밀하게 다루지는 않겠지만) t 분포는 사실 Z 분포에서 파생된다.
- Z 분포의 패러미터(parameter)는 μ와 σ^2 였지만, t 분포의 패러미터는 오로지 자유도 df 뿐이다. 다시 말해, 표본의 μ나 σ^2에 의해 형태가 변하지 않는다.
- 모평균을 추정하거나 가설검정하려는 경우에 제한조건은 $\bar{x}$ 딱 하나이므로 자유도는 $n-1$이다.
- 자유도가 작을때 t 분포는 표준정규분포에 비해 꼬리가 좀 더 두껍다.

t 분포와 자유도

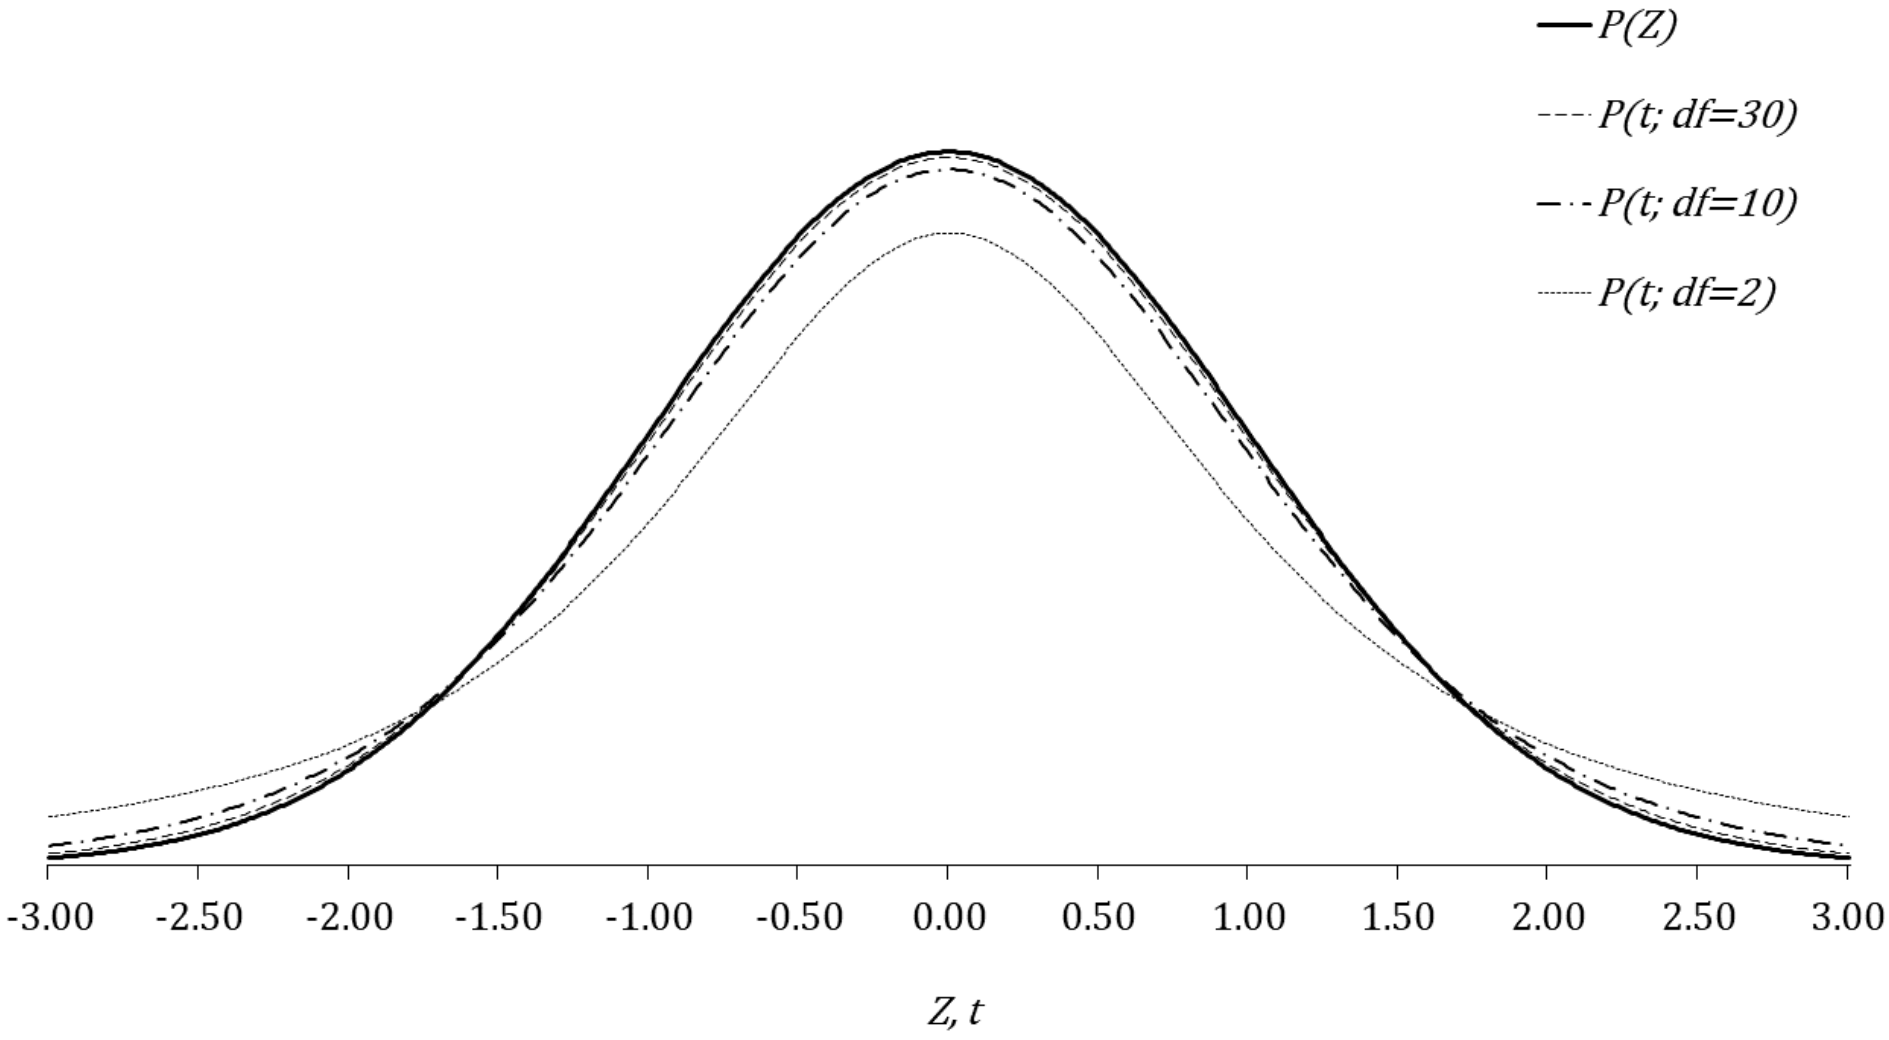
P(Z)
P(t; df=30)
P(t; df=10)
P(t; df=2)
-3.00
-2.50
-2.00
-1.50
-1.00
-0.50
0.00
0.50
1.00
1.50
2.00
2.50
3.00
Z, t

t 분포와 자유도

분포와 마찬가지로 t 값과 Z 값도 아주 밀접한 관계가 있다.

- 대표본인 표집분포의 경우 다음의 공식에 따라 Z 값으로 변환할 수 있었다.

$$Z = \frac{\bar{x} - \mu_0}{\sigma/\sqrt{n}}$$

- 소표본의 표집분포의 경우 다음의 공식에 따라 t 값으로 변환할 수 있다.

$$t = \frac{\bar{x} - \mu_0}{s/\sqrt{n}}$$

- 공식이 똑같으므로 만약 자료가 같다면 표준화했을 때 Z 값이건 t 값이건 똑같다. 다만 어떤 분포를 사용하느냐에 따라 유의확률(p-value)이 달라질 뿐이다.

t 분포와 자유도

t 분포를 사용하여 (Z 분포와 비슷하게) 가설검정을 수행할 수 있다.

- 이제부터 공부할 t 검정(t test)에는 세 종류가 있다.
- 첫번째로, 살펴보려는 모집단이 하나 있고 그 평균에 관해 가설검정할 수 있다.
- 모집단에 관한 귀무가설을 세우고 (이것이 옳다는 전제 아래) 그 표본평균의 표집분포가 t 분포를 따른다고 할 때, 나의 표본에 따라 귀무가설을 기각할 수 있는가 살펴볼 수 있다.
- 이것이 (1) 단일표본 t 검정(one-sample t test)이다.

t 분포와 자유도

- 두번째로, 이번엔 살펴보려는 모집단이 두 개 있고 그 평균의 차이에 관해 가설검정할 수 있다. 이른바 평균비교(mean comparison)이다.
- 각각에서 무한히 표본을 뽑고 두 평균의 차 $\bar{x}_1 - \bar{x}_2$를 확률변수(random variable)로 보고 표집분포를 그릴 수 있다.
- 그 표집분포는 대표본일 때 정규분포한다(증명 생략). 물론 소표본이라면 t 분포한다.
- 이제 귀무가설을 세우고 적절하게 가설검정을 수행할 수 있다. 다만 자료구조에 따라 (2) 독립표본 t 검정(t test for independent samples) 또는 (3) 쌍체표본 t 검정(t test for paired samples)을 사용해야 한다.

단일 모평균에 관한 가설검정

단일 모평균에 관한 가설검정

단일표본 t-검정의 가설구조를 살펴보자.

- 다른 검정 기법의 가설구조와 마찬가지로 양측검정과 단측검정으로 나뉜다.
- 양측검정에서 귀무가설과 대립가설의 구조는 다음과 같다.

$$H_0 : \mu = x \qquad H_a : \mu \neq x$$

- 단측검정은 두 가지 형태 중 하나의 귀무가설과 대립가설의 구조를 갖는다.

$$H_0 : \mu \geq x \qquad H_a : \mu < x$$

또는

$$H_0 : \mu \leq x \qquad H_a : \mu > x$$

단일 모평균에 관한 가설검정

예제 1. 생물정보분석팀의 지선은 급성골수성백혈병 환자들의 항암화학치료 이후 체중 변화를 연구하고 있다. 그러나 백혈병 환자는 워낙 드물어 임의표본으로 겨우 30명만을 추출할 수 있었다. 지선은 신중하게 문헌을 살펴본 뒤, "(chemotherapy를 마친 뒤) 평균 체중은 48kg일 것이다" 라는 귀무가설을 세웠다. 표본을 관찰해보니 막상 chemo를 마친 환자들의 평균은 44kg, 표준편차가 8kg였다. 지선의 귀무가설을 99% 신뢰수준에서 테스트하시오.

단일 모평균에 관한 가설검정

- 사례가 매우 적으므로 (가상적인) 백혈병 환자 표본평균의 표집분포는 정규분포 t 분포를 따른다고 전제하는 것이 타당하다. 그 t 분포의 모양은 단순히 자유도에 의해 결정되므로 여기서는 30-1, 즉 df=29다.
- 가설은 다음과 같이 설정할 수 있다.

$$H_0 : \mu = 48$$
$$H_a : \mu \neq 48$$

- Chemo 이후 환자들의 평균은 44kg, 표준편차가 8kg라고 했으므로 t 분포 위에 놓이는 t 값은 다음과 같다.

$$t = \frac{44 - 48}{8/\sqrt{30}} = -2.7386$$

단일 모평균에 관한 가설검정

- 이제 지선은 (1) 귀무가설에 옳다는 전제 아래 그린 t 분포에서 (2) 주어진 표본의 평균같이 극단적인 t 값이 나올 확률(=유의확률)이 너무 적어서 (3) 귀무가설을 기각할 수 있는지를 판단해야 한다.
- 엑셀에서 NORM.DIST(·) 대신 T.DIST(·) 함수를 통해 t 분포의 색칠 공부를 할 수 있다. 이 함수에는 t 값, 자유도 df, (곡선 밑 면적을 구하므로) TRUE를 입력해야 한다.
- (문제에서 요구한대로) 1% 유의수준(=99% 신뢰수준)을 기준으로 하면, 엑셀에서 T.DIST(-2.7386, 29, TRUE) + (1-T.DIST(2.7386, 29, TRUE))를 계산하여 유의확률(p-value)을 구할 수 있다(Why?). 답은 약 0.0104이다.
- p-value가 0.01보다 살짝 크므로 지선은 귀무가설을 1% 유의수준에서 기각할 수 없다.

단일 모평균에 관한 가설검정

하지만 만일 Z 분포를 사용했다면 어땠을까?

- 사회통계 교과서를 다시 살펴본 지선은 자신의 샘플이 $n \geq 30$ 조건을 간신히 충족하므로, 중심극한정리에 따라 평균의 표집분포가 정규분포일지도 모른다고 생각하였다. 그러므로 이번에는 표준정규분포 상에서 가설검정을 다시 실시하였다.
- Z 값은 새로 계산할 필요조차 없이 t 값과 마찬가지로 -2.739이다(Why?).
- 엑셀에서 NORM.DIST(-2.739,0,1,TRUE)+(1-NORM.DIST(2.739,0,1,TRUE)) 함수를 활용하여 유의확률(p-value)을 구할 수 있다. 답은 약 0.006이다.
- p-value가 0.01보다 살짝 작으므로 지선은 귀무가설을 1% 유의수준에서 기각한다.

단일 모평균에 관한 가설검정

여기에서 t 분포와 표준정규분포의 결정적인 차이가 나타난다.

- 아까 지선의 사례에서 보았듯, 똑같은 샘플을 가지고도 t 검정에서 기각하지 못했던 가설을 표준정규분포를 이용한 검정에서는 기각할 수 있는 상황이 생겨난다.
- 자유도가 작을때 t 분포는 표준정규분포에 비해 꼬리가 좀 더 두껍다. 이로 인해 t 분포를 사용하면 신뢰구간(예컨대 90%, 95%, 99%)을 설정할 때 좀 더 큰 검정통계량 (test statistic), 즉 높은 t 값을 얻어야만 가설을 기각시킬 수 있게 된다.

단일 모평균에 관한 가설검정

- 곰곰히 생각해보자! 소표본에서 얻어낸 검정통계량을 쉽사리 모평균이라고 신뢰할 수 있을까?
- 그럴수 없으니까 어지간히 큰 평균값이 나와주지 않는 한 쉽사리 귀무가설을 기각할 수 없는게 오히려 상식적이다.
- 이것을 보수적 추정(conservative inference)이라고 부른다.
- 물론 자유도가 커질수록(즉 표본 크기가 커질수록) t 분포는 표준정규분포와 점점 더 닮아가므로 보수적 추정을 해야 할 필요는 점점 약해진다.

단일 모평균에 관한 가설검정

단일 모평균에 관한 가설검정과 관련하여 지금까지 두 가지 기법을 배웠다.

- 기본 원리(교재 166 참고)와 엑셀 함수의 차이에도 좀 더 주목해야 한다.
- Z 분포(대표본)의 경우 NORM.DIST(x, mean, standard_dev, cumulative)를 사용했다. x에는 표준화된 Z 값을 입력한다. 물론 표준화되었으므로 mean=0 그리고 standard_dev=1이다.
- t 분포(소표본)의 경우 T.DIST(x, deg_freedom, cumulative)를 사용했다. 여기서도 x에는 표준화된 t 값을 입력한다. (mean, standard_dev 대신) deg_freedom을 입력한다.
- 색칠 공부이므로 둘 다 cumulative=TRUE이다.

단일 모평균에 관한 가설검정

예제 2. social.xlsx 파일을 엑셀로 불러오시오. socialself 변수는 초등학교 1학년생의 사회적 자아(social self)에 관한 여덟 개 문항에 대한 응답의 총합이다(코드북 참고). 승원은 “사회적 자아 점수의 평균은 32 이다” 라는 귀무가설을 세웠다. 적절한 가설을 제시하고 5% 유의수준에서 이를 검정하시오.

단일 모평균에 관한 가설검정

- 모평균에 관한 가설검정이므로 적절한 가설은 다음과 같다.

$$H_0 : \mu = 32$$
$$H_a : \mu \neq 32$$

- 이 자료는 표본 크기가 매우 작다. 그러므로 표준정규분포가 아니라 t 분포를 사용해야 한다. t 분포는 자유도를 사용하며 이 자료의 자유도는 14이다.
- 엑셀의 [데이터] 메뉴에서 [데이터 분석]을 선택하고 "기술 통계법"을 고른다. 요약통계량을 구해 표본평균 $\bar{x}$과 표준오차 $s/\sqrt{n}$도 찾아낸다.
- 이제 t 값을 다음과 같이 계산한다.

$$t = \frac{\bar{x} - \mu_0}{s/\sqrt{n}} = \frac{29.667 - 32}{5.122/\sqrt{15}} = -1.764$$

단일 모평균에 관한 가설검정

- 귀무가설이 옳다는 가정 아래에서 그린 표집분포 상에 이러한 표본평균 t 값이 나올 확률은 얼마인가? 다시 말해, 유의확률(p-value)을 확인해야 한다.
- 이 가설구조는 양측검정을 필요로 한다. 좌측 끄트머리 면적은 T.DIST(-1.764, 14, TRUE)이고, 우측 끄트머리 면적은 1-(T.DIST(1.764, 14, TRUE))이다.
- 유의확률은 약 0.0995이므로 5% 유의수준(=0.05)보다 조금 크다. 그러므로 승원은 귀무가설을 5% 유의수준에서 기각할 수 없다.