사회통계
상관분석

김현우, PhD[1]

[1] 충북대학교 사회학과 조교수

May 27, 2022

진행 순서

1. 지난 주 리뷰
2. 상관분석 톺아보기
3. 상관계수 유의성 검정
4. 상관분석의 실제 활용

지난 주 리뷰

지난 주 리뷰

1. 종속변수로 Q124 [Immigration in your country: Increases the crime rate] 변수를, 독립변수로 Q34 [Jobs scarce: Employers should give priority to (nation) people than immigrants] 변수를 사용하여 교차표를 만드시오. 각 셀을 적절하게 표준화한 뒤, 적어도 두 개 이상의 셀을 골라 그 의미를 해석하시오. (20점)

지난 주 리뷰

		Immigration in your country "Increases the crime rate."			
		0 Disagree	1 Hard to say	2 Agree	총합계
Jobs scarce "Employers should give priority to (nation)	1 Agree strongly	41	24	110	175
	2 Agree	48	52	103	203
	3 Neither agree nor disagree	22	25	12	59
	4 Disagree	23	14	10	47
	5 Disagree strongly	9	3	3	15
	총합계	143	118	238	499

		Immigration in your country			
		0 Disagree	1 Hard to say	2 Agree	
Jobs scarce "Employers should give priority to (nation)	1 Agree strongly	23.4	13.7	62.9	100.0
	2 Agree	23.6	25.6	50.7	100.0
	3 Neither agree nor disagree	37.3	42.4	20.3	100.0
	4 Disagree	48.9	29.8	21.3	100.0
	5 Disagree strongly	60.0	20.0	20.0	100.0
	총합계	28.7	23.6	47.7	100.0

지난 주 리뷰

2. 두 변수가 서로 연관되어 있는가를 판단하기 위해 적절한 분석을 수행하시오. 왜 그 분석 기법을 선택하였는지 설명하시오. 적절한 가설을 제시하고 99.9% 신뢰수준에서 이를 검정한 뒤, 최종적으로 도달한 결론을 제시하시오. (30점)

지난 주 리뷰

		Immigration in your country "Increases the crime rate."				
		0 Disagree	1 Hard to say	2 Agree	총합계	
Jobs scarce "Employers should give priority to (nation)	1 Agree strongly	41	24	110	175	
	2 Agree	48	52	103	203	
	3 Neither agree nor disagree	22	25	12	59	O
	4 Disagree	23	14	10	47	
	5 Disagree strongly	9	3	3	15	
	총합계	143	118	238	499	

		Immigration in your country				
		0 Disagree	1 Hard to say	2 Agree		
Jobs scarce "Employers should give priority to (nation)	1 Agree strongly	50.2	41.4	83.5		
	2 Agree	58.2	48.0	96.8		
	3 Neither agree nor disagree	16.9	14.0	28.1		E
	4 Disagree	13.5	11.1	22.4		
	5 Disagree strongly	4.3	3.5	7.2		
	총합계					
		1.66954136	7.301603303	8.434520903		
		1.779433268	0.33263789	0.39425164		
		1.533630494	8.748657614	9.25750033		
		6.744492109	0.749280747	6.877766977		
		5.141953838	0.084382324	2.412291811		
		chi^2	**61.46**			
		p-val	**0.00000000024**			

지난 주 리뷰

3. 이민자 가족 여부(immigrant)에 따라 위 문제에서 살펴본 변수들의 관계가 어떻게 달라지는지 살펴보기 위해 (두 개의) 교차표를 각각 따로 만드시오. 다시 말해, 이민자 가족인 경우와 그렇지 않은 경우의 두 변수 간 관계를 보여주는 교차표를 별도로 만드시오. 각각의 교차표 안에서 두 변수 간 연관성을 살펴보기 위해 (99% 신뢰수준에서) 적절한 통계 분석을 수행하시오. (40점)

지난 주 리뷰

		Immigration in your country "Increases the crime rate."				
		0 Disagree	1 Hard to say	2 Agree	총합계	
Jobs scarce "Employers should give priority to (nation)	1 Agree strongly	38	23	101	162	
	2 Agree	45	45	96	186	
	3 Neither agree nor disagree	15	17	9	41	O
	4 Disagree	19	11	9	39	
	5 Disagree strongly	8	2	1	11	
	총합계	125	98	216	439	

		Immigration in your country				
		0 Disagree	1 Hard to say	2 Agree		
Jobs scarce "Employers should give priority to (nation)	1 Agree strongly	46.1	36.2	79.7		
	2 Agree	53.0	41.5	91.5		
	3 Neither agree nor disagree	11.7	9.2	20.2		E
	4 Disagree	11.1	8.7	19.2		
	5 Disagree strongly	3.1	2.5	5.4		
	총합계					
		1.43205647	4.791812085	5.687366289		
		1.196759497	0.291389927	0.219593243		
		0.947430413	6.728279122	6.188364631		
		5.61329642	0.604371168	5.410219905		
		7.565572996	0.084523352	3.597064993		
		chi^2	**50.36**			
		p-val	**0.00000003488**			

지난 주 리뷰

		Immigration in your country "Increases the crime rate."				
		0 Disagree	1 Hard to say	2 Agree	총합계	
Jobs scarce "Employers should give priority to (nation)	1 Agree strongly	3	1	9	13	
	2 Agree	3	7	7	17	
	3 Neither agree nor disagree	7	8	3	18	O
	4 Disagree	4	3	1	8	
	5 Disagree strongly	1	1	2	4	
	총합계	18	20	22	60	

		Immigration in your country				
		0 Disagree	1 Hard to say	2 Agree		
Jobs scarce "Employers should give priority to (nation)	1 Agree strongly	3.9	4.3	4.8		
	2 Agree	5.1	5.7	6.2		
	3 Neither agree nor disagree	5.4	6.0	6.6		E
	4 Disagree	2.4	2.7	2.9		
	5 Disagree strongly	1.2	1.3	1.5		
	총합계					
		0.207692308	2.564102564	3.75967366		
		0.864705882	0.31372549	0.0942959		
		0.474074074	0.666666667	1.963636364		
		1.066666667	0.041666667	1.274242424		
		0.033333333	0.083333333	0.193939394		
		chi^2	**13.60**			
		p-val	**0.09275448827**			

지난 주 리뷰

4. 위의 두 교차표에서 얻은 결과를 신중히 비교하면서 어떤 차이를 발견하였는지 논하시오. (10점)

지난 주 리뷰

- 전반적인 결론은 무엇을 시사하는가? 각 그룹 내에서는 무엇을 달리 시사하는가?
- 이민자 직계 하위집단(subgroup)의 경우 무엇에 주의해야 하는가?

상관분석 톺아보기

상관분석 톺아보기

두 양적변수 사이의 관계를 살펴볼 때는 상관분석을 수행한다.

- 상관분석(correlation analysis)은 상관계수(correlation coefficient)를 구하는 기법이다.
- 상관계수를 이해하려면 먼저 분산(variance)과 공분산(covariance)을 돌이켜 볼 필요가 있다.
- 먼저 분산의 식을 돌이켜보자.

$$
\begin{aligned}
Var(X) = \sigma_X^2 &= \frac{1}{n}\sum_{i=1}^{n}(x_i - \mu)^2 \\
&= \frac{1}{n}\sum_{i=1}^{n}(x_i - \mu)(x_i - \mu)
\end{aligned}
$$

- 변수가 하나 주어져 있을 때 편차(deviation)를 구해 제곱하여 분산을 구했는데, 아래처럼 살짝 바꾸면 곧바로 공분산이 된다.

$$
Cov(X, Y) = \sigma_{XY} = \frac{1}{n}\sum_{i=1}^{n}(x_i - \mu_X)(y_i - \mu_Y)
$$

상관분석 톺아보기

- 공분산과 분산의 아이디어는 거의 똑같다! 다만 x_i 하나의 편차를 제곱하는 대신, x_i 와 y_i 의 편차를 서로 곱했을 뿐이다.
- 두 변수의 편차끼리 곱할 때, 모두 양수(+)이거나 음수(-)이면 공분산은 양수(+)가 되고, 어느 한쪽이 양수(+)이고 다른 쪽이 음수(-)이면 공분산은 음수(-)가 된다.
- 우리는 엑셀에서 COVARIANCE.P(·) 함수로 모집단의 공분산을 구할 수 있었다. (사실 따로 배우지는 않았지만) COVARIANCE.S(·) 함수로 표본의 공분산도 구할 수 있다.
- 공분산은 흥미로운 아이디어를 제시하고 있지만 명확한 단점이 있었다. $Cov(X, Y)$ 는 X 내부(within X)의 분산과 Y 내부(within Y)의 분산이 다를 수 있다는 점을 고려하지 않았으므로 제대로 표준화가 이루어지지 않았다.
- 그 결과 그 자체로는 해석이 어려웠기 때문에 새로운 대안이 필요했다.

상관분석 톺아보기

Karl Pearson은 공분산의 단점을 보완하는 천재적인 접근을 제시했다.

- 그는 두 변수 X와 Y의 각각의 표준편차(분산이 아니고!)를 분모로 각각 나누어줌으로서 X 내부의 분산과 Y 내부의 분산이 다를 수 있는 가능성을 제거하고 표준화를 이루었다.
- 뿐만 아니라, 일부러 분산이 아닌 표준편차로 나누어주었기 때문에 표준화된 값은 절묘하게 -1과 1사이로 두 변수가 얼마나 강한 상관관계를 가지고 있는지 보여준다.
- 이것이 이른바 피어슨의 적률상관계수(Pearson's product-moment correlation coefficient)이다. 줄여서 상관계수 ρ다. ρ는 rho라고 읽는다.

$$\rho = \frac{\sigma_{XY}}{\sigma_X \sigma_Y}$$

상관분석 톺아보기

상관계수의 해석은 매우 간단하지만 혼동하지 않도록 주의해야 한다.

- 상관계수는 반드시 -1과 1사이에 놓인다. $\rho = 0$는 무상관(no correlation), $\rho = 1$은 완전상관(perfect correlation)이라고 한다.
- 상관계수가 0보다 크면 두 변수는 서로 같은 방향(정방향)으로 움직인다. 즉 "X가 증가하면 Y도 증가한다."
- 상관계수가 0보다 작으면 두 변수는 서로 다른 방향(역방향)으로 움직인다. 즉 "X가 증가하면 Y는 감소한다."
- 왜 이렇게 해석되는지 공분산의 분자 $\sum(x - \mu_X)(y - \mu_Y)$를 잘 들여다보자.
- 상관계수가 1에 가까울수록 (그리고 -1에 가까울수록) 두 변수는 더욱 밀접한 상관관계를 갖게 된다.

상관분석 톺아보기

- 해석할 때는 0과 1 사이를 사분위수로 나누고 각각 리커트 4점 척도로 의미를 부여한다. 물론 0과 -1 사이에서도 마찬가지이다.

상관계수	상관관계의 해석
[-1, -0.75]	매우 강한 역방향
[-0.75, -0.5]	다소 강한 역방향
[-0.5, -0.25]	다소 약한 역방향
[-0.25, 0]	매우 약한 역방향
[0, 0.25]	매우 약한 정방향
[0.25, 0.5]	다소 약한 정방향
[0.5, 0.75]	다소 강한 정방향
[0.75, 1]	매우 강한 정방향

상관분석 톺아보기

예제 1. fullauto.csv를 사용하여 차체회전반경(turn)과 전장(length) 간의 상관계수를 구하고 이를 해석하시오. 상관관계를 나타내는 그래프를 함께 제시하시오.

상관분석 톺아보기

- 먼저 두 변수의 의미를 코드북에서 파악하자.
- 이제 두 변수의 자료유형을 확인해야 한다. 빈도분포표 혹은 히스토그램을 그려서 이를 확인하자.
- 두 변수는 양적변수이므로 엑셀 함수로는 CORREL(·) 혹은 PEARSON(·)을 사용하여 상관계수를 구한다.
- 상관계수에 따르면 두 변수 사이에는 상관관계가 있는가? (있다면) 어느 방향으로 얼마나 강한 상관관계가 있는가?
- 물론 앞서 제시한 식을 직접 이용할 수도 있다. 두 변수 사이의 공분산을 구한 다음, 각 변수의 표준편차의 곱으로 나누어주면 마찬가지로 상관계수를 구할 수 있다.

상관계수 유의성 검정

상관계수 유의성 검정

상관계수에 대해서도 유의성 검정을 할 수 있다.

- 상관계수에 대해서는 무조건 양측검정을 수행하며, 가설 구조는 다음과 같다.

$$H_0 : \rho = 0$$
$$H_a : \rho \neq 0$$

- 귀무가설이 참이라는 가정 아래 무한히 계속 표본을 뽑아 그것들의 상관계수 r을 구해보면 이것은 t 분포를 따른다. 이때 평균 $E(r)$은 0이다.
- 이 t 분포의 꼴은 $n-2$의 자유도로 결정된다(Why?).

상관계수 유의성 검정

- 검정통계량 t 값을 구하고 유의확률(p-value)을 계산한다.

$$t = \frac{r-\rho}{\sigma_r} = \frac{r}{\sqrt{\frac{1-r^2}{n-2}}} = r\sqrt{\frac{n-2}{1-r^2}}$$

- 이때 σ_r은 표본상관계수의 표준오차(standard error)이다.
- 즉 (1) 표본상관계수 r가 커지고 (2) 표본 크기 n이 커질수록 t 값이 커져 귀무가설을 기각하기 쉬워진다.

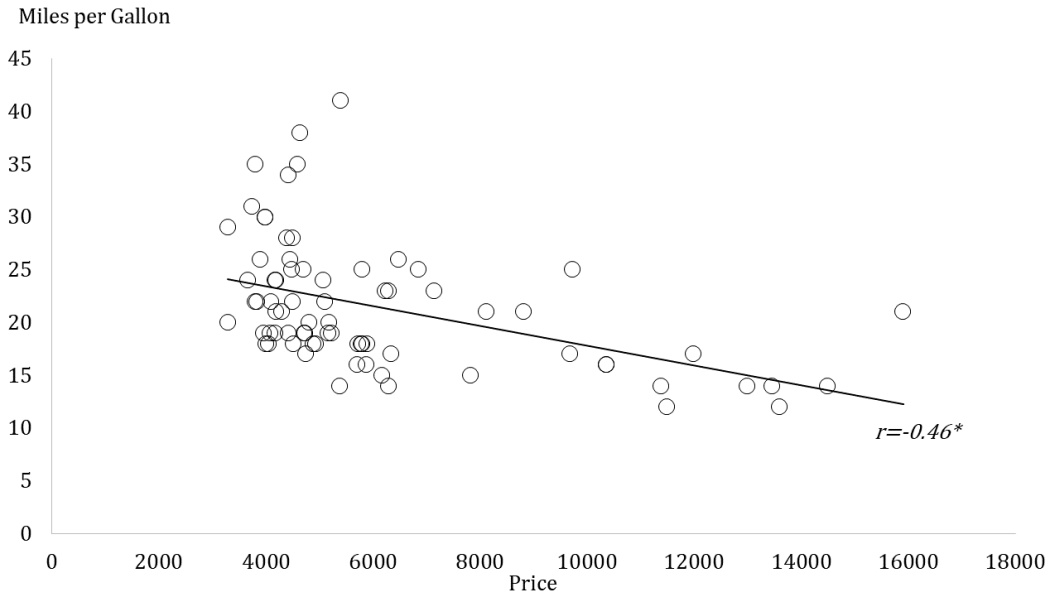

상관계수 유의성 검정

예제 2. fullauto.csv를 다시 사용하여 차량 가격(price)과 가성비(mpg) 간의 상관계수를 구하고 이를 해석하시오. 상관관계를 나타내는 그래프를 함께 제시하시오. 또한 99.9% 신뢰수준에서 가설검정을 수행하시오.

상관계수 유의성 검정

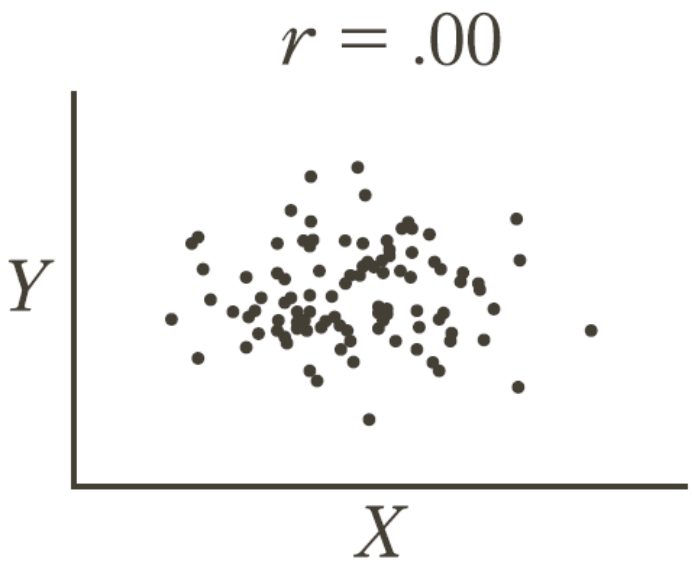

무상관

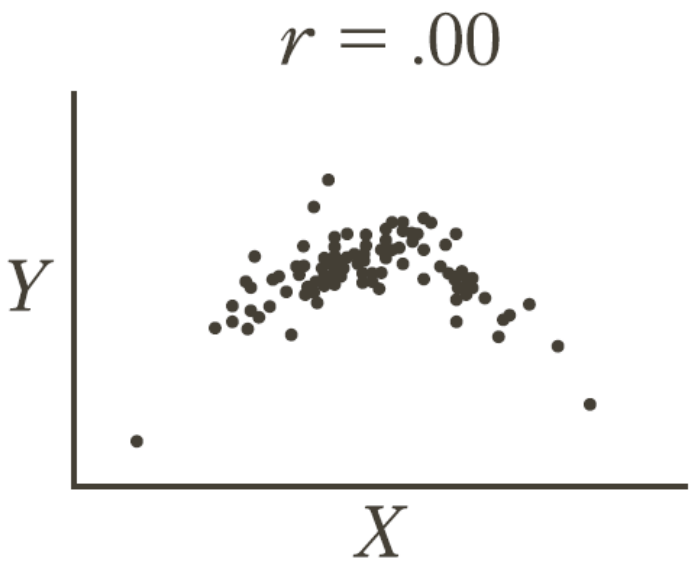

무 선형상관

상관계수 유의성 검정

- 양측검정을 수행하며, 주어진 가설 구조는 다음과 같다:

$$H_0 : \rho = 0$$
$$H_a : \rho \neq 0$$

- 엑셀에서 CORREL(·) 함수로 두 변수 사이의 상관계수를 구한다.

$$r = -0.459$$

- 검정통계량 t 값은 다음과 같다.

$$t = r\sqrt{\frac{n-2}{1-r^2}} = -4.389$$

상관계수 유의성 검정

- t 분포의 양쪽 꼬다리의 "곡선 밑 면적"을 구하고 싶다(Why?).
- 그러므로 엑셀에서 T.DIST(-4.389, 72, TRUE)와 1-T.DIST(4.389, 72, TRUE)를 입력해 나온 값들을 더해 유의확률(p-value)을 구한다.
- $p < 0.001$ 이므로 99.9% 신뢰수준에서 통계적으로 유의하게 귀무가설을 기각한다.
- 정말로 외제차 가성비와 가격 사이에는 다소 약한 역(-)의 상관관계가 존재하는 것 같다!

상관계수 유의성 검정

유의확률에 관한 정보를 요약하기 위해 이제부터 *을 붙이기로 한다.

- 유의확률이 0.001보다 작으면 상관계수 옆에 별 3개(***), 0.01보다 작으면 별 2개(**), 0.05보다 작으면 별 1개(*), 0.1보다 작으면 대거(dagger) 하나(†)를 붙일 수 있다.
- 이런 표식은 결국 "통계적으로 유의하게 귀무가설을 기각할 수 있음"을 의미한다.
- 이것은 완전히 관습의 문제이고 심지어 사람마다 다르다. 어떤 사람은 아예 붙이지 않기도 한다.
- 아까 나의 그림에서는 그냥 유의하다는 사실을 알리기 위해 별 하나로 퉁쳤다.

상관계수 유의성 검정

소표본만 벗어나도 상관계수의 유의성 검정에 사실 큰 의미가 없다.

- 위 식을 곰곰히 들여다보면 눈치챌 수 있는 부분인데, 예컨대 $n = 50$ 정도로 작은 샘플에서 $r = 0.3$ 정도의 값만 나와주어도 이미 95% 신뢰수준에서 통계적으로 유의하다(Why?).
- 오늘날 경험적 사회과학 연구에서 $n = 50$ 짜리 연구는 없다. 게다가 $r = 0.3$는 거의 없는 수준의 상관관계에 불과하다.
- 그러다보니 상관분석의 경우에는 구태여 별을 붙이지 않는 경우도 있다.

상관분석의 실제 활용

상관분석의 실제 활용

상관계수를 보고할 때는 반드시 함께 산점도를 그려야 한다.

- 상관계수는 기본적으로 두 변수간 선형적 관계의 강도(strength of the linear relationship)를 나타내 보인다.
- 다시 말해, 두 변수 사이에 선형적이지 않은 관계, 즉 비선형적 관계(nonlinear relationship)가 있는 경우에는 상관계수가 오해를 불러온다.
- 애시당초 두 변수 사이가 U자형, 역U자형, W자형 등등이 아니라는 보장이 어디에 있을까?

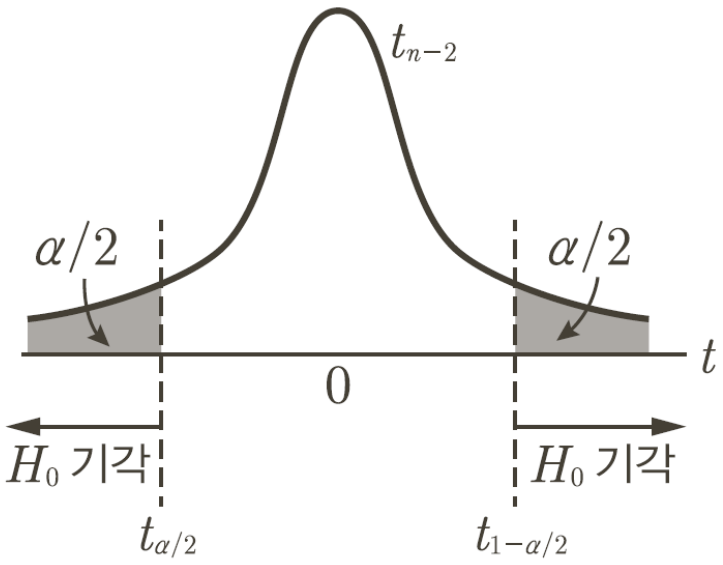

상관분석의 실제 활용

예제 3. fullauto.csv를 사용하여 후방좌석길이(rseat)과 배기량(displ) 사이의 상관계수 r을 확인하고 산점도(scatterplot)를 그리시오.

상관분석의 실제 활용

- 극단치(outliers)가 있는 경우 상관계수는 여기에 민감하게 영향받음을 알 수 있다.
- 그러므로 (극단치의 존재를 식별해내기 위해서라도) 반드시 산점도를 그려보아야 한다.
- 필요하다면 극단치를 제거한 뒤에 다시 상관계수를 계산하는 것이 바람직할 수도 있다(물론 제거 여부를 사전에 꼭 밝혀두어야 한다).

상관분석의 실제 활용

- scatterplot.csv에서 X와 다른 나머지 변수들 간의 상관계수를 구하고 산점도를 그려보자.
- 의외로 기울기(degree of steepness)는 상관계수의 본질이 아니다.
- 오히려 관찰값 사이의 흩어짐(degree of scatter), 다시 말해 산포(dispersion) 경향이 상관계수의 본질이다(Why?).

상관분석의 실제 활용

모든 변수들 사이의 관계를 한 번에 살펴보기 위해 상관계수행렬을 만든다.

- 원칙적으로 숫자형 변수가 두 개 사이의 관계를 볼 때 상관분석을 수행한다. 하지만 여러 개 있어도 큰 문제가 없다.
- 만약 10개의 변수가 있으면 쌍대비교(pairwise comparison)를 45 번($= {}_{10}C_2$)하면 그만이다(Why?).
- 그렇지만 45번을 매번 따로따로 보고하면 좀 보기 흉할 것 같다.
- 그러므로 여기서는 차라리 변수들을 쭉 나열한 뒤, 상관계수를 요약해서 보고하는 상관계수행렬(correlation coefficient matrix)을 한 번에 만드는 쪽이 낫다.

상관분석의 실제 활용

예제 4. fullauto.csv를 사용하여 모든 숫자형 변수들 price, mpg, hdroom, rseat, trunk, weight, length, turn, displ, gratio의 상관계수행렬을 만드시오.

상관분석의 실제 활용

- 변수는 모두 10개이므로 45개의 상관계수를 보고하게 된다.
- 엑셀에서 [데이터]-[데이터 분석]을 통해 "상관 분석"을 선택한다. "첫째 행 이름표 사용"을 고려하여 적절하게 자료를 하이라이트한다.
- 나온 결과에서 셀의 크기와 소숫점을 적절히 컨트롤한다.
- 많은 연구 보고서와 논문에서는 기술통계(descriptive statistics)의 일환으로 상관계수행렬을 제시하는 편이다.
- 다만 상관계수행렬은 한 페이지를 통째로 잡아먹기 때문에 근래에는 보고하지 않는 경우도 많아졌다. 그러나 이것은 메타분석(meta analysis)에도 유용한 자료가 될 수 있기 때문에 (온라인 부록으로나마) 보고하는 편이 바람직하다.
- 여기에 더해 상관계수 옆에 별을 잔뜩 붙이다보면 페이지 공간을 쓸떼없이 더 차지하고 사실 별 의미도 없다.

상관분석의 실제 활용

학술논문을 통해 상관계수행렬이 실제로 어떻게 활용되는지 살펴보자.

- 한내창 (2020)의 〈표1〉을 꼼꼼히 살펴보자.
- 비본질적 종교성의 측정도구로 몇 가지 측정문항을 사용하였는가? 그것들은 각각 무엇인가? 어떻게 그것들로 합성지수를 구성하였는가? 크론바흐 알파는 얼마인가? 내적 일관성이 있는가?
- 다음으로 〈표2〉 표는 혼전성수용도에서 교육수준에 이르기까지 10개의 변수들 사이에 상관계수가 어떠한가를 보여준다.
- 혼전성수용도와 가장 큰 상관계수를 보이는 변수는 무엇인가? 혼외성수용도와 가장 큰 상관계수를 보이는 변수는 무엇인가? 혼전 및 혼외성수용도 사이에는 통계적으로 유의한 상관관계가 있나? 가장 큰 상관계수를 보이는 두 변수는 무엇인가?

한내창. 2010. “종교와 성태도 간 관계.” 한국사회학 44(5): 114-138.