사회통계
단순회귀분석

김현우, PhD[1]

[1] 충북대학교 사회학과 조교수

May 27, 2022

진행 순서

1. 단순선형회귀모형
2. 회귀계수와 상수의 도출

단순선형회귀모형

단순선형회귀모형

독립변수 X와 종속변수 Y 사이의 관계를 선으로 나타내보자.

- 이른바 선형회귀모형(linear regression model)은 아래와 같이 일차방정식(linear equation)으로 설정할 수 있다.

$$Y_i = \beta_0 + \beta_1 X_i + \epsilon_i$$

- 하첨자 i가 붙어있으므로 관찰값(observation)에 따라 상이한 X_i와 Y_i, ϵ_i를 담게 된다.
- 이때 β_0를 상수(constant) 또는 절편(intercept)이라고 부르고, β_1를 기울기(slope)라고 부른다.
- 한편, β_0와 β_1를 어떻게 설정하더라도 결국 자료를 완벽하게 설명할 수는 없다. 따라서 오차항(error term) ϵ_i을 선형회귀모형에 추가한다.

단순선형회귀모형

- 일단 다음의 두 가정을 전제하자.

$$E(\epsilon_i|X_i) = 0$$
$$E(\beta_k|X_i) = \beta_k$$

- 그러면 선형회귀모형의 조건부 기대값(conditional expectation)인 회귀식(regression equation)을 정의할 수 있다.

$$\begin{aligned} E(Y_i|X_i) &= E(\beta_0 + \beta_1 X_i + \epsilon_i|X_i) \\ &= E(\beta_0|X_i) + E(\beta_1 X_i|X_i) + E(\epsilon_i|X_i) \\ &= \beta_0 + \beta_1 E(X_i|X_i) + 0 \\ &= \beta_0 + \beta_1 X_i \end{aligned}$$

- X가 한 단위 증가할 때, Y는 β_1 만큼 증가할 것이다(Why?).
- $X = 0$일 때, $Y = \beta_0$이다(Why?).

단순선형회귀모형

- 조건부 기대값의 계산 원리는 상당히 까다롭지만 기초 개념은 단순하다.
- 최종학력과 소득의 관계를 $E(Y_i|X_i)$로 나타낸다면, 최종학력 별로 소득의 평균을 구할 수 있다.
- educinc.csv를 사용해 직접 계산해보면 $E(Y_i|X_i = 3) = 3.25$임을 확인할 수 있다.

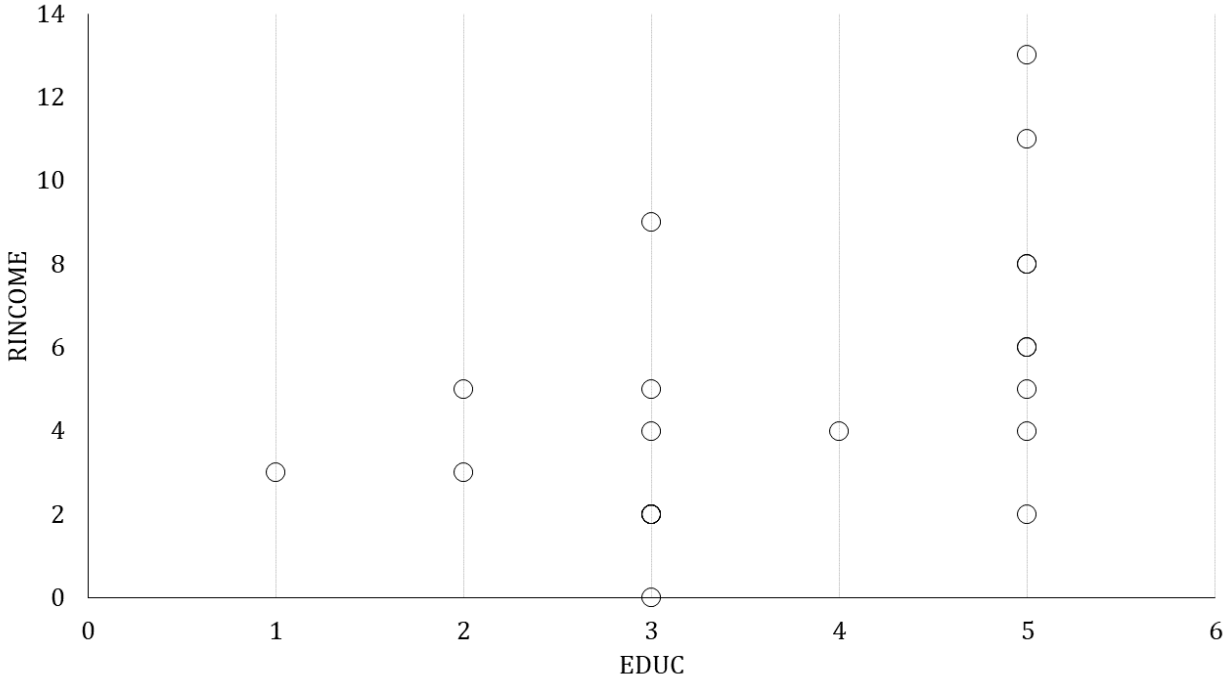

단순선형회귀모형

우리는 초등수학에서 일차방정식을 그래프로 나타내기를 배웠다.

- 그 내용이 기억나지 않는다면 desmos라는 웹사이트에서 $Y = \beta_0 + \beta_1 X$를 그려보자.
- β_1를 이리저리 바꾸어서 이것이 기울기임을 확인하고, β_0를 이리저리 바꾸어서 이것이 절편임을 확인하자.
- X가 수평축이고 Y가 수직축임에 주목하자.
- 기울기는 X가 한 단위 변화할 때 Y가 변화하는 정도를 의미한다.
- 절편은 $X = 0$일 때 Y 값을 의미한다.

단순선형회귀모형

- 우리는 이미 상관분석을 배우면서 적합선(fitting line)을 이미 그려보았다.
- 마찬가지로 주어진 자료의 X와 Y 사이에 가장 잘 맞는 직선(best-fitting straight line)을 그어 그 관계를 나타내 보일 수 있다.
- 이렇게 자료를 관통하는 하나의 선을 찾는 것이 바로 회귀분석(regression analysis)의 핵심이다.

단순선형회귀모형

예제 5. lungcancer.csv는 이것은 8개 북유럽 국가의 1인당 담배 소비량(smoke)과 인구 100만 명당 폐암 발병자수(cancer)를 나타낸다.
독립변수와 종속변수를 선택한 뒤, 둘 사이의 관계를 나타내기 위해 가장 잘 맞는 직선을 그리시오. 회귀식을 도출하고 관계를 해석하시오.

단순선형회귀모형

- 1인당 담배 소비량(smoke)이 100만 명당 폐암 발병자수(cancer)에 영향을 미친다고 보는 것이 타당하다.
- 먼저 산점도를 그리고 적합선을 추가하자. 이때, “수식을 차트에 표시”한다.
- 어떤 조건을 갖춘 적합선이 가장 잘 데이터를 나타낼 수 있을까? 만일 기울기와 절편이 달라지면 어떤 결과가 될까?

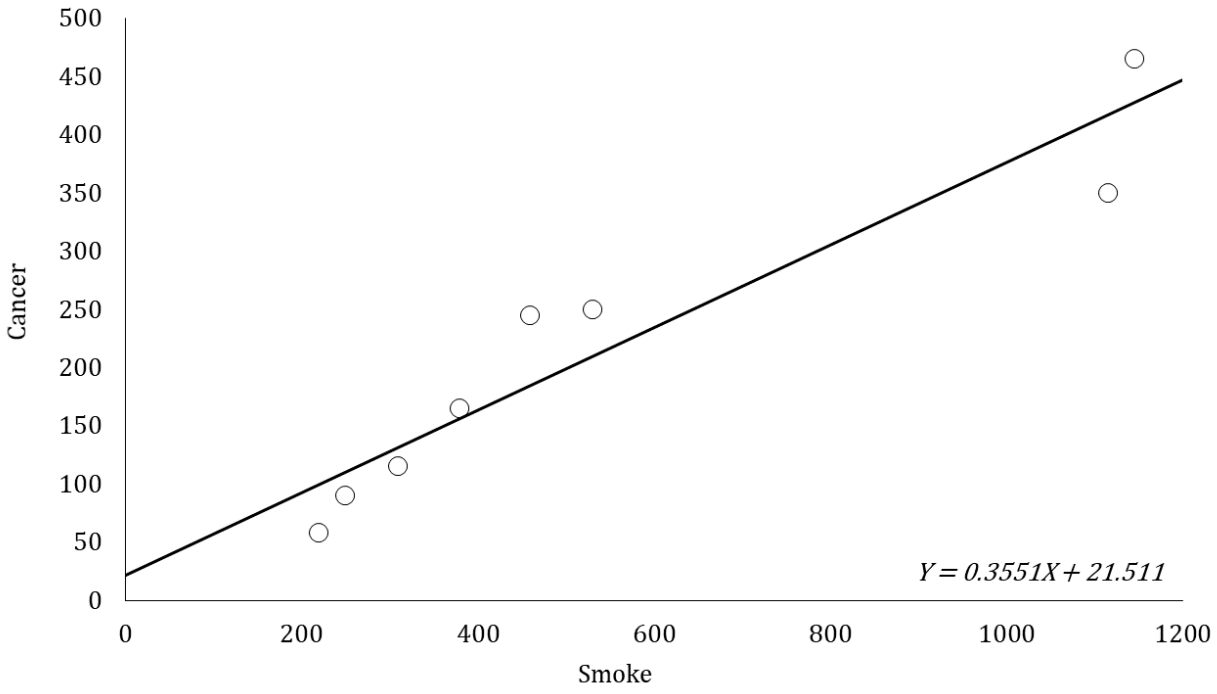

단순선형회귀모형

- 회귀식은 다음과 같이 추정되었다.

$$E(Y_i|X_i) = 21.511 + 0.355 \cdot X_i$$

- "국가의 1인당 담배 소비량이 한 단위 증가할 때, 100만 명당 폐암 발병자수는 0.355 만큼 증가한다."
- "아무도 흡연하지 않은 국가에서 100만 명당 폐암 발병자수는 21.511이다."
- 일반적으로 표현하자면, 독립변수 X의 값이 한 단위 변화(unit change)하면 회귀계수 b_1 만큼 종속변수 Y에 영향을 미친다.
- 회귀계수 및 상수의 해석은 무척 단순하지만 연습을 필요로 한다!

회귀계수와 상수의 도출

회귀계수와 상수의 도출

오차를 전반적으로 최소화하는 적합선이야말로 가장 잘 맞는 직선이다.

- 엑셀에서 그려진 적합선과 회귀식은 도대체 어떻게 추정된 것일까?
- 일단 회귀식이 추정되었다면 새로운 X_i 값이 주어질 때, (그에 대응하는) Y_i를 예측(predict)할 수 있다.
- 실제 자료 Y_i와 예측된(predicted) Y_i (혹은 $\widehat{Y}$) 간의 차이는 곧 오차(error)라고 볼 수 있다.

$$\widehat{e}_i = Y_i - \widehat{Y}_i = Y_i - (\widehat{\beta}_0 + \widehat{\beta}_1 X_i)$$

- 모집단에서는 오차, 표본에서는 잔차(residuals) e라고 구분된다(하지만 종종 잔차도 그냥 오차라고 부른다).
- 회귀식에서 추정량(estimates)에 대해서는 이렇게 ˆ(hat)을 붙인다.

회귀계수와 상수의 도출

- 예상되는 오차 $\widehat{\epsilon}_i$를 줄인다는 것은 현실 자료와 이론적 예측 사이의 괴리를 줄인다는 의미와 일맥상통한다.
- 물론 (오차 하나만 줄이는 것이 아니라) 오차를 전체적으로 줄이는 것이 중요하다.
- 단, 오차의 합을 그냥 최소화하지 않고 오차 제곱의 합(sum of squared error; SSE)을 최소화한다(Why?).
- 오차 제곱의 합을 최소화하는 β_0와 β_1을 찾음으로써, 주어진 자료를 가장 잘 설명할 수 있는 모형을 만들 수 있게 된다.

$$\underset{\beta_0,\beta_1}{\operatorname{argmin}} \sum_{i}^{n} \epsilon_i^2$$

- 이것이 바로 단순최소자승(ordinary least squares; OLS)이다.

회귀계수와 상수의 도출

lungcancer.csv를 사용하여 다음을 순서대로 계산해보자.

- 첫째, 추정된 y 또는 $\widehat{Y}_i$
- 둘째, 오차 또는 $\epsilon_i = Y_i - \widehat{Y}_i$
- 셋째, 오차제곱 또는 $\epsilon_i^2 = (Y_i - \widehat{Y}_i)^2$
- 넷째, 오차제곱합 또는 $\sum \epsilon_i^2 = (Y_i - \widehat{Y}_i)^2$

회귀계수와 상수의 도출

- 만일 추정된 회귀계수 $\widehat{\beta}_1$를 조금씩 바꾸어보면 어떻게 오차제곱합(SSE)이 변화하는지 살펴보자.

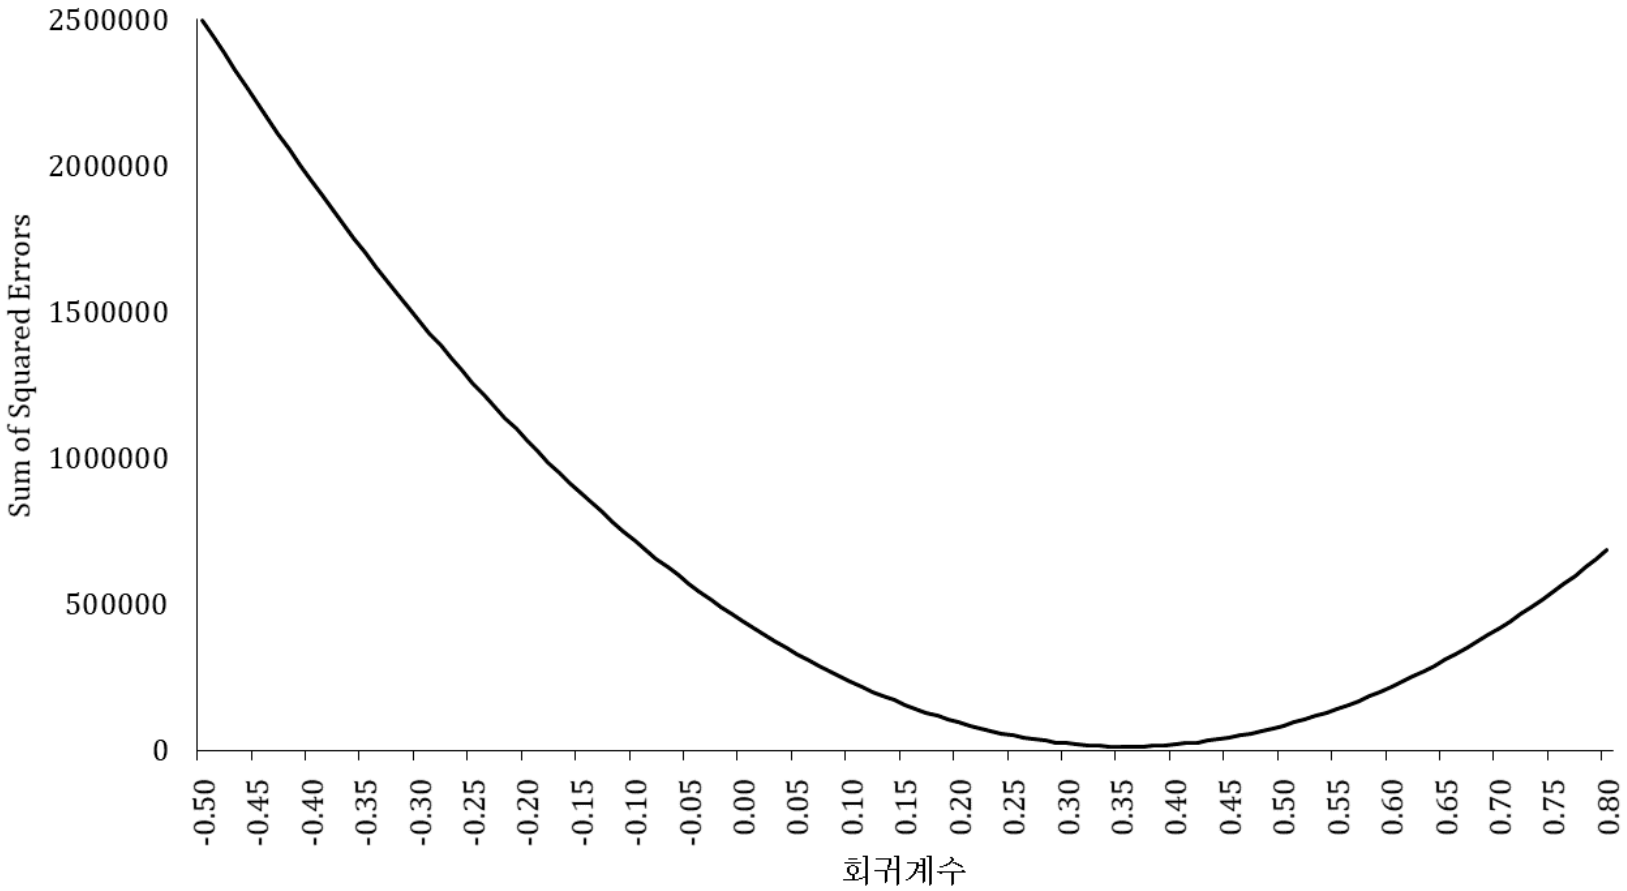

회귀계수와 상수의 도출

- 만일 추정된 상수 $\widehat{\beta}_0$를 조금씩 바꾸어보면 어떻게 오차제곱합(SSE)이 변화하는지 살펴보자.

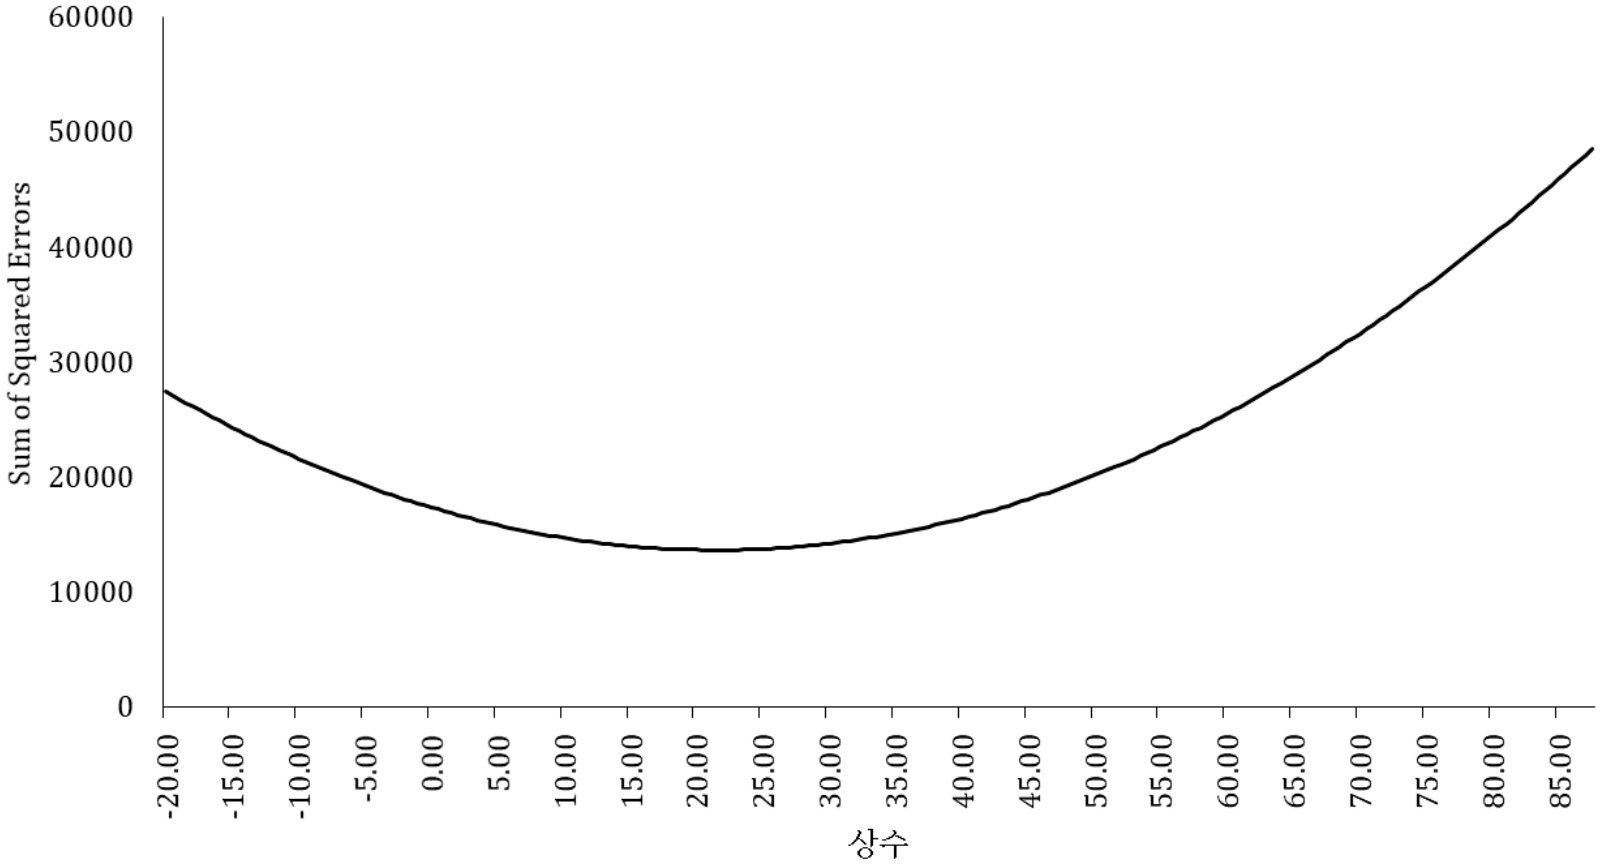

회귀계수와 상수의 도출

수학적으로 어떻게 회귀계수와 상수를 도출할까?

- (회귀식과 자료가 주어졌을 때) 단순최소자승(OLS)은 결국 다음과 같은 연립방정식(system of equations)에서 $\sum \epsilon_i^2$를 최소화하는 β_0와 β_1를 찾아내는 알고리즘(algorithm)인 셈이다.

$$
\begin{aligned}
58 &= \beta_0 + \beta_1 \cdot 220 + \epsilon_i \\
90 &= \beta_0 + \beta_1 \cdot 250 + \epsilon_i \\
115 &= \beta_0 + \beta_1 \cdot 310 + \epsilon_i \\
165 &= \beta_0 + \beta_1 \cdot 380 + \epsilon_i \\
245 &= \beta_0 + \beta_1 \cdot 460 + \epsilon_i \\
250 &= \beta_0 + \beta_1 \cdot 530 + \epsilon_i \\
350 &= \beta_0 + \beta_1 \cdot 1115 + \epsilon_i \\
465 &= \beta_0 + \beta_1 \cdot 1145 + \epsilon_i
\end{aligned}
$$

회귀계수와 상수의 도출

- 그 구체적인 원리는 미적분학(calculus)에서 2차함수 최적화 문제(quadratic optimization problem)라고 불린다.
- 이 최적화 문제의 목적함수(objective function)는 오차제곱합 $\sum \epsilon_i^2$ 이므로 2차항이다.
- 미적분학에서 미분의 의미는 기하학에서 기울기(slope)를 말한다(Why?). 아까 그래프에서 기울기가 0이 되는 지점은 어디이고 무엇을 의미할까?
- 그러므로 오차제곱합을 β_0 와 β_1 에 대해 편미분(partial derivation)한 식을 0으로 놓고 풀면 (오차의 제곱을 최소화하는) β_0 과 β_1 값을 알아낼 수 있다(교재 252–253).

$$\frac{\partial \sum \epsilon_i^2}{\partial \beta_0} = 0$$

$$\frac{\partial \sum \epsilon_i^2}{\partial \beta_1} = 0$$

회귀계수와 상수의 도출

회귀식을 일단 추정했다면 이제 마음껏 예측에 사용할 수 있다!

- 추정된 상수 $\widehat{\beta}_0$와 회귀계수 $\widehat{\beta}_1$를 통해 예측된(predicted) Y, 즉 $\widehat{Y}$를 얻을 수 있다.
- 앞서 추정한 회귀식에 따르면 $\widehat{\beta}_0 = 21.511$, $\widehat{\beta}_1 = 0.355$이므로 독립변수인 $smoke_i$에 원하는 값을 대입하면 종속변수인 $cancer_i$를 예측(prediction) 할 수 있다.

$$\widehat{cancer}_i = 21.511 + 0.355 \cdot smoke_i$$

- 만일 1인당 담배 소비량이 1000인 가상의 국가에서는 인구 100만 명당 폐암 발병자수가 몇 명인지 예측해보자.
- 예측은 회귀분석의 대단히 유용한 기능(e.g., 돈벌이) 중 하나이다. 이것으로 주가(stock price)나 집값 등에 관한 모형을 세우고 회귀계수 및 상수를 추정한 뒤, 조건별로 가격을 예측해 볼 수 있다.

단순선형회귀모형

엑셀로도 물론 쉽게 회귀식을 추정할 수 있다.

- 엑셀에서는 [데이터]-[데이터 분석]을 통해 "회귀 분석"을 선택한다.
- 회귀분석의 결과표는 크게 (1) 회귀분석 통계량, (2) 분산분석, (3) 추정된 회귀모형의 세 부분으로 나뉜다.
- 지금은 무엇도 잘 이해가 가질 않는다. 당연한 일이다. 하지만 적어도 하나는 이해할 수 있다. 관측수(number of observations)가 8개라는 점이다.
- 일단 "추정된 회귀모형" 부분을 살펴보자. 회귀계수와 상수가 있다!

회귀계수와 상수의 도출

예제 6. 재욱은 슬슬 학점에 대해 걱정이 들기 시작했다. 아르바이트를 열심히 하다보니 학교 수업 시수를 네 번 정도 빼먹었던 것이다. 재욱은 자신의 시험 성적을 예측해보고자 과거 수강생 자료를 확보하였고 회귀분석을 활용하여 자신의 학점(GPA)을 예측해보고자 한다. (attend.csv를 사용하여) 재욱을 위해 독립변수를 skipped로 종속변수를 termgpa로 하여 회귀분석을 수행하시오. skipped와 termgpa의 관계를 수식으로 표현하고 이를 해석하시오. 재욱의 예상 학점은 몇 점인지 예측하시오.

회귀계수와 상수의 도출

- 결석 시수(skipped)가 올해 학점(termgpa)에 영향을 미친다는 회귀모형을 세우고 "오차항을 최소화하는 β_0와 β_1"을 다음과 같이 추정할 수 있다.

$$Y_i = 3.043 - 0.076 \cdot X_i$$

- "결석 시수가 한 단위 증가할 때, 올해 학점은 -0.076점만큼 감소한다."
- "결석 시수가 0일 때의 올해 학점은 3.043이다."
- 추정된 상수 $\widehat{\beta}_0$와 회귀계수 $\widehat{\beta}_1$을 가지고 $\widehat{Y}$을 구할 수 있다. 우리가 추정한 모형에서 $\widehat{\beta}_0 = 3.043$ 이고 $\widehat{\beta}_1 = -0.076$이므로 독립변수 X_i에 원하는 값을 대입하면 종속변수 예측값 $\hat{Y}_i$를 얻을 수 있다.

$$\widehat{Y}_i = 3.043 - 0.076 \cdot 4 = 2.739$$

- "수업 시수를 네 번 빼먹은 재욱의 예상 학점은 2.739 이다."

끝!

와~ 숙제도 얼마 안남았네~