사회통계
다중회귀분석과 모형적합도

김현우, PhD[1]

[1] 충북대학교 사회학과 조교수

June 3, 2022

진행 순서

1. 지난 주 리뷰
2. 회귀계수와 상수의 유의성 검정
3. 다중회귀모형
4. 모형의 적합도

지난 주 리뷰

지난 주 리뷰

1. 주어진 자료는 두 커플의 고유번호(couple_id), 아내의 행복도 (wife_happy), 남편의 행복도(husband_happy)를 보여주고 있다. 두 변수 사이의 관계를 그래프로 표현하시오. 상관계수를 계산하고 유의성 검정을 수행하고 이를 해석하시오.

지난 주 리뷰

	A	B	C	D	E	F
1	couple_id	wife_happ	husband_happy			
2	6	8	9		상관계수	0.537
3	42	7	19		표준오차	0.085
4	46	29	32		t 값	6.303
5	47	45	29		색칠공부(L)	0.000
6	71	82	41		색칠공부(R)	0.000
7	85	15	95		p 값	0.000
8	92	62	33			
9	95	48	80			
10	109	5	11			
11	110	2	96			
12	117	34	11			
13	125	17	25			
14	134	59	21			
15	138	21	26			
16	151	45	46			
17	170	67	33			
18	178	80	80			
19	187	86	9			
20	193	34	23			
21	195	13	15			
22	196	5	7			
23	213	50	21			
24	220	14	80			
25	245	62	23			
26	249	4	12			
27	259	6	5			
28	277	21	15			
29	299	16	11			
30	327	45	41			
31	357	12	34			
32	376	24	20			
33	382	26	73			
34	383	14	14			
35	384	14	11			

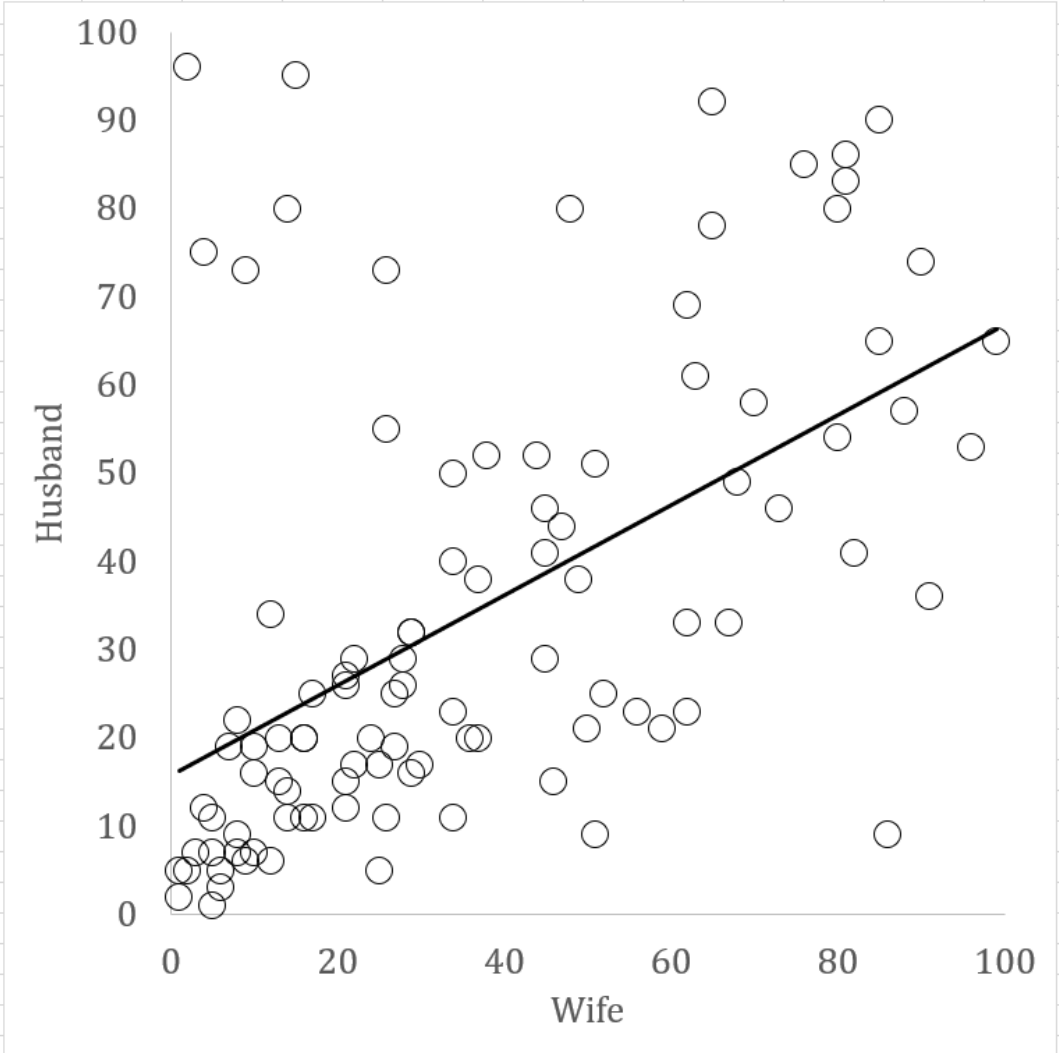

지난 주 리뷰

2. 당신의 관심에 따라 둘 중 하나의 행복도를 종속변수로 삼고 나머지 하나를 독립변수로 삼으시오. 회귀분석을 수행하고 그 결과를 최대한 "충실하게" 해석하시오.

지난 주 리뷰

- 추정된 회귀식은 다음과 같다.

$$Y = \widehat{\beta}_0 + \widehat{\beta}_1 \cdot X = 17.085 + 0.564X$$

- "남편의 행복이 (100점 만점에서) 10점 증가할 때, 아내의 행복은 5.64점 만큼 증가한다."
- "남편의 행복이 0점일 때, 아내의 행복은 17.085점이다."

요약 출력

회귀분석 통계량	
다중 상관계수	0.537102443
결정계수	0.288479034
조정된 결정계수	0.281218616
표준 오차	23.25899216
관측수	100

분산 분석

	자유도	제곱합	제곱 평균	F 비	유의한 F
회귀	1	21494.8498	21494.8498	39.73311644	8.36042E-09
잔차	98	53016.1102	540.9807164		
계	99	74510.96			

	계수	표준 오차	t 통계량	P-값	하위 95%	상위 95%	하위 95.0%	상위 95.0%
Y 절편	17.08491478	3.857098362	4.429473446	2.46062E-05	9.430628607	24.73920094	9.430628607	24.73920094
X 1	0.563646766	0.089419184	6.303421011	8.36042E-09	0.386197305	0.741096228	0.386197305	0.741096228

지난 주 리뷰

3. 당신의 독립변수가 정확히 50일 때 예상되는 종속변수의 값(predicted y)은 얼마인가? 당신의 독립변수가 2분위수일 때, 예상되는 종속변수의 값은 얼마인가? 당신의 독립변수가 3분위수일 때, 예상되는 종속변수의 값은 얼마인가? 3분위수일 때와 2분위수일 때 예상되는 종속변수 값의 차이는 얼마인가?

지난 주 리뷰

- "남편의 행복이 50점일 때, 아내의 예상되는 행복 점수는 45.267점이다."

$$Y = 17.085 + 0.564 \cdot 50 = 45.267$$

- "남편의 행복이 2분위수, 즉 중앙값(median)인 25점일 때, 예상된 아내의 행복 점수는 31.176점이다."
- "남편의 행복이 3분위수, 즉 52점일 때, 예상된 아내의 행복 점수는 46.395점이다."
- "남편의 행복이 2분위에서 3분위수로 증가한다면, 아내의 행복은 약 15.219점만큼 증가할 것으로 예상된다."

회귀계수와 상수의 유의성 검정

회귀계수와 상수의 유의성 검정

회귀분석에서도 표본을 넘어 모집단의 성격을 추론할 필요가 있다.

- 설령 우리가 미분 문제를 풀어 오차제곱합(SSE)을 최소화하는 회귀계수와 상수를 구했다고 하더라도 이것은 어디까지나 표본의 성격, 즉 통계량(statistic)일 뿐이다.
- 그렇기 때문에 모집단에서의 회귀모형과 표본에서의 회귀모형은 개념적으로 구별될 수 있다.

$$Y_i = \beta_0 + \beta_1 X_i + \epsilon_i \qquad \text{(모집단 회귀모형)}$$
$$Y_i = b_0 + b_1 X_i + e_i \qquad \text{(표본집단 회귀모형)}$$

- ϵ_i가 오차항(error term)이라고 불리우는 반면, e_i는 잔차항(residual term)이라고 불리운다.

회귀계수와 상수의 유의성 검정

- 우리는 다음과 같은 가설 구조에 따라 모집단의 성격, 즉 모수(parameter)에 대해서도 추론해야 한다.

$$H_0 : \beta_0 = 0 \qquad H_a : \beta_0 \neq 0 \qquad \text{(상수의 경우)}$$
$$H_0 : \beta_1 = 0 \qquad H_a : \beta_1 \neq 0 \qquad \text{(회귀계수의 경우)}$$

회귀계수와 상수의 유의성 검정

- 우리는 모집단에서 수많은 표본을 뽑아 그로부터 상수 b_0와 회귀계수 b_1를 추정한 뒤, 이것들의 표집분포를 구축해 볼 수 있다.
- 우리는 (1) 표본회귀모형 $y = b_0 + b_1 X + e$에 대해 정규성(normality)을 가정하거나 (2) 중심극한정리(central limit theorem)에 힘입어 아래 다음을 알 수 있다.

$$\beta_0 = E(\widehat{b_0})$$
$$\beta_1 = E(\widehat{b_1})$$

- 이제 (상수항와 회귀계수의) 표집분포의 표준편차를 표준오차(standard error)라고 부를 수 있다.

회귀계수와 상수의 유의성 검정

- (b_1 와 b_0 의) 표준오차는 추정값(estimates)에 대해 얼마나 확신하는가(confident)를 보여준다.

$$SE_{\hat{b}} = \sqrt{\frac{\sum(Y_i - \hat{Y}_i)^2/(n-2)}{\sum(X_i - \bar{X})^2}} = \frac{\sigma_e}{\sqrt{\sum(X_i - \bar{X})^2}}$$

- 분자는 오차의 표준편차이다. 이것은 오차평균제곱(mean squared error; MSE), 즉 오차제곱합(SSE)을 자유도로 나눈 값의 제곱근이다.
- 이 모형에서 회기계수와 상수 두 개가 사용되었으므로 자유도는 $n-2$이다.
- 분모는 독립변수의 편차제곱이다. 독립변수 X_i 의 분산이 작으면 회귀계수의 표준오차 SE_b 가 커지므로 b는 믿을 수 없게(unreliable) 된다.

회귀계수와 상수의 유의성 검정

t 분포를 사용하여 회귀계수와 상수에 대한 유의성 검정을 수행한다.

- 주어진 표본에서 회귀분석으로 추정된 회귀계수 $\widehat{b}_1$ 의 t 값은 아래와 같다.

$$t = \frac{\widehat{b}_1 - \beta_1}{SE_{b_1}} = \frac{\widehat{b}_1}{SE_{b_1}}$$

- 이때 t 분포의 자유도는 (상수와 회귀계수를 포함하여) $n-2$이다.
- 귀무가설이 옳다는 전제 아래 그린 표집분포는 t 분포한다. 표본에서 추정된 검정통계량 t 값의 위치를 확인해보고 그보다 극단적인 t 값을 얻게 될 확률, 즉 유의확률(p-value)을 계산할 수 있다.
- 만일 유의확률이 0.05보다 작다면 우리는 5% 유의수준 또는 95% 신뢰수준에서 귀무가설($H_0 : \beta_1 = 0$)을 기각하고 대립가설($H_a : \beta_1 \neq 0$)을 채택할 수 있다.

다중회귀모형

예제 1. lungcancer.csv는 이것은 8개 북유럽 국가의 1인당 담배 소비량(smoke)과 인구 100만 명당 폐암 발병자수(cancer)를 나타낸다. 폐암 발병자수를 종속변수로, 담배 소비량을 독립변수로 하는 회귀분석을 수행하고 유의성 검정 결과를 해석하시오.

회귀계수와 상수의 유의성 검정

다시 폐암 자료를 가지고 회귀분석을 수행해보자.

- 이제 회귀계수 뿐 아니라, 표준오차(standard error), t 통계량, 유의확률, 95% 신뢰구간도 어떤 의미인지 이해할 수 있다.
- 흡연은 폐암 발생의 통계적으로 유의한(statistically significant) 변수인가?
- 회귀계수와 상수의 95% 신뢰구간은 각각 어떻게 되는가? 이것을 색칠공부하듯 그림으로 표시해보자.

회귀계수와 상수의 유의성 검정

통계적 유의성와 실질적 유의성은 다른 개념이다

- 통계적 유의성(statistical significance)을 해석할 때 가장 흔한 실수 중 하나는 유의확률(p-value)이 작은 것을 가지고 선형적 관계의 강도(strength of linear relationship)로 해석하는 것이다. 유의확률은 단지 $H_0 : \beta = 0$라는 옳은 귀무가설을 기각하는 가능성을 보여줄 뿐이다.
- 실질적 유의성(substantial significance)은 통계적으로 유의한가 여부와 상관없이 실제로 얼마나 그 강도가 센가의 문제를 다룬다. 예컨대 한 시간 게임을 더하게 되면 독서시간이 2분 줄어든다는 발견(Cummings and Vandewater 2007)은 설령 통계적으로 유의하더라도 실질적으로는 그다지 유의하지 않다.
- 그러므로 통계적으로 유의한 결과를 얻었더라도 그 관계를 "실질적인 의미가 담겨있는 언어로 해석하고 음미하여" 실질적 유의성이 얼마나 높은지 판단할 필요가 있다.

Cummings, Hope M. and Elizabeth A. Vandewater. 2007. "Relation of Adolescent Video Game Play to Time Spent in Other Activities." Archives of Pediatrics Adolescent Medicine 161(7): 684-689.

다중회귀모형

다중회귀모형

현실에서는 아무도 단순회귀모형을 사용하지 않는다.

- 단순회귀모형(simple regression model)에서는 오로지 독립변수 X와 종속변수 Y, 딱 두 개의 변수만 고려하였다.

$$y_i = \beta_0 + \beta_1 X_i + \epsilon_i$$

- 하지만 이것은 학습용 혹은 연습용에 불과하다.
- 반면, (종속변수는 여전히 1개지만) 모형 안에 k개의 독립변수가 투입된 경우를 다중회귀모형(multiple regression model)이라고 부른다.

$$y_i = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + \ldots + \beta_k X_{ki} + \epsilon_i$$

다중회귀모형

다중회귀분석은 (다른 변수들의 효과를 통제한 상태에서) 특정 변수의 순효과를 살펴보는데 유용하다.

- 가령 결석 시수(skipped)가 올해 학점(termgpa)에 영향을 미친다는 회귀모형을 세우고 오차항을 최소화하는 b_0와 b_1을 다음과 같이 추정하였다고 하자.

$$termgpa_i = 3.043 - 0.076 skipped_i$$

- 회귀계수와 상수의 해석은 오로지 주어진 두 변수 간 사이의 1:1 관계로만 제한된다.

  (1) "결석 시수가 한 단위 증가할 때, 올해 학점은 -0.076점만큼 감소한다."
  (2) "결석 시수가 0일 때의 올해 학점은 3.043이다."

- 하지만 학점과 관련있는 변수는 결석 이외에도 많다!

다중회귀모형

- k개의 독립변수를 모형에 투입했다면 여러 영향력은 각각에 해당되는 변수 안으로 나뉘어 흡수된다. 그러므로 다중회귀분석은 (다른 변수의 영향력으로부터 독립된) 특정 변수의 순효과(net effect) 또는 부분효과(partial effect)를 살펴보는데 유리하다.
- 가령 임금(ln_wage)을 종속변수로, 나이(age)와 교육연수(educ)를 독립변수로 하는 회귀모형을 세웠다고 하자.

$$ln_wage = b_0 + b_1 age + b_2 educ + e$$

- 다중회귀분석을 통해 "나이(age)의 효과를 통제했을 때(즉 같은 나이일 때)" 교육연수(educ)가 한 단위 변화하면 임금(ln_wage)이 얼마만큼 변화하는지 살펴볼 수 있다.

다중회귀모형

다중회귀분석을 수행할 때는 (여러 변수를 사용하는 만큼) 변수의 사전 체크에 주의를 기울여야 한다.

- 여러 개의 독립변수를 모형에 한꺼번에 투입하다보면 하나하나를 꼼꼼하게 살펴보지 않고 그냥 대충 집어넣는 경우가 많다. 이것은 매우 위험하다!
- 개별 변수의 척도가 어떻게 구성되어 있는지, 분포는 어떠한지, 결측치(missing values)가 있는지 등을 반드시 꼼꼼하게 살펴보아야 한다.
- 엑셀에서 필터링(filtering)이나 소팅(sorting) 등을 통해 꼼꼼히 자료를 살펴보아야 하고, [자료 분석]에서 "기술 통계법"이나 "히스토그램" 등을 활용해 변수의 분포도 살펴보아야 한다.
- 불편하지만 엑셀에서는 반드시 모든 독립변수들이 나란히 붙어있어야 한다.

다중회귀모형

예제 2. college.csv는 미국 대학 파일별 졸업생의 평균수입(earnings), 학자금 상환비율(debt), 등록금(cost), 졸업률(grad), 대학이 도시에 위치해 있는가 여부(city)에 관한 정보를 담고 있다. 유진은 미국 유학을 계획 중에 있으며, 특히 등록금에 비해 졸업 후에 얼마를 버는지 잘 따져보고 대학을 결정하고자 한다. 학자금 상환비율의 영향력을 통제하였을 때와 그렇지 않을 때, 등록금과 졸업생 평균수입의 연관성이 어떻게 달라지는지 살펴보시오.

다중회귀모형

- 먼저 분석에 투입할 자료만을 남겨두고 나머지 변수는 일단 삭제하자. 먼저 각 변수별로 정렬해보고 맨 끄트머리를 살펴보아 혹시 극단치(outliers)가 있지는 않는지 살펴보자.
- 반드시 회귀분석과 함께 산점도와 적합선을 그려 정말로 선형관계가 존재하는지도 살펴보아야 한다. 등록금와 평균수입의 관계는 다음과 같이 산점도와 적합선으로 표현될 수 있다.

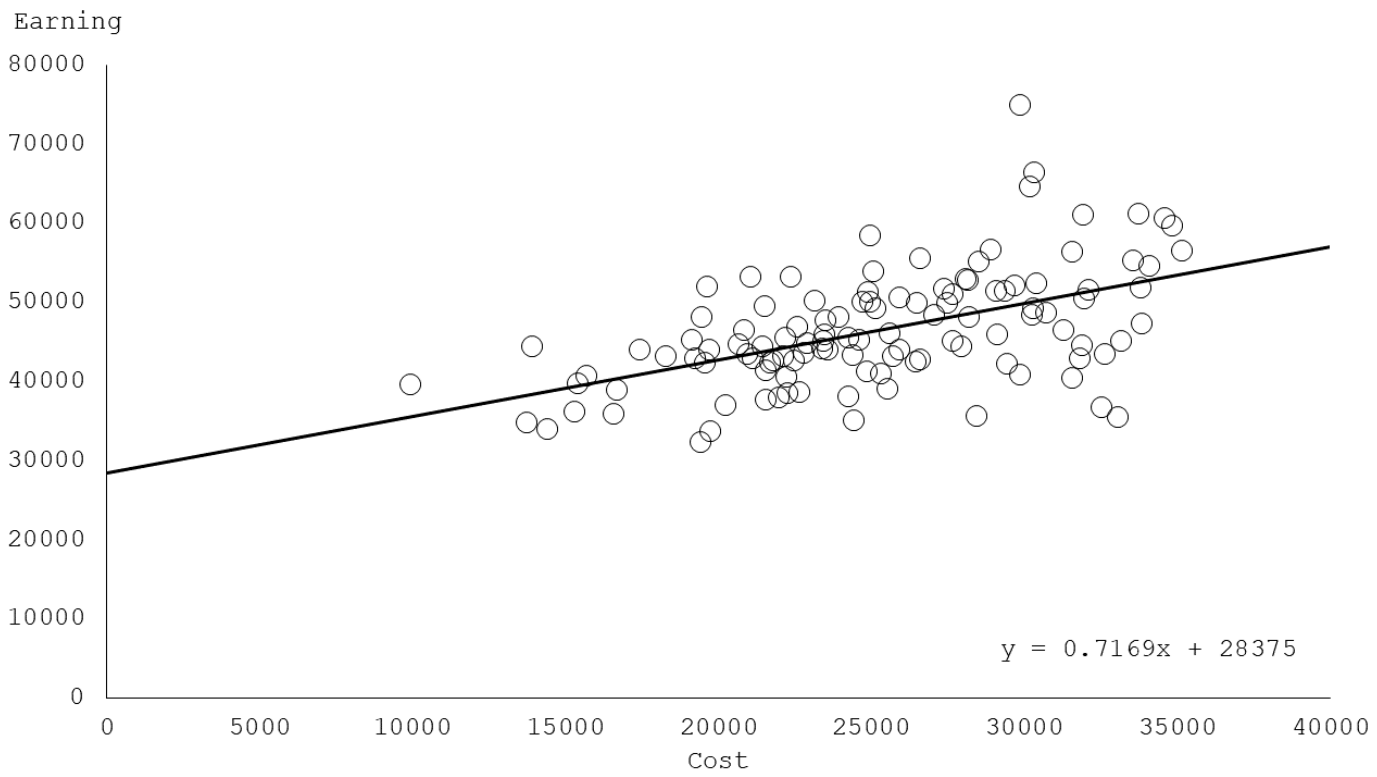

다중회귀모형

- 이제 우선 등록금이 졸업후 평균수입에 미치는 영향을 파악하기 위해 회귀분석을 수행할 수 있다.
- 한편 학자금 상환비율의 영향력을 배제하고 등록금만의 순효과를 파악하기 위해서는 다중회귀분석이 적절할 것이다.
- 그러므로 먼저 (1) 등록금과 졸업후 평균수입 사이의 단순회귀분석을 먼저 수행하고, 그 다음에 (2) 학자금 상환비율을 추가한 다중회귀분석을 수행하여 그 차이를 살펴보면 된다.
- 엑셀에서 [자료]-[자료 분석]을 통해 "회귀 분석"을 선택하자. 다중회귀분석에서는 모든 독립변수를 한번에 선택해야 하는 점에 주의하자.

다중회귀모형

- 다음은 단순회귀분석에서 추정된 등록금의 효과로 학자금 상환비율의 영향력은 제대로 반영하지 못하고 있다.

$$earnings = 28375.405 + 0.717 \cdot cost$$

- 반면 다중회귀분석의 추정 결과는 다음과 같다.

$$earnings = 2526.991 + .570 \cdot cost + 334.338 \cdot debt$$

다중회귀모형

- "학자금 상환비율의 효과를 무시하였을 때, 등록금이 1000달러 증가하면 평균수입은 717달러만큼 증가한다."
- "학자금 상환비율의 효과를 통제하였을 때, 등록금이 1000달러 증가하면 평균수입은 570달러만큼 증가한다."
- "등록금과 학자금 상환비율의 중앙값(median)은 각각 24957.5달러와 90%인데, 그 경우 예상되는 평균수입은 약 46,843 달러이다."
- "유진이 만일 등록금 30,000달러 정도에 학자금 상환비율이 최소 90%인 학교에 간다면 그녀의 예상되는 평균수입은 약 49,717달러이다."

모형의 적합도

모형의 적합도

개발한 회귀모형이 현실 자료에 얼마나 적합한지 살펴보아야 한다.

- 우리가 모형을 세워 그것을 현실 자료에 맞추어(fit) 본 이상, 이것이 얼마나 잘 맞는가를 말할 수 있어야 한다. 이것이 모형의 적합도(goodness-of-fit)이다.
- 우리는 여러가지 적합도 지표 가운데 결정계수(coefficient of determination)와 분산분석만 공부한다.
- 교재에 따라서는 회귀계수와 상수의 유의도 검정 또한 적합도 지표 중 하나로 취급하기도 한다.

모형의 적합도

먼저 결정계수를 살펴보자.

- 주어진 자료에 전체 변량(total variation)이 있다면, 이것은 (모형에 의해) 설명된 변량(explained variation)과 (그렇지 못하고) 남은 변량(residual variation)의 합이라고 분해될 수 있다.

$$\sigma^2_{total} = \sigma^2_{explained} + \sigma^2_{residual}$$

- 그렇다면 설명된 변량 $\sigma^2_{explained}$와 전체 변량 σ^2_{total}의 비율은 모형의 높은 설명력을 의미한다고 볼 수 있다.

$$R^2 = \frac{\sigma^2_{explained}}{\sigma^2_{total}} = 1 - \frac{\sigma^2_{residual}}{\sigma^2_{total}}$$

- 이것이 바로 결정계수 R^2의 직관적 의미이다. 설명된 변량과 전체 변량의 비율이므로 0과 1사이에 놓인다. 1에 가까울수록 모형은 높은 적합도를 보인다고 할 수 있다.
- 이제 남은 문제는 세 변량들이 어떤 식으로 정의되는가를 파악하는 것이다.

모형의 적합도

독립변수 X가 없을 때 종속변수 Y를 가장 잘 예측하는 요소는 무엇일까?

- 이 질문은 생각보다 매우 중요하다! 그것은 바로 종속변수의 평균 $\bar{Y}$이다(Why?). 우리는 사실 학기 초에 중심성향(central tendency)에 관해 공부하면서 이것을 은근슬쩍 배웠다.
- 이 원리는 우리에게 다음과 같은 중요한 원칙 하나를 제공한다.

  "어떤 모형을 세우던지 최소한 종속변수의 평균 $\bar{Y}$보다는 나은 설명력을 보여야 한다."
- 종속변수의 평균 $\bar{Y}$는 일종의 기준점이자 최소한의 바닥이다. 이것보다도 못한 모형은 아무런 가치도 없다(Why?).
- 한편 종속변수의 실제 값 Y_i는 일종의 천장과도 같다. 이것은 모형이 추구할 수 있는 최고의 이상(ideal)이기 때문이다.
- (직관적으로 설명한다면) 당연히 모형의 예측값 $\widehat{Y}_i$는 Y_i와 $\bar{Y}$ 사이 어딘가 놓이리라 생각할 수 있다(실제로는 꼭 그렇지 않을수도 있지만 너무 신경쓰지 말자).

모형의 적합도

- 그림을 통해서 우리는 다시 한 번 전체 변량이 잔여 변량과 설명된 변량의 합임을 직관적으로 이해할 수 있다.

$$(Y_i - \bar{Y}) = (Y_i - \widehat{Y}_i) + (\widehat{Y}_i - \bar{Y})$$

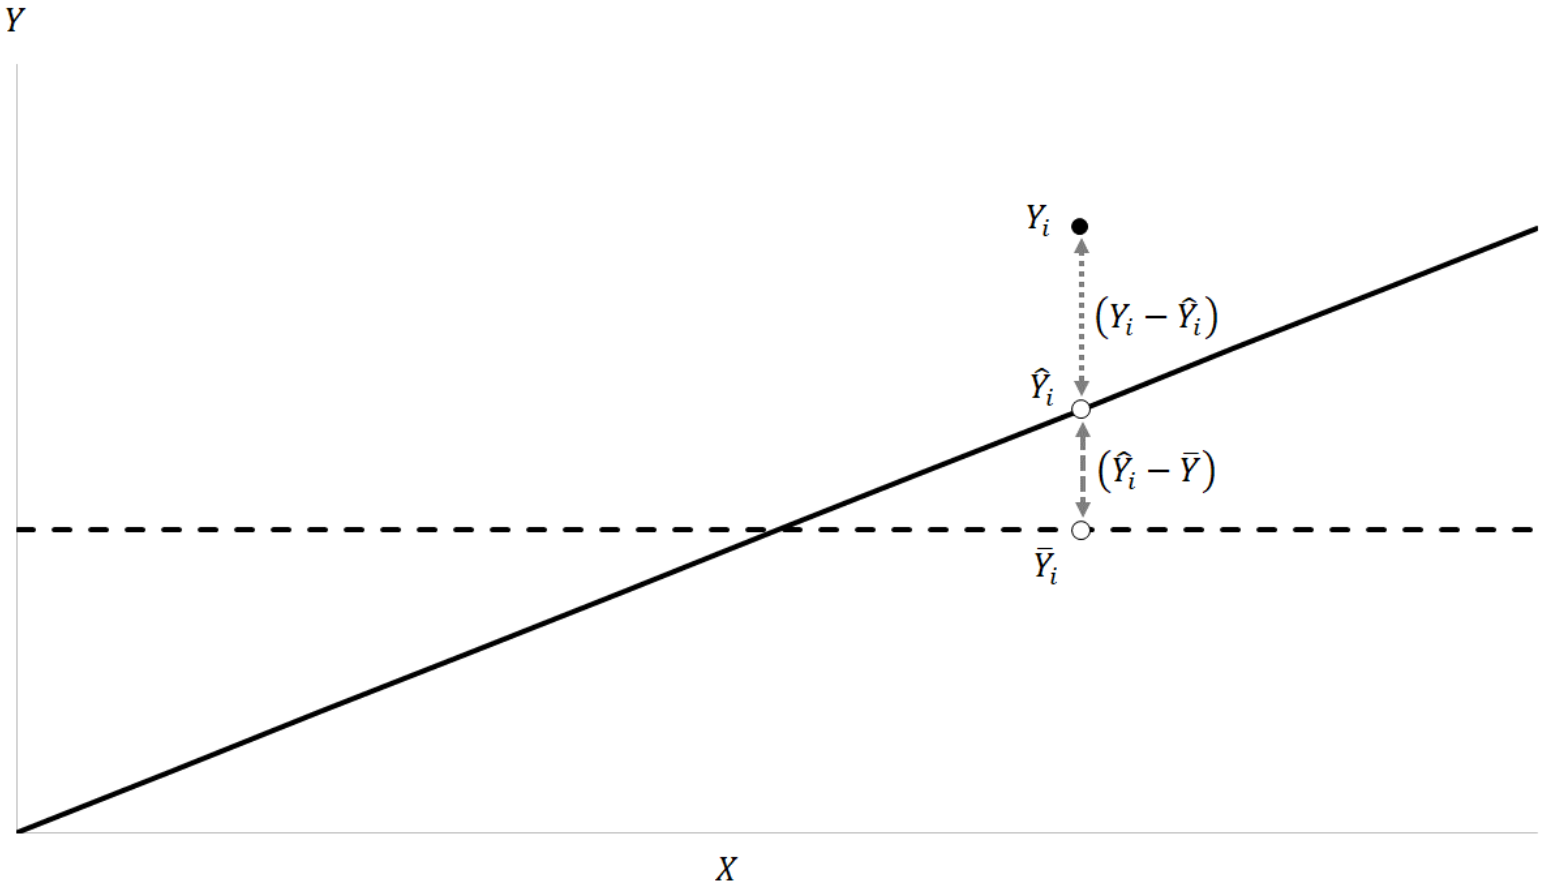

모형의 적합도

- 우리는 이제 제곱합(Sum of Squares; SS) 개념을 가지고 다음의 공식에 도달할 수 있다(증명 생략).

$$\sum(Y_i - \bar{Y})^2 = \sum(Y_i - \widehat{Y}_i)^2 + \sum(\widehat{Y}_i - \bar{Y})^2$$
$$SS_{total} = SS_{residual} \quad + SS_{explained}$$

- 이제 결정계수 R^2를 측정할 수 있다.

$$R^2 = \frac{SS_{explained}}{SS_{total}} = \frac{\sum(\widehat{Y}_i - \bar{Y})^2}{\sum(Y - \bar{Y})^2}$$
$$= 1 - \frac{SS_{residual}}{SS_{total}} = 1 - \frac{\sum(Y_i - \widehat{Y}_i)^2}{\sum(Y_i - \bar{Y})^2}$$

- 아까 그림을 통해 되새겨보면, y_i에 더 가까운 위치에 $\widehat{y}_i$가 놓일수록 R^2 역시 높으리라고 추측할 수 있다.

모형의 적합도

이제 college 자료의 회귀분석 결과에서 결정계수가 어떤 의미인지 이해할 수 있다.

- "학자금 상환비율과 등록금 두 독립변수를 사용한 선형모형은 자료의 전체 변량 중 36.2%를 설명한다."
- 0.362라는 결정계수는 너무 낮을까? 그렇지만도 않다. 겨우 두 개의 변수만으로 이 정도 설명했다는 것은 나름 탁월하다. 많은 사회과학 연구를 돌이켜볼 때 이 정도면 제법 괜찮다.
- 바로 아래 조정된 결정계수(adjusted R^2)는 무엇인가? 기본적으로 결정계수는 보다 많은 독립변수를 집어넣을 때 무제한적으로 팽창하는 성향이 있다. 그런데 이것은 오캄의 면도날 원칙(Occam's Razor)에 반하는 것이므로, 독립변수를 추가적으로 집어넣을 때마다 적절한 패널티를 가할 필요가 있다. 조정된 결정계수는 바로 이렇게 패널티가 가해진 결정계수이다.

모형의 적합도

근데 왜 하필 R^2 일까? 우리가 배운 r 은 상관계수였다. 혹시?

- 사실 상관계수 r 의 제곱은 단순회귀모형의 R^2 와 일치한다.
- 학부 사회통계학 레벨에서는 수학적으로 엄밀하게 이를 증명하는 대신 실습을 한 번 해보자.
- Earnings를 종속변수로 하고 Cost를 독립변수로 하였을 때, 단순회귀모형의 결정계수는 얼마인가? 또 CORREL$(\cdot)$ 함수로 구한 상관계수 r 의 제곱은 얼마인가?

모형의 적합도

분산분석 결과표 역시 모형 전체의 적합도를 보여준다.

- 아래와 같이 선형모형을 설정하였을 때 최악의 추정 결과는 무엇일까?

$$Y_i = \beta_0 + \beta_1 X_i + \cdots + \beta_{k-1} X_{k-1} + \beta_k X_k + \epsilon_i$$

- 그건 (상수 빼고) 모든 회귀계수가 0이 되는 상황이다. 보다 구체적으로 말해서 "모집단에서 (상수 빼고) 모든 β가 0인 상황"이다.
- 제대로 된 모형이라면 최소한 이런 경우는 부정할 수 있어야 한다. 만일 이런 상황을 부정할 수 없다면 "이 모형은 완전히 쓸모없다" 라는 말을 부정할 수 없는 것이나 마찬가지이기 때문이다.

모형의 적합도

- 그러므로 다음과 같은 가설구조를 검증해 볼 수 있다.

$$H_0 : \beta_1 = \beta_2 = ... = \beta_k = 0$$
$$H_a : (\beta_1 \neq 0) \text{ or } (\beta_2 \neq 0) \text{ or } ... \text{ or } (\beta_k \neq 0)$$

- 이 가설구조를 테스트할 수 있는 방법은 일원분산분석(one-way ANOVA)이다. 제 11주차 강의안을 꼭 복습하자!

모형의 적합도

- 제11주차 때 배운 일원분산분석의 검정통계량 F 값은 다음과 같았다.

$$F_{(k-1,n-k)} = \frac{\sigma^2_{between}}{\sigma^2_{within}} = \frac{MS_{between}}{MS_{within}} = \frac{SS_{between}/(k-1)}{SS_{within}/(n-k)}$$

- 다중회귀분석의 맥락에서 검정통계량 F 값은 다음과 같다. 단 k는 독립변수의 수를 의미한다.

$$F_{(k,n-k-1)} = \frac{\sigma^2_{explained}}{\sigma^2_{residual}} = \frac{MS_{explained}}{MS_{residual}} = \frac{SS_{explained}/k}{SS_{residual}/(n-k-1)}$$

- F 값이 클수록 유의확률(p-value)이 작아지므로 위 귀무가설을 기각할 수 있다.

모형의 적합도

- 분산분석표 안에 채워진 숫자는 다음과 같은 의미이다(교재 272).

Variance	SS	df	MS	F
Explained	$SS_{explained} = \sum(\widehat{Y}_i - \bar{Y})^2$	k	$MS_{explained}$	F
Residual	$SS_{residual} = \sum(Y_i - \widehat{Y}_i)^2$	$n-k-1$	$MS_{residual}$	
Total	$SS_{total} = \sum(Y_i - \bar{Y})^2$	$n-1$	MS_{total}	

- 계산을 직접 하는데 집착하기 보다는 그 논리 전개에 주목하여 공부하자.

모형의 적합도

이제 college 자료의 회귀분석 결과에서 분산분석이 어떤 의미인지 이해할 수 있다.

- "유의한 F"라고 괴상하게 이름 붙여진 항목을 보자. 이것은 유의확률(p-value)을 뜻한다. 이것이 0.05보다 작다는 사실은 95% 신뢰수준에서 다음의 귀무가설을 기각할 수 있다는 의미이다.

$$H_0 : \beta_1 = \beta_2 = 0$$

- 우리는 "모든 회귀계수가 0이다"라는 귀무가설을 기각하고 "최소한 하나의 회귀계수는 0이 아니다"라는 대립가설을 채택할 수 있었다. 다행이다~