사회통계

더미변수와 회귀분석의 가정

김현우, PhD[1]

[1] 충북대학교 사회학과 조교수

June 3, 2022

진행 순서

1. 더미변수의 활용
2. 회귀분석의 가정
3. 상관분석과 회귀분석
4. 마지막 코멘트

더미변수의 활용

더미변수의 활용

회귀분석에서도 질적 차이를 부각시킬 수 있다.

- 지금까지 회귀분석에서는 양적변수만 사용하였다. 그 결과 "X가 한 단위 증가할 때, Y는 β만큼 증가한다"와 같은 해석만을 사용하였다.
- 그러나 질적인 차이를 강조한 회귀분석은 불가능한 것일까? 가령 "X가 a가 아닌 b라면 Y는 β만큼 다르다"와 같은 해석 말이다.
- 가능하다! 질적변수, 특히 범주형 변수인 인종(1=백인; 2=흑인; ...)이나 종교(0=없음; 1=기독교; 2=불교; ...) 역시 회귀분석에서 독립변수로 사용할 수 있다.
- 그 방법은 (제10주차에서 이미 공부한) 더미 변수(dummy variable)를 활용하는 것이다.

더미변수의 활용

- 더미 변수란 처방, 조건, 또는 상황 등이 존재하면(present) 1로, 그것이 부재하면(absent) 0으로 더미 코딩(dummy coding)된 변수이다.
- 예를 들어, "처방 상태"에 관한 더미변수(treatment dummy)라면 받았다(1) 또는 안받았다(0) 중 하나의 값을 갖는다.
- "성별이 여성이다"에 관한 더미변수라면 그렇다(1) 또는 아니다(0) 중 하나가 된다.
- 이때 둘 다 1이거나 0일 수는 없다. 더미 코딩되었을 때 그 범주는 반드시 상호배타적(mutually-exclusive)이고 전체포괄적(all-inclusive)이어야 하기 때문이다.

더미변수의 활용

회귀분석 안에서 더미변수의 작동 원리와 해석은 매우 간단하다.

- 양적변수 X를 단순회귀모형에 투입했다면, "X가 한 단위 증가할 때 Y가 β_1만큼 변화한다" 그리고 "X가 0일 때, Y는 β_0와 같다" 라고 해석할 수 있다.

$$Y = \beta_0 + \beta_1 X$$

- 위 모형에서 만약 X가 양적변수가 아니라 더미 변수라도 해석은 마찬가지이다. 제일 흔한 더미 변수인 성별로써 남자는 0, 여자는 1로 더미 코딩되었다고 하자.

$$\widehat{Y} = \widehat{\beta}_0 \qquad (\text{if } X = 0)$$
$$\widehat{Y} = \widehat{\beta}_0 + \widehat{\beta}_1 \qquad (\text{if } X = 1)$$

- 남녀 간 $\widehat{Y}$의 격차는 $\widehat{Y}_{\text{여}} - \widehat{Y}_{\text{남}} = \widehat{\beta}_1$이다. 바로 더미변수의 회귀계수 $\widehat{\beta}_1$이다!

더미변수의 활용

예제 3. 민재는 유진이 유학을 결심했다는 소문을 듣고 이렇게 말했다. "유진, 시골에 있는 대학에 가면 근처에 취업할 곳이 마땅치 않아서 평균수입이 작을지도 몰라." 그 말에 유진은 흠칫 놀라 "과연 그렇구나, 민재!" 하고 대답했다. 등록금(cost), 졸업율(grad), 학자금 상환비율(debt)의 영향력을 통제하였을 때, 도시에 캠퍼스가 있는지 여부(city)가 졸업생의 평균수입(earnings)에 미치는 영향을 예측하는 회귀모형을 추정하고 해석하시오.

더미변수의 활용

X에 1과 0을 넣었을 때 각각 예상되는 Y의 차이로 더미변수를 해석하자.

- 엑셀에서 [데이터 분석]-"회귀 분석"을 수행하면 아래와 같은 회귀식을 추정할 수 있다.

$$earnings = 10004.966 + 0.435 \cdot cost + 178.099 \cdot grad + 141.478 \cdot debt + 2526.789 \cdot city$$

- 더미변수인 city의 회귀계수는 2526.789 이므로 "도시 대학을 졸업한 사람은 비도시 대학을 졸업한 사람보다 약 2,527달러 평균수입이 높다"고 해석할 수 있다.
- city는 95% 신뢰수준에서 통계적으로 유의하다. 그러므로 위 해석은 표본을 넘어 모집단에 대해서도 적용될 수 있다.
- 보통 통계적으로 유의하지 않으면 (찻잔 속의 태풍이므로) 해석을 아예 하지 않는 경우가 많다.

더미변수의 활용

- cost, grad, debt의 중앙값(median)은 각각 24957.5, 67, 90이다. 이를 아래 회귀식에 대입하면 아래와 같다.

$$
\begin{aligned}
earnings &= 10004.966 + 0.435 \cdot cost + 178.099 \cdot grad + 141.478 \cdot debt + 2526.789 \cdot city \\
&= 10004.966 + 0.435 \cdot 24957.5 + 178.099 \cdot 67 + 141.478 \cdot 90 + 2526.789 \cdot city \\
&= 45527.132 + 2526.789 \cdot city
\end{aligned}
$$

- 다른 모든 변수들이 중위값에 고정되었을 때, 비도시 대학 졸업자(city=0)의 예상되는 평균수입($\widehat{earnings}$)은 약 45,527 달러이다.
- 다른 모든 변수들이 중위값에 고정되었을 때, 도시 대학 졸업자(city=1)의 예상되는 평균수입($\widehat{earnings}$)은 약 48,054 달러이다.
- 다른 모든 변수들이 중위값에 고정되었을 때, 도시 대학 졸업자(city=1)는 비도시 대학 졸업자(city=0)보다 약 2,527달러 더 많이 번다.

더미변수의 활용

범주형 변수에서 더미 변수들을 직접 만들 수도 있다.

- 만일 범주형 변수인 종교가 "기독교=1, 천주교=2, 불교=3, 원불교=4, 기타=5, 종교없음=6"으로 주어졌다고 하자.
- 엑셀에서 IF(·) 함수를 사용해 범주형 변수로부터 더미변수를 만들어낼 수 있다. 자세한 절차는 이미 제10주차에서 배웠으므로 강의안을 복습하자.
- 그런데 위의 범주형 변수에서 6개의 더미변수를 만들었더라도 이 모든 변수를 독립변수로 집어넣을 수는 없고 반드시 하나를 빼고 집어넣어야만 한다.
- 하나를 빼야 하는 이유는 (1) 나머지 5개의 더미변수로부터 마지막 하나의 더미변수 내용을 완벽하게 추측할 수 있고, (2) 계산상의 이유로 똑같은 독립변수를 여러 개 집어넣어서는 안되기 때문이다.

더미변수의 활용

- 이렇게 빠진 변수를 기저범주(baseline category) 또는 기준집단(reference group)이라고 부른다.
- 모든 더미변수의 해석은 기준집단에 비교하여 이루어진다. 그러므로 아까 도시 더미변수를 해석할 때도 비도시에 비교하여 해석이 이루어졌다.
- 아까 예제 3에서 도시 더미변수 외에 비도시 더미변수를 따로 넣지 않았던 이유도 여기에 있다. 남녀 더미변수의 경우에도 마찬가지이다.

회귀분석의 가정

회귀분석의 가정

단순최소자승은 사실 몇 가지 가정에 입각하고 있다.

- 이 가정들은 (1) 단순최소자승을 통해 추정량(estimator)을 도출하고 (2) OLS 추정량이 왜 왜곡이 없고(unbiased) 다른 추정량보다 작은 표준오차만을 가지는지, 즉 효율적(efficient)인지 증명하는데 조용히 쓰인다.
- 재미있게도 교과서에 따라 가정의 목록이 조금씩 다르다. 보통 다음 중 어느 하나만을 설명한다.

  (1) 고전적 가정(classical assumption)
  (2) 종속변수 Y에 대한 가정
  (3) 오차항 ϵ에 대한 가정
- 이것은 상당히 복잡하고 대학원에서나 다루어지는 문제로 여겨진다.

회귀분석의 가정

- 그런데 어이없게도 사회조사분석사 2급에서 몇 차례나 기출문제가 등장했다. 수험서 레벨에서 오차항 ϵ에 관해 흔히 세 가지 가정을 한다.
  1. 정규성(normality)

$$\epsilon_i \sim N(0, \sigma^2)$$

  2. 등분산성(homoscedasticty)

$$Var(\epsilon_i|X) = \sigma^2$$

  3. 독립성(independence)

$$Cov(\epsilon_i, \epsilon_j) = 0$$

- 약간 논리적으로 엉성하지만 적어도 틀린 것은 아니니 받아들여도 된다.

회귀분석의 가정

- 논리적으로 좀 더 엄격하게는 다음과 같이 오차항 ϵ에 대한 가정을 나열할 수 있다.

  1. 외생성(exogeneity)/조건부 영평균(zero conditional mean)

$$E(\epsilon_i|X_i) = 0$$

  2a. 등분산성(homoscedasticty)

$$Var(\epsilon_i|X) = Cov(\epsilon_i, \epsilon_i) = \sigma^2$$

  2b. 자기상관 없음(no autocorrelation)

$$Cov(\epsilon_i, \epsilon_j) = 0$$

- 그리고 위 가정들보다 좀 더 강한 가정 하나를 "편의상" 추가한다.

  3. 정규성(normality)

$$\epsilon_i \sim N(0, \sigma^2)$$

회귀분석의 가정

- 오차항 ϵ에 대한 가정을 넘어 회귀모형에 대한 고전적 가정(classical assumptions)은 좀 더 광범위하다.

  1. 선형성(linearity): Y와 X의 관계는 선형적으로(linearly) 표현된다.
  2. 완전공선성 없음(no perfect collinearity): 똑같은 독립변수 두 개 이상 넣지 않는다.
  3. 비확률적 독립변수(non-stochastic Xs): 독립변수는 외생적이다.

- 물론 위에 더하여 오차항에 대한 가정도 필요하다!
- 어떤 교과서는 4. 극단치 없음(no outliers)을 포함하기도 한다. (분명히 필요하긴 하지만) 가정이라고 하기엔 좀 무리가 있다.
- 보통 연구자들은 다음과 같이 짧게 (모든 가정을 충족하는) 전형적인 회귀모형을 정의한다.

$$\mathbf{Y} = \mathbf{XB} + \boldsymbol{\epsilon}$$

$$\boldsymbol{\epsilon} \sim N(0, \sigma^2)$$

회귀분석의 가정

회귀분석의 가정은 고급통계학의 관문과도 같다.

- 회귀모형에서 가정이 깨지면 더이상 단순최소자승(OLS)이 최적이라고 보장할 수 없다.
- 그러나 가정이 깨져도 이에 대응하는 별도의 기법이 존재한다. 이 고급 기법들은 각각의 가정 위배에 대응하여 다루어진다.
- 그런 의미에서 OLS의 가정에 관해 심도있게 학습하는 것은 고급통계학으로의 관문(gateway)으로 이어진다고 할 수 있다.
- $1 + 1 = 2$ 를 배우는 것은 금방이지만 왜 이 식이 성립하는지 공리(axioms)나 가정을 공부하는 것은 어렵다. 그렇기 때문에 학부 사회통계학에서 가정은 더이상 다루어지지 않는다.

상관분석과 회귀분석

상관분석과 회귀분석

회귀분석에서는 독립변수와 종속변수 사이의 비선형적 관계도 추정할 수 있다.

- 상관계수는 변수 간 선형적 관계의 강도(strength of the linear relationship)를 알려줄 뿐이다.
- 그러나 회귀분석은 매우 탄력적이라서 두 변수 사이에 비선형적 관계(nonlinear relationship)가 있더라도 어렵지 않게 살펴볼 수 있다. 구체적인 방법은 사실 아래처럼 매우 쉽지만 학부 과정에서는 다루지 않는다.

$$Y = \beta_0 + \beta_1 X + \beta_2 X^2 + \epsilon$$

상관분석과 회귀분석

우리가 배운 회귀분석은 인과분석이 아니다.

- "상관분석은 상관관계를 살펴보고, 회귀분석은 인과관계를 살펴본다"는 식의 헛소문은 전혀 사실이 아니다.
- 회귀분석을 통해 계산된 회귀계수는 사실 수학적으로 꼼꼼히 따져보면 표준화된 상관계수에 불과하다.
- 비실험적 자료(non-experimental data) 혹은 관찰자료(observational data)라고 불리우는 일반적인 사회과학 데이터를 가지고 평범하게 회귀분석하였다면 단지 상관관계만을 파악한 것이다.
- 물론 인과관계가 아니라고 연구로서 무가치해지는 것은 아니다. 다만 회귀분석의 결과를 해석할 때 (실험설계가 아닌 이상) 마치 인과관계인 것처럼 말하지 않아야 한다.

상관분석과 회귀분석

예제 4. servpc.csv 파일을 엑셀로 불러오시오. 이 자료는 2010년 우리나라 군 별 인구 1천 명당 공무원 수(servpc)와 재정자립도(finind), 그리고 광역자치단체별 더미변수들을 담고 있다. 다음의 물음에 답하시오.

(1) 종속변수는 재정자립도, 독립변수는 광역자치단체별 더미변수들인 선형모형을 세우고 회귀분석하시오. 회귀계수, 유의성 검정 및 적합도 검정 결과를 모두 충실히 해석하시오.

(2) 독립변수로 공무원 수도 추가한 선형모형을 다시 한 번 세우고 회귀분석하시오. 회귀계수, 유의성 검정 및 적합도 검정 결과를 모두 충실히 해석하시오.

마지막 코멘트

마지막 코멘트

단순최소자승 회귀분석은 기초사회통계의 마지막 관문이다.

- 지금까지 걸어온 길을 반추해보자. 단순최소자승 회귀분석은 가설검정의 논리, t 검정, 일원분산분석(one-way ANOVA)에 이르기까지 모든 기법을 총동원하고 있다.
- 물론 우리는 중간시험 전까지 가설검정의 논리를 이해하기 위해서 확률변수, 확률분포, 표집분포, 표준오차, 누적분포함수, 표준정규분포, 임계값, 유의수준을 배웠다.
- 이제 여러분은 기초사회통계에 필요한 모든 지식을 학습하였다.
- 하나 아쉬운 것은 우리가 전문적인 통계분석 패키지, 특히 SPSS를 배우지 못한 점이다. 대신 엑셀을 배웠으니 뭐 나쁜 딜은 아니었던 것 같다.

마지막 코멘트

그럼 다음 학기 전공필수 사회통계연습에서 우리는 무엇을 배울까?

- 기초통계분석을 할 수 있게 된 우리는 이제 그 원리와 방법론을 활용하여 표본조사방법(survey sampling methods), 온라인 실험설계(online experimental design)와 A/B 테스트, 지리정보시스템(GIS)과 소셜 네트워크(social network) 등 고급 시각화 기법, 군집분석(cluster analysis) 등을 배운다.
- 그때도 숙제는 매주 있다! 당연하지~
- 기초사회통계는 당연히 다음 수업에서 계속 쓰인다. 잊지 않기 위해서라도 방학 때 사회조사분석사 2급 준비를 해두자(어차피 졸업 요건이다).

마지막 코멘트

기말시험에 관한 코멘트(중요함)

- 모든 과제를 전부 다 처음부터 풀어볼 것. 이번 학기에 배운 것은 하나도 모르는 것이 없어야 한다. 쉬지 않고 쭉 풀어보는 연습을 해서 "그 동안 배운 모든 것은 회귀분석과 이런 식으로 이어지는구나 " 하고 깨달아야 한다.
- 오프라인으로 시험을 보기 때문에 컨디션 관리에 만반을 기하자.
- 원한다면 마음껏 인터넷 검색을 하거나 교과서를 참고해도 좋다. 숙제를 다시 봐도 좋고 신문을 읽어도 좋다. 하지만 기억할 것: 시간은 2시간 밖에 없다. 이 시간을 넘기면 감점한다.
- 시험은 PDF 및 워드 파일로 주어지며 최선을 다해 모든 풀이과정과 논리적 흐름을 담아 작성할 것. 계산이 틀려도 논리가 맞으면 부분 점수가 인정된다.
- (필요하다면) 이번 주에는 가능한 친구들과 직접 만나 토론하여 모르는 것을 서로 물어보고 가르쳐 줄 것. 그래도 모르겠으면 메일 또는 조교 선생님을 통해 약속을 잡아 내 연구실로 찾아올 것(다음 주 내내 오후에는 최대한 시간을 비워둘 예정). 아주 짧은 내용이라면 메일로 질문해도 괜찮다.

끝!

어라? 숙제가 없네?